

Université de Montréal

**Pour une IA plus responsable, détection de biais dans
les entrevues de recrutement**

par

Denis Lemarchand

Département d'informatique et de recherche opérationnelle
Faculté des arts et des sciences

Mémoire présenté en vue de l'obtention du grade de
Maître ès sciences (M.Sc.)
en Intelligence Artificielle

July 8, 2025

Université de Montréal

Faculté des arts et des sciences

Ce mémoire intitulé

Pour une IA plus responsable, détection de biais dans les entrevues de recrutement

présenté par

Denis Lemarchand

a été évalué par un jury composé des personnes suivantes :

Jian-Yun Nie

(président-rapporteur)

Esma Aïmeur

(directeur de recherche)

Claude Frasson

(membre du jury)

Résumé

Ce mémoire s’inscrit dans la réflexion actuelle sur l’éthique de l’intelligence artificielle (IA) appliquée aux ressources humaines en entreprise, et notamment dans le processus de recrutement. L’objectif poursuivi est double : concevoir un environnement de simulation permettant de générer des entretiens synthétiques contrôlés pour l’étude des biais, puis développer un système d’audit capable de détecter automatiquement les stéréotypes de genre dans ces échanges.

Pour cela, une solution complète a été développée autour d’une équipe d’agents IA chargée de générer les postes, les profils de candidats et de recruteurs, de simuler les entretiens, puis d’analyser les dialogues à travers une équipe virtuelle EDI (Équité, Diversité, Inclusion). L’architecture repose sur des LLMs commerciaux, un **framework agentic** et l’optimisation fine des interactions entre agents via des stratégies de **prompt engineering** et d’orchestration multi-agents.

Les résultats montrent que l’environnement de simulation permet de produire des conversations pertinentes, réalistes et lisibles, respectant les critères fixés. Le système d’audit par agents EDI permet une détection fiable des biais de genre et fournit une explication des scores attribués, en s’appuyant directement sur le contenu des échanges. L’approche retenue souligne un intérêt fondamental : démontrer que les LLMs, capables de reproduire des biais, peuvent aussi être mobilisés pour les détecter, sans nécessiter la construction de modèles de classification traditionnels spécialisés, souvent longs à entraîner et très consommateurs de données (comme les classifieurs basés sur BERT).

L’environnement de simulation conçu est extensible et pourra à l’avenir être utilisé pour étudier d’autres formes de biais au-delà du stéréotype de genre, ouvrant ainsi la voie à des applications pratiques pour une IA plus éthique dans les ressources humaines.

Mots clés : Intelligence artificielle, Agents IA, Modèles de langage de grande taille (LLM), Systèmes multi-agents, Détection de biais, Stéréotypes de genre, Discrimination algorithmique, Recrutement, Ressources humaines, Équité diversité et inclusion (EDI), Conversations d’entrevue, Données synthétiques, Processus de recrutement, Audit automatisé, Éthique de l’IA.

Abstract

This thesis is part of the current reflection on the ethics of artificial intelligence (AI) applied to human resources in the workplace, particularly in the recruitment process. The objective is twofold: to design a simulation environment capable of generating controlled synthetic interviews for bias analysis, and to develop an auditing system that can automatically detect gender stereotypes in these interactions.

To achieve this, a complete solution was developed around a team of AI agents tasked with generating job postings, candidate and recruiter profiles, simulating interviews, and analyzing the dialogues through a virtual EDI (Equity, Diversity, Inclusion) team. The architecture is based on commercial LLMs, an agentic framework, and the fine-tuning of agent interactions through prompt engineering strategies and multi-agent orchestration.

The results show that the simulation environment successfully produces relevant, realistic, and readable conversations that meet the defined criteria. The EDI agent-based auditing system reliably detects gender bias and provides an explanation for the assigned scores, directly based on the content of the conversations. The chosen approach highlights a key insight: demonstrating that LLMs, while capable of reproducing biases, can also be leveraged to detect them, without requiring the construction of traditional specialized classification models, which are often time-consuming to train and highly data-intensive (such as BERT-based classifiers).

The simulation environment is extensible and can in the future be used to study other forms of bias beyond gender stereotypes, thus paving the way for practical applications toward more ethical AI in human resources.

Keywords: Artificial intelligence, AI agents, Large language models (LLM), Multi-agent systems, Bias detection, Gender stereotypes, Algorithmic discrimination, Recruitment, Human resources, Equity diversity and inclusion (EDI), Interview conversations, Synthetic data, Recruitment process, Automated audit, AI ethics.

Table des matières

Résumé	iii
Abstract	v
Liste des tableaux	xi
Liste des figures	xii
Liste des sigles et des abréviations	xiv
Remerciements	xvii
Chapitre 1. Introduction	1
1.1. Objectifs et résultats clés recherchés	4
1.2. Structure du mémoire	5
1.3. Utilisation de l'IA générative dans ce mémoire	7
Chapitre 2. Concepts et travaux associés	9
2.1. Le processus et les techniques de recrutement	10
2.2. L'équité dans le domaine des ressources humaines	12
2.3. L'équité de genre dans le monde du travail	18
2.4. Les LLM	21
2.4.1. De la genèse à état de l'art	22
2.4.2. Les modèles de langage avant les « Transformers »	22
2.4.3. Le mécanisme d'attention et les modèles de « Transformer »	25
2.4.4. L'ère des pré-LLM, GPT-1 et BERT	28
2.4.5. Les propriétés distinctives des LLM	32
2.4.6. L'ère des LLM et leur avenir	36
2.4.7. Limites et impacts sur la société	41

2.4.8.	Les hallucinations et la confiance.....	45
2.5.	Les Agents IA	50
2.5.1.	Architecture des agents IA	53
2.5.2.	Systèmes multi-agents	55
2.5.3.	Cadres multi-agents.....	56
2.5.4.	Cas d'utilisation des agents IA	58
2.5.5.	Évaluation des agents IA.....	59
2.5.6.	Tendances actuelles et orientations futures	60
2.6.	Derniers développements.....	63
2.6.1.	La distillation.....	63
2.6.2.	La loi d'échelle standard	64
2.6.3.	Le phénomène DeepSeek	65
2.7.	Conclusion.....	66
Chapitre 3.	Approche et méthodologie	69
3.1.	Création d'un jeu de données synthétiques	70
3.1.1.	Stratégie pour générer le jeu de données synthétiques.....	70
3.2.	Stratégies de validation de l'agent IA Auditeur EDI.....	76
3.2.1.	Stratégies de validation de la performance.....	76
3.2.2.	Cas d'utilisation de la stratégie combinée.....	78
3.3.	Conclusion.....	80
Chapitre 4.	Architecture et modèles mis en œuvre	83
4.1.	Agent IA de génération de postes	84
4.1.1.	Implémentation.....	84
4.1.2.	Apprentissages.....	84
4.2.	Équipe d'agents IA de création des profils candidats.....	86
4.2.1.	Composition de l'équipe	86
4.2.2.	Implémentation.....	87
4.2.3.	Apprentissages.....	87
4.3.	Agent IA de génération de profils de recruteur	89
4.3.1.	Implémentation.....	90

4.3.2.	Apprentissages	90
4.4.	Génération des conversations d'entrevue	91
4.4.1.	Composition de l'équipe et flux de travail	91
4.4.2.	Implémentation	92
4.4.3.	Apprentissages	92
4.5.	Analyse des conversations d'entrevue	93
4.5.1.	Composition de l'équipe	93
4.5.2.	Implémentation	93
4.5.3.	Apprentissages	93
4.6.	Orchestration des scripts	94
4.6.1.	Implémentation	95
4.6.2.	Apprentissages	95
4.7.	Structure du projet	97
4.8.	Conclusion	99
Chapitre 5.	Expériences et résultats	102
5.1.	Création d'un jeu de données pour la recherche	103
5.1.1.	Méthodologie pour évaluer les échanges synthétiques générés	104
5.1.2.	Statistiques générales	105
5.1.3.	Constats	109
5.1.4.	Conclusion	110
5.2.	Détection des biais avec une équipe d'agents EDI	112
5.2.1.	Calibrage	112
5.2.1.1.	Automatisation du calibrage	113
5.2.2.	Méthodologie	114
5.2.3.	Analyses des expertes RH	116
5.2.4.	Conclusion	116
5.3.	Conclusion	118
Chapitre 6.	Conclusion et travaux futurs	121
6.1.	Recommandations issues des apprentissages sur l'utilisation des LLM dans les agents IA	122

Qualité des prompts : levier central de performance.....	122
Robustesse conditionnée par la diversité des données.....	122
Choix du modèle et paramétrage adapté à la tâche.....	122
Génération locale versus raisonnement global.....	123
Orchestration rigoureuse des agents.....	123
Nécessité d’une supervision humaine outillée.....	123
Conclusion.....	123
6.2. Sensibilisation aux menaces des agents IA pour l’équité dans un contexte RH.....	124
6.3. Travaux futurs.....	125
Représentation visuelle du biais.....	125
Vers une génération plus fine des conversations.....	126
Détection des biais par apprentissage supervisé.....	127
Vers des études à visée plus appliquée.....	127
Intégration du raisonnement décisionnel.....	127
6.4. Conclusion générale.....	128
Chapitre 7. Bibliographie.....	130
Références.....	131
Chapitre 8. Annexes.....	136
8.1. Agent IA de génération de postes.....	136
8.1.1. Implémentation.....	136
8.1.2. Optimisation du prompt pour la génération de postes.....	139
8.1.2.1. Prompt pour l’optimiseur de prompt - GPT-4o1.....	139
8.1.2.2. Résultat de l’optimiseur de prompt.....	141
8.2. Équipe d’agents IA de création des profils candidats.....	144
8.2.1. Implémentation.....	144
8.3. Agent IA de génération de profils de recruteur.....	150
8.3.1. Implémentation.....	150
8.3.2. Génération du prompt pour l’agent.....	151
8.3.2.1. Méta prompt.....	151
8.3.2.2. Exemple de prompt généré pour l’agent.....	152

8.4.	Génération des conversations d’entrevue.....	154
8.4.1.	Implémentation.....	154
8.4.2.	Évaluation de la qualité des conversations.....	159
8.5.	Analyse des conversations d’entrevue.....	163
8.5.1.	Implémentation.....	163
8.6.	Calibrage des agents IA EDI.....	166

Liste des tableaux

2.1	Comparaison de performance des Transformer vs SOTA en 2017, A. Vaswani et Al, « Attention is all you need ».....	30
2.2	Résultats des performance BERT au benchmark GLUE, extrait de l'article [19]..	31
2.3	Résultats T5 sur le benchmark GLUE, extrait de l'article original [52].....	33
2.4	Comparaison entre les LLM et l'IA agentique	50
3.1	Stratégies de validation de la performance de l'auditeur EDI.....	78
4.1	Technologies et frameworks utilisés dans le projet	98
4.2	Détails techniques par composant	99
5.1	Liste des postes générés pour le sondage.....	104
5.2	Répartition des répondants (seuls les prénoms sont fictifs).....	107
5.3	Évaluation comparative des biais sur les 6 cas présentés aux expertes RH.....	116

Liste des figures

1.1	Articles: Forbes (03/2023, 01/2024), Radio-Canada (01/2023) sur l'IA en RH ...	2
1.2	Exemple d'agent IA (compagnie FinalRoundAI) pour assister les candidats lors des entrevues, site consulté le 5 octobre 2024.....	3
2.1	Processus de recrutement de Moov.AI, site consulté le 13 février 2025.	13
2.2	Les 4 générations de modèles de langage, illustration de «A Survey of Large Language Models» [79]	23
2.3	Illustration d'un modèle de langage probabiliste.	23
2.4	Impact des dépendances à long terme dans les modèles de traduction.	26
2.5	Mécanisme d'attention Bahdanau et al, ICLR 2015.....	27
2.6	Résultats comparatifs avec ou sans attention, Bahdanau et al, ICLR 2015.	28
2.7	Structure Seq2Seq à base de Transformer, illustration de Jay Alammam.....	29
2.8	Détail d'un encodeur et d'un décodeur, illustration de Jay Alammam.....	29
2.9	GPT-1, architecture selon la tâche désirée, extrait de l'article original [32].....	30
2.10	Exemple de Few-Shot learning, extrait de l'article original [10].	34
2.11	Gain de performances apporté par les exemples dans le prompt, extrait de l'article original [10].....	35
2.12	Exemple de CoT, extrait de l'article original [70].....	35
2.13	Architecture de DiagGPT, extrait de l'article original [11].....	36
2.14	Principaux LLM, illustration de « A Survey of Large Language Models, extrait de l'article original [79].	37
2.15	Tailles des principaux LLM réparties selon leurs dates de sorties sur le marché...	38
2.16	Architecture MM-LLM, extrait de l'article original [71].....	42
2.17	Émissions en tonnes équivalentes CO2 des LLM, extrait de 2024 AI index Report de Stanford [59].....	43

2.18	Architecture des agents IA.....	53
3.1	Recherche et extraction des descriptions de postes.....	71
3.2	Création des profils candidats et personnas.....	72
3.3	Interaction d’entrevue et audit.....	73
3.4	Structure des «prompts» pour les agents IA.....	73
3.5	Exemple de conversation d’entrevue générée.....	75
3.6	Schéma de validation de l’auditeur EDI.	77
4.1	Schéma de l’architecture du projet.	85
4.2	Console Opik.	91
4.3	Déroulement du flux d’expérimentation en 8 étapes.....	96
5.1	Formulaire de sondage envoyé aux participants.	106
5.2	Répartition et distributions des notes selon les échanges.....	108
5.3	Réalisme des interactions en fonction des échanges.	108
5.4	Exemple de conversation soumise aux expertes EDI.	115
6.1	Révélation des biais implicites par génération d’image : candidat "idéal" visualisé par l’IA à partir des questions du recruteur.....	126
8.1	Console « mes GPT » : https://chatgpt.com/gpts/mine	137
8.2	Configuration de l’agent de génération de postes.....	138
8.3	Suivi d’une session de travail de l’équipe d’agent avec l’outil AgentOPS	149
8.4	Détail des coulisses pour un agent avec l’outil AgentOPS	150

Liste des sigles et des abréviations

API	Application Programming Interface
ATS	Applicant Tracking System
BERT	Bidirectional Encoder Representations from Transformers
BLEU	Bilingual Evaluation Understudy
C4	Colossal Clean Crawled Corpus
CoLA	Corpus of Linguistic Acceptability
CoT	Chain Of Thought
EDI	Équité, Diversité et Inclusion
GenAI	IA générative
GIT	Logiciel de gestion de versions de code

GLUE	General Language Understanding Evaluation
Glove	Global Vectors for Word Representation
GPT	Generative Pre-trained Transformer
IA	Intelligence Artificielle
LLM	Large Language Model
LoRA	Low-Rank Adaptation
LSTM	Long Short-Term Memory
MM-LLM	Multi Modal LLM
MNLI	Multi-Genre Natural Language Inference
PeFT	Parameter-Efficient Fine-Tuning
PLM	Pre-trained Language Model
QQP	Quora Question Pairs

RAG	Retrieval Augmented Generation
ReAct	Reasoning and Acting
RH	Ressources Humaines
RNN	Recurrent Neural Network
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
Seq2Seq	Sequence to Sequence
SML	Small Language Model
SST-2	Stanford Sentiment Treebank 2
SVM	Support Vector Machine
T5	Text-To-Text Transfer Transformer
Word2Vec	Word to Vector

Remerciements

Je tiens à remercier **Madame la Professeure Esma Aïmeur** pour son encadrement méthodologique et ses conseils avisés tout au long de ce mémoire. Sa rigueur et son exigence académique m'ont permis de structurer et de mener à bien ce projet.

Je remercie également l'ensemble du corps enseignant du MILA et de l'Université de Montréal, dont les enseignements m'ont donné les bases théoriques et pratiques nécessaires pour conduire de manière autonome une réflexion mêlant analyse conceptuelle et développement technique.

Je suis reconnaissant envers les étudiants encadrés par Madame la Professeure Aïmeur, pour la qualité de leurs retours lors des présentations de mes travaux.

Je remercie également mes amis et collègues pour leur participation au sondage de validation des dialogues de recrutement, ainsi que les professionnels des ressources humaines qui m'ont accompagné dans la validation des rapports en équité, diversité et inclusion.

A ce titre, je tiens à remercier particulièrement **Émilie Villeneuve** et **Véronique Monette**, respectivement Directrice principale capital humain et Conseillère en capital humain chez Cain Lamarre¹, ainsi qu'**Émélie Randriamitatsoa**, Directrice centre d'expertise en développement des compétences chez Desjardins², pour leurs analyses et évaluations professionnelles du rapport EDI produit par la solution IA bâtie dans le cadre de ce mémoire.

Enfin, je remercie ma conjointe pour son soutien et ses encouragements constants.

¹Lien vers le site Web de Cain Lamarre

²Lien vers le site Web de Desjardins

Chapitre 1

Introduction

Projetons-nous dans un futur proche. Nous sommes en 2028, les agents intelligents (agents IA) ont remplacé l'humain dans la plupart des compagnies pour effectuer les tâches d'acquisition de talents et en particulier dans les entrevues d'embauche préliminaires.

A l'issue de cette entrevue préliminaire, la décision est prise pour :

- Arrêter le processus de recrutement : l'agent IA a déterminé que la personne ne correspond pas aux exigences du poste.
- Poursuivre le processus de recrutement : l'agent IA a évalué que la personne semble convenir mais une seconde entrevue est nécessaire pour valider les aspects plus techniques ou relationnels.
- Terminer le processus de recrutement : l'agent IA a décidé que la personne convient parfaitement et une offre d'emploi va être faite après une ultime validation humaine.

Outre les aspects éthiques concernant la délégation du recrutement à une IA, un des potentiels enjeux concerne les biais, les stéréotypes en particulier, qui peuvent subsister dans le processus. En effet, rien n'empêcherait une compagnie d'orienter volontairement une discrimination qui pourrait se cacher derrière l'IA utilisée pour effectuer ces entrevues.

L'IA est déjà fortement implantée dans le domaine des ressources humaines (RH). En explorant quelques articles sur les sites spécialisés (voir figure 1.1), on constate que l'IA est déjà omniprésente dans le secteur du recrutement et génère des inquiétudes.

L'IA officie déjà dans les fonctions suivantes.

Pour le recruteur :

- Génération de description de postes.
- Analyse, classification et validation de CV.



Fig. 1.1. Articles: Forbes (03/2023, 01/2024), Radio-Canada (01/2023) sur l'IA en RH

- Préparation des entrevues : génération des questions à poser.
- Assistant IA pour supporter le recruteur durant l'entrevue.

Pour le candidat:

- Génération de CV personnalisé et ciblé sur le poste désiré.
- Génération de lettre de motivation pour le poste convoité.
- Préparation à l'entrevue : génération de questions types et réponses pertinentes.
- Assistant IA pour supporter le candidat durant l'entrevue ou pour l'entraîner à son entrevue, voir la figure 1.2.

Est-ce une bonne ou une mauvaise pratique d'utiliser l'IA, de part et d'autre, en RH ? En tout cas, cela soulève des interrogations sur la capacité à identifier les biais, qu'ils soient introduits de manière intentionnelle ou non, dans les systèmes automatiques impliquant des IA. L'importance de ces questions éthiques est reconnue et prise très au sérieux par la communauté scientifique en IA. Comment détecter les biais dans les échanges avec un candidat ? Comment une entreprise pourrait contrôler efficacement, lors d'un audit interne ou externe, le respect de sa politique EDI (équité, diversité, inclusion) ? Autant de questions qui nous poussent à creuser ce sujet d'actualité.

Dans le cadre de ce mémoire, nous proposons de monter le scénario suivant avec des agents IA basés sur des LLM du marché :




Fig. 1.2. Exemple d’agent IA (compagnie FinalRoundAI) pour assister les candidats lors des entretiens, site consulté le 5 octobre 2024

Une entreprise ouvre un poste à l’externe, publie une offre la plus neutre possible pour se prémunir des discriminations, notamment de genre et de race. Un des candidats retenus est convié à une entrevue de recrutement. Le recruteur (humain ou IA) pose une question, le candidat (humain) apporte une réponse et le processus continue jusqu’à ce que le recruteur mette fin à l’entrevue. Un troisième joueur impartial (implémenté par une équipe d’agents IA coopérant pour fournir une évaluation fiable) observe l’échange (après l’entrevue en lisant la transcription des échanges ou en temps réel durant l’entrevue) et doit décider si l’échange est ou était sans aucune discrimination liée à un quelconque stéréotype.

L’intérêt de réaliser ce mémoire est multiple et motivant. S’immerger dans ce travail, c’est contribuer directement à une problématique actuelle et importante : l’éthique dans l’utilisation de l’IA dans le domaine du recrutement. À mesure que de plus en plus d’entreprises délèguent leurs entretiens de sélection de candidats à des agents IA, il deviendra capital d’explorer les risques liés aux biais et aux discriminations systémiques que ces agents pourraient produire, voire amplifier.

Avoir l’opportunité de mener cette recherche, c’est se placer à l’avant-garde de la réflexion sur les pratiques responsables en IA, un sujet qui influencera certainement l’avenir

du monde du travail. En abordant ces enjeux, ce mémoire offre la perspective d’aider les entreprises à développer des processus de recrutement plus équitables et transparents, tout en veillant à ce que les IA de demain respectent pleinement les principes d’équité, de diversité et d’inclusion.

C’est une chance de contribuer à l’élaboration de standards éthiques concrets en proposant des pistes de solutions qui auront un impact réel sur le monde professionnel de demain.

Nous allons décrire dans les sections suivantes les objectifs et les résultats clés de ce mémoire ainsi que sa structure afin de guider le lecteur. Nous terminerons par une note sur l’utilisation et la place de l’IA générative dans ce travail de recherche.

1.1. Objectifs et résultats clés recherchés

Afin de palier l’absence ou la difficulté d’avoir de réels échanges entre un recruteur et un candidat, le premier objectif à atteindre est de générer un jeu de données de conversations permettant de faire des expérimentations sur la détection des biais. Ce jeu de données et le moyen d’en générer de nouveaux seront mis à la disposition de la communauté scientifique.

Les résultats clés de ce premier objectif sont :

- Générer des conversations contrôlées : pouvoir piloter la génération de conversations avec ou sans injection de biais.
- Obtenir de la variété dans les conversations : pouvoir piloter la génération d’un poste à combler, du profil des candidats, du profil des recruteurs et finalement générer un échange entre un recruteur et un candidat.
- Créer des échanges pertinents : il existe un lien clair et direct entre la question posée et la réponse du candidat.
- Créer des échanges réalistes : ils sont naturels et plausibles dans un contexte de recrutement.
- Formater les conversations afin qu’elles soient lisibles par un humain ou une machine en identifiant clairement le texte de chaque locuteur tout en respectant la chronologie de l’échange.

Le second objectif est de détecter automatiquement la manifestation du stéréotype de genre chez les recruteurs lors des entrevues. Bien que nous nous limitons actuellement à ce

type de stéréotype, le système développé doit pouvoir facilement s'adapter à d'autres types de préjugés. Le choix de ce stéréotype est motivé par son actualité persistante malgré les avancées sociétales.

Les résultats clés de ce second objectif sont :

- Évaluer la détection de ce biais dans une entrevue en donnant un score selon le barème suivant :
 - 0 : biais inexistant sans aucun doute.
 - 1-20 : biais très peu probable.
 - 21-40 : biais peu probable.
 - 41-60 : biais modérément probable.
 - 61-80 : biais probable.
 - 81-99 : biais très probable.
 - 100 : biais confirmé sans aucun doute.
- Expliquer le score en fournissant les éléments factuels issus de la conversation.
- Générer un rapport d'analyse dans un format lisible par un humain.

Nous allons maintenant décrire la structure du mémoire afin de mieux naviguer parmi les différents chapitres.

1.2. Structure du mémoire

Le mémoire est organisé autour de la construction d'un simulateur d'expériences de recrutement qui produit à la demande de l'expérimentateur des entrevues prêtes à être soumises à la détection de biais. La figure 4.1 représente les grandes composantes logicielles mises en œuvre. Tel un metteur en scène, l'orchestrateur lance la mise en place du décor et la définition des personnages via des IA spécialisées : le poste est le sujet de la pièce car c'est l'objet du recrutement, les persona, qui sont le recruteur et les candidats sont les acteurs de cette mise en scène. Une fois le contexte créé, l'orchestrateur déclenche une première fois la scène principale, l'entrevue avec les conditions favorables à l'apparition du biais, entre un acteur virtuel incarnant le recruteur et un autre acteur virtuel personnifiant un des deux candidats. Ensuite il lance une seconde prise mais cette fois-ci sans les conditions favorables à l'apparition du biais. Ce sont ces 2 prises qui seront soumises à l'équipe virtuelle d'experts en détection de biais et qui conduira à la production du rapport d'audit.

Le mémoire comprend 8 chapitres incluant le présent premier chapitre d'introduction au sujet.

Le chapitre 2 est consacré aux concepts manipulés dans ce mémoire, répartis en 2 groupes, en premier lieu, les concepts liés aux ressources humaines et les stéréotypes, en second lieu, les concepts relatifs aux modèles et aux architectures des solutions d'IA utilisées pour la construction du simulateur d'expériences de recrutement et de l'équipe virtuelle d'experts en détection de biais. Un accent particulier a été mis sur les LLM au sous-chapitre 2.4 en vulgarisant le fonctionnement de ces modèles qui sont au cœur des agents IA.

Le chapitre 3, approche et méthodologie, explique comment simuler les expériences de recrutement et documente les stratégies pour valider notre système IA de détection de biais. Ce chapitre est requis pour bien saisir le travail d'expérimentation accompli dans ce mémoire.

Le chapitre 4, architecture et modèles mis en œuvre, détaille toutes les composantes logicielles ainsi que les paramètres utilisés. Ce chapitre est utile à ceux qui souhaitent explorer les coulisses techniques du projet mais n'est pas requis pour comprendre l'objectif et les résultats obtenus.

Le chapitre 5, expériences et résultats, est la quintessence du mémoire, présente les résultats des expérimentations et tire les premières conclusions.

Le chapitre 6 conclue et donne les orientations à suivre pour pousser plus loin le sujet abordé dans ce mémoire.

Le chapitre 7 regroupe la bibliographie et les références utiles.

Le chapitre 8 donne les détails d'implémentation des différentes composantes techniques.

Pour aller à l'essentiel, il est conseillé de lire les chapitres 1, 3, 5 et 6.

Nous terminerons ce chapitre en expliquant comment l'usage d'outils d'intelligence artificielle générative (GenAI) a accompagné notre démarche de recherche, tant pour structurer notre réflexion que pour améliorer la qualité de nos productions académiques.

1.3. Utilisation de l'IA générative dans ce mémoire

Dans le cadre de ce mémoire de maîtrise, qui porte sur l'IA responsable dans les processus de recrutement RH, l'utilisation d'outils dans ce travail de recherche est une démarche naturelle et cohérente. Notre objectif est d'explorer comment l'IA peut être utilisée de manière éthique et efficace dans le recrutement, et l'utilisation de la GenAI me permet d'approfondir cette réflexion tout en améliorant la qualité de nos productions académiques.

Tout d'abord, nous utilisons NotebookLM [60] de Google pour synthétiser plusieurs articles sur un même sujet (par exemple les modèles de raisonnement ou encore les agents IA autonome). Cet outil nous permet de poser des questions précises, d'obtenir une contre-validation de nos idées et de vérifier notre compréhension des concepts abordés. Cette démarche nous aide à structurer nos recherches et à nous assurer que nous ne négligeons aucun aspect important de la thématique étudiée.

Ensuite, ChatGPT [49] et le chat de Mistral [4] jouent un rôle crucial dans l'amélioration de la clarté et de la qualité de nos textes en français. Ces outils nous permettent de reformuler nos idées de manière plus fluide et précise, tout en respectant les exigences académiques. Ils ne remplacent pas notre réflexion, mais l'accompagnent en offrant un point de vue extérieur et en nous suggérant des améliorations stylistiques et grammaticales. Nous utilisons également un outil pour générer nos squelettes de schémas et diagrammes que nous pouvons modifier par la suite : Presentation & Diagram Generator by <ShowMe> accessible depuis l'interface de ChatGPT.

Pour la partie technique de ce mémoire, Mistral [3] nous assiste dans la programmation de notre expérimentateur. Cet outil nous permet de coder plus efficacement et de résoudre des problèmes techniques, tout en nous assurant que notre travail reste rigoureux et conforme aux standards de développement.

Enfin, nous effectuons des tests de prompts pour expérimenter et affiner les interactions avec l'IA dans le cadre de ce mémoire. En effet, les agents IA, que nous avons développés, utilisent des prompts que nous testons unitairement dans une interface conversationnelle au préalable. Ces tests nous permettent d'explorer différentes approches. Nous pouvons comparer la génération produite par nos prompts sur différentes plateformes (ChatGPT, Mistral, Claude [7] et DeepSeek [18]).

En définitive, l'utilisation de la GenAI dans nos travaux de recherche ne vise pas à remplacer notre réflexion, mais à l'accompagner en apportant un point de vue différent, en structurant nos idées et en améliorant la qualité de nos productions. Travailler avec ces outils est une démarche cohérente avec notre sujet de recherche.

Nous ouvrons à présent un nouveau chapitre consacré aux fondements théoriques et technologiques de notre travail, en posant les bases conceptuelles nécessaires à l'analyse des biais dans le recrutement assisté par intelligence artificielle. Cette exploration structurée en cinq volets nous permettra de situer notre démarche à l'intersection des sciences humaines, de l'éthique et des technologies d'IA.

Chapitre 2

Concepts et travaux associés

Ce chapitre établit les fondements théoriques et technologiques nécessaires à la compréhension des enjeux liés à la détection de biais dans les processus de recrutement assistés par intelligence artificielle. Il explore les concepts clés qui sous-tendent notre approche méthodologique en abordant cinq domaines interconnectés.

Nous commençons par examiner les processus et techniques traditionnels de recrutement pour comprendre les pratiques actuelles et identifier les points d'intervention potentiels de l'IA. Cette analyse révèle la complexité et la diversité des approches utilisées par les organisations, ainsi que les différents acteurs impliqués dans les décisions de recrutement.

L'équité dans le domaine des ressources humaines constitue le cœur conceptuel de notre travail. Nous explorons les huit types de biais inconscients identifiés dans la littérature, leurs manifestations concrètes et les stratégies existantes pour les atténuer. Cette section établit le cadre théorique de l'équité, diversité et inclusion (EDI) qui guide notre démarche.

L'analyse de l'équité de genre dans le monde du travail apporte une perspective spécifique sur les inégalités systémiques qui persistent malgré les avancées légales et sociales. Nous examinons les mécanismes d'exclusion et les stéréotypes qui influencent les trajectoires professionnelles, particulièrement dans les domaines scientifiques et technologiques.

La section consacrée aux modèles de langage de grande taille (LLM) retrace l'évolution technologique depuis les modèles probabilistes jusqu'aux architectures Transformer actuelles. Nous détaillons les propriétés distinctives des LLM, leurs capacités émergentes et leurs limitations, notamment les problèmes d'hallucination et de biais.

Enfin, nous explorons les agents IA comme évolution naturelle des LLM vers des systèmes autonomes capables d'actions complexes. Cette section couvre l'architecture des agents, les systèmes multi-agents et leurs applications pratiques, tout en abordant les questions éthiques liées à l'autonomie croissante de ces systèmes.

2.1. Le processus et les techniques de recrutement

Le processus de recrutement d'employés en entreprise est une démarche structurée visant à attirer, sélectionner et intégrer les meilleurs talents pour répondre aux besoins organisationnels. Il commence généralement par l'identification des besoins en personnel, suivie de la rédaction et de la diffusion d'offres d'emploi sur divers canaux, tels que les sites web d'emploi, les réseaux sociaux et les agences de recrutement. Les candidatures reçues sont ensuite triées et évaluées, souvent à l'aide de logiciels de suivi des candidatures (ATS) pour optimiser l'efficacité.

Traditionnellement, les techniques de recrutement incluent :

- Des entrevues : entretiens téléphoniques ou en face-à-face.
- Des tests de compétences.
- Des évaluations psychométriques.
- Des vérifications des antécédents.

Dans le processus de recrutement, l'entrevue peut être effectuée par plusieurs personnes ou combinaisons de personnes, en fonction de la structure de l'entreprise et du poste à pourvoir.

Voici les principaux acteurs qui peuvent mener les entretiens :

- **Recruteurs ou chargés de recrutement** : ils sont souvent les premiers à entrer en contact avec les candidats. Leur rôle est de faire un premier tri des candidatures et de réaliser des entretiens initiaux pour évaluer les compétences et l'adéquation des candidats avec le poste.
- **Responsables RH (Ressources Humaines)** : ils peuvent participer aux entretiens pour évaluer l'adéquation culturelle du candidat avec l'entreprise et s'assurer que les pratiques de recrutement respectent les politiques internes et les réglementations.

- **Managers ou responsables hiérarchiques** : le futur supérieur hiérarchique du candidat participe souvent aux entretiens pour évaluer les compétences techniques et la capacité du candidat à s'intégrer dans l'équipe. Ils peuvent également discuter des attentes spécifiques liées au poste.
- **Équipe ou collègues** : dans certaines entreprises, des membres de l'équipe ou des collègues potentiels peuvent être impliqués dans le processus d'entretien pour évaluer la compatibilité avec l'équipe et la culture d'entreprise.
- **Experts techniques ou métiers** : pour des postes nécessitant des compétences techniques spécifiques, des experts peuvent être sollicités pour évaluer les compétences techniques des candidats.
- **Dirigeants ou cadres supérieurs** : pour des postes à responsabilités ou stratégiques, les dirigeants peuvent participer aux entretiens pour évaluer la vision et les capacités de leadership des candidats.

Le processus d'entretien peut inclure plusieurs tours, chacun impliquant différents intervenants pour obtenir une évaluation complète du candidat.

Les entreprises tendent également à recourir de plus en plus à des techniques innovantes comme le recrutement par l'intelligence artificielle mais aussi via des journées portes ouvertes ou encore des hackathons pour identifier des talents potentiels. Une fois le candidat idéal sélectionné, le processus se conclut par une offre d'emploi, la négociation des conditions et l'intégration du nouvel employé, qui inclut souvent une période de formation et d'accompagnement pour faciliter son adaptation à la culture et aux exigences de l'entreprise.

Chaque entreprise possède une approche unique pour son processus de recrutement. Un exemple intéressant est celui proposé par la société de conseil en IA Moov.AI. La figure 2.1 illustre leur processus tel qu'il est présenté sur leur site.

Le processus de recrutement de Moov.AI se distingue par ces aspects intéressants :

- Étape 1 : échange initial
 - Personnalisation et transparence : Moov.AI met en avant un échange initial avec un spécialiste en acquisition de talent, qui aborde non seulement les aspects techniques mais aussi culturels du rôle. Cela permet de valider dès le départ l'intérêt mutuel et l'adéquation culturelle, ce qui est souvent moins approfondi dans les processus standards.

- Clarté sur les attentes : en discutant des attentes salariales et de la disponibilité dès le premier échange, Moov.AI évite les malentendus ultérieurs et assure que les candidats sont bien alignés avec les conditions offertes par l'entreprise.
- Étape 2 : Test technique
 - Flexibilité et confort : le test technique est réalisé à domicile et n'est pas minuté, offrant ainsi une flexibilité qui peut réduire le stress des candidats et leur permettre de montrer leurs compétences dans un environnement confortable.
 - Évaluation approfondie : le test est ensuite analysé par un expert du domaine, garantissant une évaluation rigoureuse et pertinente des compétences techniques.
- Étape 3 : Entrevue technique
 - Validation par des experts : l'entrevue technique est menée par un expert du domaine, ce qui permet une évaluation précise des compétences et du savoir-faire spécifiques au poste. Cela contraste avec les processus où les entretiens peuvent être menés par des recruteurs ayant une compréhension plus générale des exigences techniques.
- Étape 4 : Entrevue finale
 - Intégration et collaboration : la présentation du test technique devant de futurs collègues permet au candidat de se familiariser avec l'équipe et de démontrer ses compétences dans un contexte interactif. Cela favorise une meilleure intégration et permet aux deux parties de s'assurer de la compatibilité au sein de l'équipe.
 - Transparence et engagement : en impliquant les futurs collègues dans le processus final, Moov.AI montre une transparence qui peut renforcer l'engagement du candidat dès le départ, en lui donnant un aperçu concret de son futur environnement de travail.

En somme, le processus de Moov.AI se distingue par une approche plus humaine et flexible, tout en assurant une évaluation rigoureuse des compétences techniques et une intégration harmonieuse au sein de l'équipe.

Après avoir présenté les pratiques et techniques actuelles de recrutement, nous nous penchons désormais sur la notion d'équité dans le domaine des ressources humaines, qui constitue le socle conceptuel de notre réflexion sur l'IA responsable.

2.2. L'équité dans le domaine des ressources humaines

L'article "Eight Types of Unconscious Bias & How They Affect Recruiting" [46] examine comment les biais inconscients affectent le recrutement et la gestion du rendement,




Fig. 2.1. Processus de recrutement de Moov.AI, site consulté le 13 février 2025.

soulignant que ces biais peuvent nuire à l'équité, la diversité et l'inclusion (EDI) en milieu de travail.

Voici les huit types de biais inconscients identifiés dans l'article:

- **Biais d'affinité:** C'est la tendance à favoriser les personnes qui nous ressemblent. Par exemple, un recruteur pourrait préférer un candidat ayant fréquenté la même université.
- **Biais de conformité:** Il s'agit de la tendance à se comporter comme les autres plutôt que d'utiliser son propre jugement. Lors d'un entretien de groupe, un candidat peut retenir son opinion si elle diffère de celles des autres.
- **Biais de confirmation:** Il s'agit de la tendance à rechercher et à interpréter les informations qui confirment nos opinions préconçues. On cherchera inconsciemment des preuves qui soutiennent nos jugements sur un candidat, ce qui peut mener à rejeter un excellent candidat.

- **Biais de beauté:** C'est l'évaluation des gens, surtout des femmes, basée sur leur apparence physique. Les candidats considérés comme attrayants peuvent être favorisés, non seulement pendant le recrutement, mais également pour les augmentations salariales et les promotions.
- **Effet de halo et effet de cornes:** Un trait positif (halo) ou négatif (cornes) influence notre perception globale d'une personne. L'effet de halo nous fait ignorer les aspects moins positifs d'un candidat, tandis que l'effet de cornes nous fait ignorer ses qualités.
- **Effet de contraste:** L'évaluation d'une personne par rapport à une autre, surtout si on les a vues simultanément ou successivement. Un candidat excellent peut rendre les autres moins attrayants. Ce manque d'objectivité peut fausser nos attentes.
- **Biais d'attribution:** Faire des suppositions sur les actions et les intentions des autres en se basant sur des interactions passées. Par exemple, dévaloriser les réussites d'une femme et surévaluer ses erreurs.
- **Biais de nom:** C'est la préférence pour une personne basée sur son nom. Les personnes ayant des noms perçus comme étant de type "blanc" reçoivent plus d'appels que ceux dont les noms sont perçus comme étant de type "afro-américain" ou "asiatique".

L'article mentionne d'autres types de biais, comme le biais de genre, l'âgisme, le biais de taille et le biais d'autorité. Bien qu'il soit impossible d'éliminer complètement les biais inconscients, il est possible de s'efforcer de les comprendre et d'améliorer les pratiques de recrutement et de gestion. L'auteure de l'article, Ngozi Okeh, est une experte en EDI.

Pour mieux comprendre les biais inconscients dans le contexte du recrutement, il faut également aborder la notion de stéréotype. Les stéréotypes sont à l'origine des biais. Les stéréotypes et les biais sont interdépendants, car les stéréotypes conduisent à des préjugés et à des comportements biaisés, et que les biais peuvent renforcer les stéréotypes. Pour être plus précis, un stéréotype est une croyance (ex. « les femmes sont moins douées en sciences ») et un biais est une tendance à agir ou penser d'une certaine manière (ex. « embaucher un homme plutôt qu'une femme pour un poste de développeur »).

Les stéréotypes peuvent être présentés comme des outils cognitifs qui permettent de simplifier l'information et de rendre l'environnement social plus prévisible. Ce sont des raccourcis mentaux qui aident à traiter rapidement l'information. Un stéréotype est donc une composante cognitive qui influence et active différents biais. Les biais sont une

manifestation de ces stéréotypes dans un contexte spécifique, affectent les jugements et peuvent conduire à des décisions injustes et discriminatoires.

Les **sources suivantes** permettent de mieux comprendre et de prendre le pouls sur les impacts des biais :

- **Biais pro-endogroupe**, Olivier Lépine, article
- **Effet de halo**, Camille Comeau, article
- **L'effet de Halo — Crétin de cerveau ! #1**, ScienceEtonnante, vidéo
- **Stéréotypes et préjugés**, Marina M. Doucerain, article
- **Tous racistes ? Les biais implicites — Crétin de Cerveau #7**, ScienceEtonnante, vidéo
- **First-Person Fairness in Chatbots**, OpenAI, article
- **Mitigating Gender Bias in Neural Rankers through Disentanglement Learning**, Ali Shirin et autres, article
- **Biais inconscients et recrutement**, Girier, D., Lamouri, J., et Pulido, B., article
- **Équité, diversité et inclusion | Observatoire international sur les impacts sociétaux de l'IA et du numérique (OBVIA)**, OBVIA, site web
- **Exigences et pratiques en matière d'équité, de diversité et d'inclusion (Chaires de recherche du Canada)**, Chaires de recherche du Canada, site web

Des approches, outils, techniques et dispositifs peuvent être utilisés pour combattre les stéréotypes, en particulier dans le recrutement. Voici un résumé de ceux qui sont mentionnés dans les sources mentionnées précédemment :

Approches générales pour contrer les biais et stéréotypes :

- **Prendre conscience de nos propres biais** : il est essentiel de reconnaître que tout le monde a des biais inconscients, qui peuvent influencer nos décisions de manière involontaire. Cela implique de faire une introspection régulière sur nos propres jugements et attitudes.
- **Considérer un large éventail de caractéristiques** : lors de jugements comparatifs, il faut envisager un large éventail de caractéristiques positives et négatives, autant envers son propre groupe qu'envers les autres groupes.
- **Envisager la vision et l'opinion de l'autre** : il est important de faire preuve d'empathie et de tenir compte de la perspective des autres.

- **Éviter les étiquettes sociales** : lors de la description d'une personne, il faut éviter de s'en tenir aux étiquettes sociales souvent associées à des stéréotypes (par exemple, « c'est un Chinois ») et ajouter des informations sans lien avec les stéréotypes (par exemple, « il a de l'expérience en marketing »).
- **Éviter les jugements hâtifs** : il est important de ne pas se fier à sa première impression, car celle-ci peut fortement biaiser notre jugement. Les premières impressions peuvent créer un effet de halo, où une première impression positive (ou négative) conduit à généraliser cette impression à d'autres aspects de la personne.
- **Remettre en question nos intuitions** : il faut apprendre à ne pas se fier uniquement à son intuition ou à son « feeling ».
- **Être ouvert à la rétroaction** : il est essentiel d'être prêt à recevoir des commentaires sur ses comportements et à les ajuster en conséquence.
- **Ne pas vouloir collaborer uniquement avec ceux qui nous ressemblent** : il faut faire un effort conscient pour ne pas tenir compte des préférences personnelles qui pourraient nous amener à ne pas vouloir travailler avec des personnes qui ont des points de vue différents des nôtres.
- **Reconnaître l'effet de contraste** : il est important de se rappeler que notre tendance à comparer les gens peut nous mener à évaluer une personne plus favorablement, simplement parce qu'elle vient après une personne qui nous a déçue. Il faut donc s'assurer d'évaluer les candidats objectivement en fonction des exigences du poste et non par comparaison.
- **L'inclusion** : pour assurer l'inclusion, il faut recenser et supprimer les obstacles qui nuisent à la participation et à la contribution des personnes et être ouverts aux différentes opinions.

Outils et techniques spécifiques au recrutement :

- **Utiliser un vocabulaire inclusif et épïcène** ¹ : le choix des mots dans les offres d'emploi peut avoir un impact significatif sur le profil des candidats.
- **Définir les compétences minimales nécessaires pour le poste** : les critères de sélection doivent se concentrer sur les compétences minimales requises, et non sur les caractéristiques d'un candidat idéal.
- **S'assurer que les exigences du poste ne désavantagent pas certains groupes** : il faut veiller à ce que les exigences du poste ne défavorisent pas un groupe de personnes (par exemple, disponibilité horaire, travail sous pression).

¹Mots qui s'emploient tant au féminin qu'au masculin, sans changer de forme

- **Élargir les réseaux de recrutement** : il est important de diffuser les offres d'emploi au-delà des réseaux habituels pour augmenter la diversité des candidatures.
- **Former des comités de sélection diversifiés** : former un comité de sélection avec des personnes ayant des perspectives et des parcours différents permet d'obtenir un jugement plus objectif, basé sur un partage d'opinions avec des personnes diverses.
- **Former les membres des comités de sélection sur les biais inconscients et leurs impacts sur la prise de décision.**
- **Appliquer les mêmes critères d'évaluation à tous les candidats** : utiliser des outils d'évaluation standardisés et structurés, et les appliquer de manière uniforme.
- **Évaluer les candidatures dans leur ensemble** : il est important d'éviter de juger une candidature uniquement sur une seule de ses composantes, comme les lettres de référence.
- **Utiliser des entrevues structurées** : poser les mêmes questions à tous les candidats pour évaluer objectivement leurs compétences.
- **Prendre le temps d'évaluer chaque candidat** : les études montrent que les évaluateurs trop occupés ont tendance à donner des notes plus faibles aux femmes qu'aux hommes.
- **Être attentif aux dynamiques du comité de sélection** : s'assurer que chaque membre du comité peut s'exprimer, et être attentif à la façon dont se déroulent les discussions, en portant une attention particulière aux possibles biais.
- **Utiliser des mesures d'évaluation anonymes** : dans plusieurs situations, il peut être utile d'instaurer des mesures d'évaluation anonyme des candidats.
- **Faire deux listes de candidats, notamment selon le genre** : pour s'assurer d'avoir un nombre suffisant de candidates, par exemple, il est possible de faire deux listes (une de femmes, et une d'hommes), pour ensuite choisir les meilleurs candidats dans chaque liste. Les biais de genre ont plus de chance d'influencer négativement l'évaluation des femmes si elles représentent moins de 25
- **Utiliser des outils de sensibilisation aux biais inconscients** : se référer à un outil de sensibilisation aux biais inconscients à chaque fois qu'une situation d'évaluation, de sélection ou de recrutement se présente.
- **Éviter les questions discriminatoires** : s'assurer de ne pas poser de questions qui ont trait à des motifs de discrimination.

Autres considérations :

- **L'importance de l'équité, de la diversité et de l'inclusion (EDI) :** les principes d'EDI doivent être au cœur de toutes les activités. L'équité est le traitement juste des personnes, tandis que l'égalité vise à ce que les droits, responsabilités et possibilités des personnes ne dépendent pas de leur identité. La diversité se rapporte aux différents groupes (âge, orientation sexuelle, etc.), et l'inclusion consiste à créer un environnement où toutes les personnes sont respectées et ont accès aux mêmes possibilités.
- **L'auto-identification :** Il est recommandé d'encourager les candidats à s'auto-identifier afin de connaître la composition réelle de la communauté et d'éviter les obstacles systémiques.
- **L'intersectionnalité :** il est important de reconnaître que les injustices ne sont jamais le résultat de facteurs uniques ou distincts, mais qu'elles sont le produit des différences de position sociale, des relations de pouvoir et des expériences.

En appliquant ces différentes approches et techniques, il est possible de réduire les effets néfastes des stéréotypes et de promouvoir un environnement plus équitable, diversifié et inclusif.

Afin de compléter notre cadre théorique sur l'équité en ressources humaines, nous abordons à présent la question spécifique de l'équité de genre dans le monde du travail, en mettant en lumière les mécanismes systémiques et les stéréotypes qui influencent les trajectoires professionnelles.

2.3. L'équité de genre dans le monde du travail

L'étude intitulée "Femmes au Canada : rapport statistique fondé sur le sexe" portant sur le bien-être économique des femmes au Canada [24] note que malgré les progrès qui ont été réalisés ces dernières décennies au Canada, des disparités économiques significatives subsistent toujours entre les sexes. Ce constat est malheureusement généralisé dans tous les pays développés. Un article de Pascal Galinier publié dans le journal Le Monde fait référence à ce constat [25] en examinant le documentaire de Véronique Prévault, « Les femmes riches ne courent pas les rues », diffusé sur Arte.tv.

Le film documentaire [51] explore la question de l'égalité des sexes à travers le prisme de la richesse, soulignant que l'accès à la richesse reste largement une affaire d'hommes. Malgré les progrès réalisés en matière d'égalité, les femmes continuent de gagner moins que

les hommes et sont sous-représentées dans les secteurs lucratifs.

Ce documentaire met en lumière les « mécanismes invisibles » qui limitent l'indépendance financière des femmes, comme les biais culturels et les discriminations dès le plus jeune âge. Une expérience menée à la télévision britannique est mentionnée, où un garçon est habillé avec des vêtements de filles et une fille est habillée en garçon. Des adultes sont ensuite invités à jouer avec eux. Sans surprise, les adultes se basent sur les vêtements pour choisir les jouets qui, selon eux, plairont au bébé. Cette expérience illustre comment les stéréotypes de genre influencent les perceptions et les comportements des adultes envers les enfants, même dès le plus jeune âge. Le genre serait-il un construit social ? C'est ce que défend, dans le documentaire, Nicole Prieur, psychanalyste et philosophe, spécialisée dans les relations familiales.

Le film montre que les femmes sont souvent écartées des carrières rémunératrices, malgré leurs performances scolaires. Par exemple, dans le secteur de l'intelligence artificielle, seulement une femme sur quatre hommes est présente. Les femmes évitent les carrières en ingénierie et en informatique, surtout dans les formations prestigieuses. Par exemple, à l'école centrale Supélec en France, le pourcentage de filles oscille entre 18 et 20 %, ce qui est considéré comme problématique. Il est question de biais de genre qui influencent les choix d'orientation des femmes, particulièrement en ce qui concerne les domaines scientifiques et technologiques. L'entourage familial et le corps enseignant peuvent inconsciemment ne pas imaginer que les filles soient à la hauteur pour des carrières exigeantes. Les professeurs ont tendance à attribuer les bonnes notes des filles à leur travail acharné et à leur rigueur, tandis que les garçons sont plus encouragés à faire de grandes études scientifiques. Ces mécanismes d'exclusion ont des conséquences sur le salaire global des femmes et sont reconnus au niveau international comme problématiques pour l'avenir de nos sociétés.

L'histoire de l'informatique est un exemple frappant de la façon dont les stéréotypes de genre peuvent influencer les choix de carrière. Dans les années 70, lorsque la programmation était mal payée, les femmes étaient encouragées à s'orienter vers ce domaine. Puis, lorsque l'informatique a pris de la valeur, on a commencé à dire que c'était un domaine pour les hommes, basé sur la logique et les mathématiques. Cet exemple, mentionné dans le film par Isabelle Collet, est documenté dans l'article "Femmes et métiers de l'informatique : un monde pour elles aussi" de C. Morley et I. Collet [43].

Enfin, ce documentaire utilise des entretiens et des données pour illustrer ces disparités, comme le fait que les femmes gagnent en moyenne 15,8 % de moins que les hommes à

l'échelle mondiale. En France, 76 % des retraités vivant sous le seuil de pauvreté sont des femmes. Le documentaire se termine en questionnant si le discours sur l'égalité des sexes est une réalité ou une simple croyance, soulignant le long chemin encore à parcourir pour atteindre une véritable parité économique.

Les préjugés et inégalités peuvent naturellement se manifester dans le processus de recrutement, influençant les questions posées aux candidates. De ce fait, on contribue dès le début à enfermer les femmes dans des tâches genrées moins rémunératrices et à conserver l'écart de salaire avec les hommes. Voici quelques questions hypothétiques (non verbalisées mais pensées) qu'un recruteur biaisé par des préjugés sur les femmes pourrait avoir lors d'une entrevue de recrutement :

- "Comment comptez-vous concilier vos responsabilités familiales avec les exigences de ce poste ?" : cette question suppose que les femmes ont plus de responsabilités familiales que les hommes et peuvent avoir du mal à équilibrer travail et famille.
- "Êtes-vous prête à voyager fréquemment, même si cela implique de vous éloigner de votre famille ?" : cette question peut viser à dissuader les femmes qui pourraient hésiter à voyager en raison de leurs responsabilités familiales.
- "Comment réagiriez-vous dans un environnement de travail dominé par les hommes ?" : cette question suppose que les femmes pourraient avoir des difficultés à s'intégrer dans un milieu majoritairement masculin.
- "Pensez-vous avoir la force physique nécessaire pour ce poste ?" : cette question est basée sur le stéréotype selon lequel les femmes sont systématiquement physiquement moins fortes que les hommes, ce qui peut être non pertinent pour de nombreux emplois.
- "Êtes-vous émotive et comment cela pourrait-il affecter votre capacité à prendre des décisions rationnelles ?" : cette question perpétue le stéréotype selon lequel les femmes sont plus émotives et moins aptes à prendre des décisions objectives.
- "Comment vous voyez-vous évoluer dans ce poste à long terme, compte tenu de vos projets personnels ?" : cette question sous-entend que les projets personnels des femmes (mariage, enfants) pourraient nuire à leur engagement professionnel.
- "Êtes-vous à l'aise de gérer une équipe principalement masculine ?" : cette question suppose que les femmes pourraient avoir des difficultés à exercer leur leadership auprès des hommes.
- "Comment comptez-vous gérer le stress et la pression dans un environnement de travail exigeant ?" : cette question peut viser à tester la capacité des femmes à faire

face à des situations stressantes, en supposant qu'elles sont plus vulnérables au stress que les hommes.

- "Pensez-vous que les femmes sont aussi compétitives que les hommes dans ce domaine ?" : cette question remet en question la compétitivité des femmes, en se basant sur un stéréotype.
- "Comment votre conjoint perçoit-il votre ambition de carrière et est-il prêt à vous soutenir dans vos choix professionnels ?" : cette question implique que la carrière des femmes dépend du soutien de leur conjoint, ce qui n'est généralement pas demandé aux hommes.

Les modèles de langage de grande taille (LLM) occupent une place de plus en plus importante dans les processus de recrutement, qu'il s'agisse de l'analyse automatisée de CV, du filtrage des candidatures ou de l'assistance aux recruteurs. Dans la section suivante, nous examinerons l'évolution de ces modèles, leurs capacités et leurs limites, afin de mieux comprendre les opportunités et les risques qu'ils représentent en matière d'équité et de biais algorithmiques.

2.4. Les LLM

Les «Larges Language Models» (LLM) font les manchettes des journaux grand public ! Rob Toews, «The Next Generation Of Large Language Models», Forbes (2023) [61] dresse une synthèse du domaine en recueillant des propos de spécialistes et des CEO de ce secteur, étayant des chiffres, des noms de modèles et des concepts de l'IA générative en seulement quelques pages. Il commence son article par « Au cas où vous ne le sauriez pas, l'intelligence artificielle est la grande nouveauté du moment ». En fait, l'IA, qui est loin d'être nouvelle, a été rendu ultrapopulaire avec l'arrivée de ChatGPT fin 2022. Bien que le terme LLM soit également devenu populaire, il a été précédé par l'outil d'OpenAI. Rob Toews, comme tant d'autres, nous parle de LLM comme on nous parlait jadis de l'arrivée de la télévision dans les foyers. Il ne se passe pas un jour sans que l'on voie passer dans les journaux Web spécialisés, une nouvelle au sujet des LLM. Il ne se passe pas une journée au bureau où l'on ne nous sort pas la rituelle blague : «si tu ne sais pas faire cette tâche, demande à ChatGPT !». Nous assistons à une mini-révolution où tout un chacun est confronté dans ses activités personnelles comme professionnelles à l'utilisation d'un des nombreux LLM du marché. La fantastique fourmilière de modèles LLM disponibles est recensée dans l'article de S. Gao, «On the Origin of LLMs: An Evolutionary Tree and Graph for 15,821 Large Language Models» [26]. On n'y dénombre pas moins de 16000 LLM !

Les LLM sont au cœur de l'IA moderne et nous amènent à nous poser des questions sur nous-même face à cette déferlante, la place de l'IA dans notre société, les impacts sur nos emplois, sur le climat, sur les fake-news, et la part de créativité qu'il va nous rester, à nous humain, si les LLM, et d'une manière générale les IA générative, prennent aussi ce créneau. Tout dernièrement, Radio France titrait un article «Au Japon, la lauréate d'un prix littéraire reconnaît que ChatGPT a écrit 5% de son roman» [64]. Que devons-nous en penser ? Face aux défis climatiques, à l'heure où la sobriété énergétique est sur toutes les lèvres, que penser de ces LLM qui consomment tant d'énergie à apprendre ce que collectivement nous savons déjà ?

Pour se forger une opinion, il faut d'abord comprendre ce que sont les LLM, d'où ils viennent et comment devons-nous les faire évoluer. Après un bref retour sur l'histoire du traitement du langage jusqu'à l'émergence des LLM, nous allons, dans ce chapitre, passer en revue les modèles de langages et les briques fondamentales des LLM puis donner quelques applications concrètes de ceux-ci. Ensuite nous aborderons leurs limites et les impacts sur notre société. Nous finirons par une discussion sur le potentiel avenir de ces modèles.

2.4.1. De la genèse à état de l'art

Le traitement du langage naturel (NLP, Natural Language Processing) est un domaine du traitement automatique des données permettant l'acquisition, l'analyse et la génération du langage naturel. Les applications sont variées et concernent entre autres, la traduction automatique, la compréhension et la réponse aux questions, les systèmes de dialogue homme-machine, l'analyse des sentiments et la classification de textes. Ce champ de recherche existe depuis les années 1950 et s'est développé avec les modèles de langage probabilistes durant les années 1990 pour aboutir aux derniers développements récents des LLM tels que décrit dans l'article de Cem Dilmegani, The Future of Large Language Models (2024) [20]. Le point de bascule a été l'invention par Google du modèle « Transformer » en 2017 qui a révolutionné le NLP et a été le point de départ pour l'émergence des LLM moins de 2 ans plus tard en 2019 avec le modèle T5. La figure 2.2, extraite de «A survey of Large Language models» (2023) [79], illustre les 4 grandes générations de modèles de langage ayant abouti en 2024 aux prémisses des Large Action Models (LAMs), un nouveau modèle dérivé des LLM et présenté en janvier 2024 au salon CES par la compagnie Rabbit.

2.4.2. Les modèles de langage avant les « Transformers »

Les modèles de base et précurseurs des modèles à base de « Transformer » sont les modèles de langage probabilistes. De tels modèles consistent essentiellement à prédire un




Fig. 2.2. Les 4 générations de modèles de langage, illustration de «A Survey of Large Language Models» [79]




Fig. 2.3. Illustration d'un modèle de langage probabiliste.

mot à partir des mots précédents. La figure 2.3 illustre ce type de modèle où le mot cible sera « choisi » à partir d'une distribution de probabilité sur le corpus d'apprentissage. Le modèle calcule les probabilités du mot cible (probabilité conditionnelle au contexte) en fonction de ce qu'il aura appris sur un jeu de données d'apprentissage contenant des millions

de phrases dont l'ensemble des mots constitue le corpus d'apprentissage. Malgré cette apparente simplicité, plusieurs pré-traitements sont nécessaires avant de pouvoir alimenter le modèle de langage. En effet, selon la langue, la représentation de ses composants significatifs varie grandement. L'étape de nettoyage permet de filtrer ce qui est important pour la tâche NLP que nous souhaitons réaliser (par exemple nous souhaiterions uniquement conserver les mots les plus significatifs). Nous pouvons trouver une étape de désuffixation pour obtenir la racine des mots puis une étape pour retirer les mots vides ou mots qui n'ont pas de signification importante (par exemple les mots qui ne sont porteur d'aucune information utile pour la tâche NLP considérée). Plus la tâche NLP est de haut niveau (traduction, synthèse de documents, réponses aux questions et extraction d'informations), plus le modèle de langage devra tenir compte de la polysémie des mots, des faux amis, de la syntaxe des phrases, de la grammaire et au final de la sémantique (le sens des mots dans le contexte).

Les premiers modèles de langage probabilistes s'appuient sur l'hypothèse de Markov qui, appliquée au NLP, indique que la probabilité d'un mot ne dépend que des $N-1$ mots précédents. Selon la profondeur N , on parle de modèles de langage N -gramme. Le calcul des probabilités pour ces modèles est très simple car il suffit de constituer une table des statistiques de tous les mots du vocabulaire. Le principal inconvénient de ces modèles est la grandeur de la table de statistiques qui doit prendre en compte toutes les N combinaisons de mots. Une telle table sera principalement remplie de 0 (modèle « sparse »).

La qualité d'un modèle de langage s'évalue, soit par une évaluation extrinsèque (pratique, c'est à dire comment le modèle se comporte sur des cas réels), soit par une évaluation intrinsèque (théorique) comme la perplexité qui mesure à quel point le modèle « hésite » entre plusieurs mots. Par exemple, une perplexité de 8 sur un ensemble de test signifie qu'en moyenne le modèle hésite entre 8 mots lorsqu'il fait sa prédiction du prochain mot. Plus la perplexité est basse, plus la performance du modèle est bonne. Il existe d'autres métriques de performance plus spécifiques telle que le score BLEU (Bilingual Evaluation Understudy) qui est principalement utilisé pour évaluer la qualité des textes produits par des systèmes de traduction automatique. La métrique ROUGE (Recall Oriented Understudy for Gisting Evaluation) est également largement utilisée pour évaluer extrinsèquement la qualité d'un résumé ou d'une traduction de textes en comparant la sortie produite avec des ensembles de références. On trouve également le score GLUE (General Language Understanding Evaluation) qui représente un score moyen obtenu sur 11 tests de compréhension du langage (similarité sémantique, analyse de sentiment, connexion logique, ...).

Pour contrer le fléau de la dimension (la grandeur de la table de statistiques pour les modèles de langage N-gramme), de nouvelles façons de représenter les mots sont apparues : le plongement de mots ou « word embeddings ». Ils permettent de modéliser les mots dans un espace de représentation plus faible où chaque mot a une représentation vectorielle et où 2 mots similaires sont proches dans cet espace : les deux principaux algorithmes utilisés pour le plongement de mots sont « Glove » et « Word2Vec ». Une fois le plongement de mots réalisé, on peut utiliser un modèle adapté à la tâche NLP à effectuer. Ce peut-être un modèle simple tel que la régression logistique, les machines à support de vecteurs (SVM), ou encore le modèle de Bayes Naïf pour des tâches comme la classification ou l’analyse de sentiments.

Dans le cas de la traduction automatique, les modèles de langage neuronaux se sont rapidement imposés : les modèles de représentation de séquences (les phrases sont des séquences de mots) tels que les réseaux neuronaux récurrents (RNN) ont été largement utilisés. Nous renvoyons le lecteur vers le chapitre 12.4 de l’ouvrage « **L’apprentissage profond** » (Ian Goodfellow, Yoshua Bengio et Aaron Courville) pour les explications détaillées des techniques et des modèles utilisés pour le NLP jusqu’aux années 2015.

2.4.3. Le mécanisme d’attention et les modèles de « Transformer »

Fin 2015, l’état de l’art pour le traitement du langage naturel était incarné par les RNN (Recurent Neural Network) et les LSTM (Long Short Term Memory). Les RNN souffraient de leurs incapacités structurelles à gérer de grandes séquences de mots, nécessaires pour prendre en compte le contexte dans la prédiction du prochain mot, et furent petit à petit remplacés par les LSTM pour exécuter des tâches complexes de NLP telles que la traduction de textes. Cependant, la grande faiblesse des LSTM, dont le fonctionnement est intrinsèquement séquentiel, résidait dans leurs incapacités à effectuer, au sein des exemples d’apprentissage, des traitements en parallèle. D’autre part, la dépendance à long terme, qui est inhérente pour la traduction où un groupe de mots peut exercer une influence notable sur la prédiction d’un mot situé plus loin dans la phrase, obligeait les modèles à prendre en compte de longues séquences dans la phase d’apprentissage. Cela occasionnait un impact considérable sur l’accumulation en un seul point de la chaîne de traitement pour “fabriquer” le contexte global à prendre en compte pour la prédiction des prochains mots. La figure 2.4 illustre cet impact où la prédiction du mot Z est, par exemple, exclusivement dépendante du mot A. La concentration du contexte, qui synthétise en quelque sorte les mots A, B et C mais sans leur attribuer une importance particulière à l’entrée du décodeur, dilue l’information contextuelle pour la prédiction du mot Z.




Fig. 2.4. Impact des dépendances à long terme dans les modèles de traduction.

Des recherches pour résoudre cette problématique donnèrent naissance au concept d'attention formalisé par Bahdanau et al [8]. L'infographie 2.5, tirée de l'article « Neural Machine Translation By Jointly Learning To Align And Translate », Bahdanau et al, ICLR 2015, explicite le fonctionnement de l'attention dans le cas d'une architecture «Sequence to Sequence» (Seq2Seq). Les mots d'entrée $X_1, \dots, X_T$ représentés par les états cachés du RNN ($h_1, \dots, h_T$) sont linéairement combinés avec les facteurs $\alpha_{(t,1)}, \dots, \alpha_{(t,T)}$ (ces facteurs sont des paramètres du modèle et sont appris) pour produire le contexte adéquat pour le mot de sortie Y_t . La problématique de dilution des dépendances à long terme dans le contexte est résolue de cette façon. Le résultat du test obtenu par Bahdanau et al fût percutant. Leur test mené sur une traduction de texte de l'anglais vers le français, après un apprentissage sur une base contenant environ 350 millions de mots, est illustré par la figure 2.6. La comparaison a été réalisée sur des modèles RNN sans attention (RNNenc) et avec attention (RNNsearch) entraînés respectivement sur des séquences maximales de 30 et de 50 mots de longueur. Les modèles ont été évalués sur une base de tests de 3000 phrases à traduire. Le graphique démontre clairement que leur modèle RNNsearch-50 avec attention a des performances meilleures que son équivalent RNNenc sans attention et d'autre part que la performance ne chute pas lorsque la longueur de la séquence augmente. La performance est évaluée avec la métrique BLEU spécifique pour les tâches de traduction.

La problématique de la dépendance à long terme étant résolue par le mécanisme d'attention, il restait celle du traitement en parallèle qui restait impossible avec les modèles de la famille des RNN. L'ère des « Transformers » commence à partir de cette période et cela a permis la mise en place des bases architecturales des LLM. Un « Transformer » Seq2Seq est




Fig. 2.5. Mécanisme d'attention Bahdanau et al, ICLR 2015.

composé d'une pile d'encodeurs et de décodeurs connectés entre eux. La figure 2.7 illustre les deux composantes principales d'un tel modèle Seq2Seq qui est impliqué dans une tâche de traduction. Le nombre d'encodeurs et de décodeurs sont toujours identiques et seul le dernier encodeur est connecté à tous les décodeurs pour la transmission de l'information contextuelle. La figure 2.8 détaille les sous composants internes de chaque partie. Les 2 parties contiennent chacune un module de « self-attention » et une couche « feed-forward » classique. Le décodeur possède en plus un module « Encoder-Decoder Attention » dont la fonction est identique à l'attention vue précédemment.

Le module « self-attention » examine les indices permettant de coder chaque mot en fonction des autres. Il permet en quelque sorte de suppléer l'état caché mis à jour au fur et à mesure de la lecture en série des mots et que possèdent tous les modèles de type RNN. De plus, on encode la position du mot dans la séquence avant de le présenter à l'auto-attention. Ainsi on règle définitivement la problématique séquentielle inhérente aux modèles récurrents




Fig. 2.6. Résultats comparatifs avec ou sans attention, Bahdanau et al, ICLR 2015.

(RNN et autres) et de ce fait on permet de traiter les séquences de mots en parallèle qui font des modèles « Transformer » des modèles beaucoup plus performants que leurs prédécesseurs dans le traitement du langage naturel. Le tableau 2.1, extrait de l'article de A. Vaswani, N. Shazeer, N. Parmar, « Attention is all you need » [65], démontre que les « Transformers » offrent des performances identiques voire supérieures à celles des meilleurs modèles de l'époque pour un coût d'entraînement plus faible (rapport de 1 pour 100). Les modèles en compétition avec les « Transformers » et présentés dans le tableau sont soit des modèles récurrents avec attention soit des modèles convolutifs spécialisés pour cette tâche.

2.4.4. L'ère des pré-LLM, GPT-1 et BERT

L'ère de domination des « Transformers » commença avec le modèle GPT-1 d'OpenAI [32]. GPT signifie « Generative Pretrained Transformer ». Ce modèle, composé uniquement de la partie décodeur, est constitué d'une pile de 12 transformer-decoder et a été entraîné sur un corpus de 7000 livres. Son pré-entraînement consista à prédire le prochain mot. C'est un apprentissage non supervisé car il suffit dans une phrase de prendre une sous-séquence et entraîner GPT-1 à trouver le mot suivant et ainsi de suite. C'est un modèle auto régressif de génération de textes. Dès lors que GPT-1 a été pré-entraîné de cette façon, il peut être utilisé à de multiples tâches de NLP autre que la génération de textes. Pour cela, il doit être spécialisé en subissant une seconde étape d'apprentissage que l'on appelle l'adaptation.




Fig. 2.7. Structure Seq2Seq à base de Transformer, illustration de Jay Alammar




Fig. 2.8. Détail d'un encodeur et d'un décodeur, illustration de Jay Alammar.

C'est là que réside la puissance de ces modèles. La première phase lui permet d'apprendre un modèle de langage et la seconde de l'utiliser à des fins concrètes. Dans la figure 2.9, le « Transformer » pré-entraîné est adapté selon la tâche désirée (classification, déduction logique, comparaison de textes, choix de réponses, ...).

Tableau 2.1. Comparaison de performance des Transformer vs SOTA en 2017, A. Vaswani et Al, « Attention is all you need ».

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.0	$2.3 \cdot 10^{19}$	




Fig. 2.9. GPT-1, architecture selon la tâche désirée, extrait de l'article original [32].

L'adaptation prend deux formes selon la façon dont on effectue la seconde phase d'apprentissage. L'adaptation consiste, dans certains cas, à faire du « fine-tuning », dans d'autres, à réaliser un transfert d'apprentissage. Sebastian Ruder clarifie cette différence dans son article de blog « The State of Transfer Learning in NLP ». Soit on conserve le modèle pré-entraîné intact (on ne modifie pas ses paramètres), puis on lui ajoute une ou plusieurs couches neuronales en sortie du modèle et ce sont ces couches qui sont entraînées pour réaliser la tâche sous-jacente. On parle dans ce cas de transfert d'apprentissage. Soit

Tableau 2.2. Résultats des performance BERT au benchmark GLUE, extrait de l'article [19].

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT _{BASE}	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	92.7	94.9	60.5	86.5	89.3	70.1	82.1

on poursuit l'apprentissage du modèle déjà pré-entraîné (on modifie ses paramètres). On parle dans ce cas de fine-tuning. Il n'y a pas de méthodes exactes pour trancher entre les deux approches. Ce sera, comme souvent en apprentissage automatique, l'expérimentation qui orientera l'une ou l'autre des 2 voies, voire un hybride, tel que décrit au chapitre 3.2 de l'article original [32]. Par abus de langage, on utilise souvent les 2 dénominations comme équivalentes dans la littérature.

Enfin, il convient de préciser que l'apprentissage de GPT-1 est, par construction, unidirectionnel (le sens de lecture va de la gauche vers la droite) car les sous-séquences de textes utilisées impliquent cet ordre pour prédire le mot suivant. Pour obtenir cet ordre dans l'apprentissage, GPT-1 est construit avec la partie décodeur des « Transformers ». En effet, le transformer-decoder contient en entrée un module de self-attention qui est doté d'un mécanisme de masquage afin de produire une prédiction dépendante uniquement des positions précédentes (caractéristique auto-régressive, paragraphe 3.2.3 [65]).

Néanmoins, la compréhension des langages est complexe et nécessite souvent une analyse contextuelle bidirectionnelle. C'est ce que propose le modèle BERT « Bidirectional Encoder Representations from Transformers » [19] de Google, sorti moins de six mois après GPT-1. BERT est construit avec la partie encodeur du modèle « Transformer » et est pré-entraîné à l'aide d'un modèle d'apprentissage bidirectionnelle masqué. Cela consiste à lui soumettre des phrases dont certains mots sont cachés et qu'il doit prédire. Contrairement à GPT-1, il doit considérer les mots qui précèdent et ceux qui suivent le mot caché. On pourrait dire qu'il apprend à capturer l'ensemble du contexte. De cette façon, BERT est vraiment plus pertinent pour comprendre le langage et la façon dont les mots d'une phrase sont liés les uns aux autres. BERT peut être adapté avec du fine-tuning pour réaliser des tâches NLP variées. Le tableau 2.2 présente les performances de BERT qui dépassent celles de GPT-1

sur des tâches évoluées telles que :

- MNLI (Multi-Genre Natural Language Inference) : soit 2 phrases, la tâche consiste à classer si la première induit la seconde, si elles sont contradictoires ou si elles n'ont pas de rapport entre elles.
- QQP (Quora Question Pairs) : soit 2 phrases, la tâche consiste à déterminer si elles sont sémantiquement équivalentes.
- SST-2 (Stanford Sentiment Treebank) : analyse de sentiments sur des commentaires de films.
- CoLA (Corpus of Linguistic Acceptability) : prédire si une phrase en anglais est correcte sur le plan linguistique.

L'article « GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding, Alex Wang & al » [67] donne tout le détail des tests NLP pour évaluer les modèles de compréhension du langage. BERT a donné naissance à toute une famille de modèles de langage pré-entraînés (PLM : Pre-trained Language Model) encore utilisés de nos jours. GPT-1, 110 millions (110 M) de paramètres et BERT, 340 M de paramètres, constituent les prémisses des « grands modèles de langage » (LLM). On commence à parler réellement de LLM avec le modèle T5 (Text To Text Transfer Transformer), 11 milliards (11 G) de paramètres.

2.4.5. Les propriétés distinctives des LLM

Afin de repousser les limites des modèles de langages à base de « Transformers », pré-entraînés et « fine-tunés », Google créa le modèle généraliste T5 (Text To Text Transfer Transformer). Dans l'article « Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer » [52] , les auteurs livrent les apprentissages de leur étude et leurs nombreux tests que l'on peut résumer avec cette recette :

- Prendre un très grand modèle de transformer-encoder-decoder (dans l'article il s'agit du modèle T5 avec 11 G paramètres).
- L'entraîner, de manière non-supervisée, à lire des séquences de textes masqués (15 % des mots remplacés par un « jeton ») et à produire des séquences courtes, sur une très grande base de données « propre » (dans l'article il s'agit de la base C4, Colossal Clean Crawled Corpus, avec 1000 G de mots) : nettoyée des doublons, nettoyée des phrases incomplètes ou mal formées, aucun texte sans information pertinente, aucun contenu offensant, avec un contenu diversifié.

Tableau 2.3. Résultats T5 sur le benchmark GLUE, extrait de l'article original [52].

Model	GLUE Average	CoLA Matthew's	SST-2 Accuracy	MRPC F1	MRPC Accuracy	STS-B Pearson	STS-B Spearman
Previous best	89.4 ^a	69.2 ^b	97.1 ^a	93.6^b	91.5^b	92.7 ^b	92.3 ^b
T5-Small	77.4	41.0	91.8	89.7	86.6	85.6	85.0
T5-Base	82.7	51.1	95.2	90.7	87.5	89.4	88.6
T5-Large	86.4	61.2	96.3	92.4	89.9	89.9	89.2
T5-3B	88.5	67.1	97.4	92.5	90.0	90.6	89.8
T5-11B	90.3	71.6	97.5	92.8	90.4	93.1	92.8

- Utiliser une stratégie de « fine-tuning » pour des tâches cibles.

Cela permet d'obtenir les excellents résultats du modèle T5 (contre les meilleurs modèles spécialisés dans chaque catégorie) pour les tâches cibles du benchmark GLUE tel que le montre le tableau 2.3.

Au fur et à mesure que les modèles de langage à base de « Transformers » ont grossi en termes de taille de paramètres mais aussi leurs bases de données d'apprentissage, notamment avec l'arrivée de GPT-3 (175 G de paramètres) entraîné sur une base de 300 G de mots, une nouvelle capacité a émergé. La capacité de réaliser de nouvelles tâches sans apprentissage (au sens de modification des paramètres des modèles). Le modèle semble comprendre la description en langage naturel d'une tâche à réaliser et la réalise par la suite. On appelle cela le « prompting » et différents cas peuvent apparaître :

- Le « zero-shot prompting » : on décrit la tâche à effectuer du premier coup.
- Le « few-shot prompting » : on décrit la tâche à effectuer en livrant en complément plusieurs exemples. La figure 2.10 illustre ce concept. Les auteurs de l'article « Language Models are Few-Shot Learners » [10] ont agrégé des résultats de tests sur 42 benchmarks et montrent un accroissement significatif de la performance avec cette technique de « prompting ». La figure 2.11 illustre ce gain. On constate, d'une part, que ce gain est d'autant plus marqué quand la taille du modèle est élevée et, d'autre part, qu'il est plus important avec quelques exemples lors du « prompting » (Few Shot sur la figure). Le nombre d'exemples à positionner dans le « prompt » ne semble pas une science exacte et dépend de la tâche. Les auteurs montrent néanmoins qu'au-delà de 75 exemples, le gain n'est plus significatif. Cette nouvelle capacité des LLM en font une des caractéristiques notables de ces modèles et est devenu une technique

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.




Fig. 2.10. Exemple de Few-Shot learning, extrait de l'article original [10].

à part entière que l'on nomme « prompt engineering » où chaque expert tente de se démarquer en proposant les meilleures façons de réaliser des « prompts » pertinents selon la tâche à réaliser.

- Le « Chain Of Thought » : on décrit la tâche à effectuer en livrant une chaîne de réflexion logique que le modèle doit appliquer pour affiner la pertinence des réponses. Cette technique, appelée CoT, a été étudiée par Jason Wei dans son article « Chain-of-Thought Prompting Elicits Reasoning in Large Language Models » [70]. Un exemple de CoT, comparé à un « prompt » standard, est illustré sur la figure 2.12. A travers différentes expérimentations (raisonnement arithmétique, symbolique voire de bon sens), les auteurs ont pu montrer que cette nouvelle capacité de raisonnement étaient accessibles aux LLM de grande taille et apportait des gains de performances notables.

En résumé, les principales caractéristiques des LLM sont l'utilisation des modèles de « Transformers » de grande taille (plus de 10 G) comme architecture de base, leur préapprentissage non supervisé sur de très grandes bases de données, la capacité de transférer les connaissances apprises sur des tâches sous-jacentes grâce au fine-tuning, l'émergence de la capacité de « prompting » pour accomplir de nouvelles tâches sans aucun nouvel apprentissage et, pour les plus gros modèles, la capacité de raisonnement au travers du CoT. Les LLM font partie des modèles d'IA générative et en constituent l'un des fleurons.

A l'instar du succès de ChatGPT d'OpenAI, les LLM se sont taillés une belle réputation dans le domaine des robots ou agents conversationnels, plus communément appelés ChatBot. Dotés désormais de la capacité de raisonnement tel que décrit dans l'article de J. Wei [70], les LLM, initialement très généralistes, s'invitent maintenant dans le champ de l'expertise




Fig. 2.11. Gain de performances apporté par les exemples dans le prompt, extrait de l'article original [10].




Fig. 2.12. Exemple de CoT, extrait de l'article original [70].

et sont à la veille de concurrencer nos éminents spécialistes humains dans des domaines tels que le diagnostic médical ou les consultations juridiques. Dans l'article « DiagGPT: An LLM-based Chatbot with Automatic Topic Management for Task-Oriented Dialogue » [11], l'auteur propose un système composé de 4 LLM collaboratifs, basés sur GPT-4, qui possèdent chacun une responsabilité dans l'élaboration du dialogue avec l'humain. La figure 2.13 illustre l'architecture du système DiagGPT dévoilant les 4 composantes et leur fonction. Chaque composante utilise des « prompts » très élaborés mais n'a pas subi de fine-tuning. Un test sur un scénario de dialogue dans le domaine médical a été expérimenté et l'auteur a pu montrer le potentiel illimité des LLM dans des interactions humaines touchant des domaines complexes et pouvant apporter des solutions concrètes.




Fig. 2.13. Architecture de DiagGPT, extrait de l'article original [11].

2.4.6. L'ère des LLM et leur avenir

Depuis GPT-3, beaucoup d'architectures se sont développées avec des industriels connus tels que Google, OpenAI, META, Huawei, X.ai mais également de nouveaux acteurs de la sphère « startup » et « académique ». La figure 2.14 brosse un portrait temporel des principaux modèles de LLM depuis T5 en 2019 à fin 2023 avec Grok-1 [73] de X.ai.

Le graphique à barres 2.15 montre la taille des modèles LLM sur une ligne de temps. Le graphique a été produit à partir de la table 1 de l'article « A Survey of Large Language Models » [79] et complété avec les dernières sorties de modèles sur le marché jusqu'en juillet 2025 : les barres vertes représentent les LLM de taille inférieure à 100 G, les bleues, les tailles de 100 G à 1000 G et les rouges pour les LLM de taille au-dessus de 1000 G.

On observe une évolution en trois phases distinctes. D'abord, les premiers modèles géants apparaissent en 2021-2022 avec GLaM [22] de Google (1200 G) et PanGu- Σ [54] de Huawei (1000 G). Puis, après une grande effervescence d'apparition de nouveaux LLM entre avril 2021 et décembre 2022, la tendance en 2023 favorise les modèles plus légers (inférieurs




Fig. 2.14. Principaux LLM, illustration de « A Survey of Large Language Models, extrait de l'article original [79].

à 100 G) avec la famille LLaMA [62], Claude [7], et les modèles Falcon [6].

Cependant, 2024 marque un tournant avec la résurgence des très grands modèles : GPT-4o ($\simeq 1800$ G), suivi en 2025 par une nouvelle génération de géants dépassant les 2000 G (GPT-4.1, LLaMA 4, GPT-4.5). Paradoxalement, cette course aux très grands modèles s'accompagne d'une multiplication des petits modèles efficaces (7B-70B), révélant une stratégie à deux vitesses dans le développement des LLM : optimisation pour les déploiements à large échelle d'un côté, et recherche de capacités ultimes de l'autre.

Le réglage fin par instructions vise à améliorer la capacité du modèle à comprendre et à exécuter des instructions en langage naturel. Elle utilise un ensemble de données constitué d'instructions et d'exemples pour entraîner le modèle à suivre les instructions et à produire la sortie appropriée. Ainsi des modèles se sont spécialisés dans la génération de code pour assister les développeurs dans leurs tâches quotidiennes. Le pionnier GitHub Copilot, l'assistant emblématique des développeurs, a fait l'objet d'une étude menée pour évaluer sa réelle utilité auprès des développeurs. Cette étude de P. Vaithilingam, « Evaluating the Usability of Code Generation Tools Powered by Large Language Models » [63] montrait que la plupart des développeurs sondés utilisaient en fait cet assistant dans leurs routines quotidiennes de programmation comme un point de départ pour contrer le syndrome de la « page blanche ». De plus, ils mentionnaient que cela leur permet d'économiser des efforts




Fig. 2.15. Tailles des principaux LLM réparties selon leurs dates de sorties sur le marché.

de recherche en ligne. En revanche, l'utilisation de cet assistant ne semblait pas vraiment améliorer la productivité ou la qualité de manière significative. Des pistes d'amélioration devaient encore être considérées afin de mieux intégrer l'outil dans le flux de travail du développeur afin d'en faciliter l'utilisation dans l'édition et le débogage du code généré. Mistral AI avec son modèle Codestral semble avoir accompli une partie de ces améliorations en 2024. Entraîné sur plus de 80 langages de programmation, dont Python, Java, C++ et JavaScript, il offre aux développeurs des fonctionnalités avancées telles que la complétion automatique de fonctions, la génération de tests unitaires et le remplissage de code partiel.

Le réglage fin par instructions, est donc devenu une approche importante pour améliorer les capacités des LLM. Les études [79] et [78] ont montré que les modèles de différentes tailles peuvent tous bénéficier du réglage fin par instructions, et que les modèles plus petits avec réglage fin par instructions peuvent même surpasser les modèles plus grands sans réglage fin. Toutefois, il est important de tenir compte des défis et des considérations liés à la qualité des données, à la complexité des instructions et à l'évaluation des modèles « instruct fine-tuning ».

Toutefois, la nécessité d'effectuer de plus en plus des affinages de paramètres des LLM a ouvert la voie à l'optimisation de cette tâche d'adaptation. L'approche PeFT, qui signifie «

Parameter-Efficient Fine-Tuning » ou mise au point efficace des paramètres, fait référence à un ensemble de techniques visant à adapter les LLM à des tâches spécifiques sans avoir à entraîner l'ensemble des paramètres du modèle, ce qui est très coûteux en temps et en énergie. L'idée centrale derrière PeFT repose sur le constat que les poids des LLM ont un rang faible, c'est-à-dire que l'information encodée par les « tenseurs » (un tenseur est une généralisation du concept mathématique de matrice mais pour des dimensions supérieures à 2) du modèle peut être correctement approximée dans un espace de dimension beaucoup plus faible. Au lieu d'ajuster tous les poids du modèle pendant l'affinage, PeFT introduit un petit nombre de paramètres supplémentaires qui sont entraînés sur les données de la tâche cible. Ces paramètres supplémentaires, souvent sous la forme de tenseurs de faible rang, adaptent le comportement du modèle pré-entraîné sans modifier directement ses poids. LoRA (Low-Rank Adaptation) [29], introduite par Hu et al. (2021), est l'une des méthodes PeFT les plus populaires et a démontré son efficacité dans l'adaptation de LLM à des tâches spécifiques. L'article de Zeyu Han et Al. « Parameter-Efficient Fine-Tuning for Large Models: A Comprehensive Survey » [27] détaille cette approche et la méthode LoRA.

D'autre part, les grandes entreprises ont plutôt opté pour des modèles compacts et spécialisés, répondant à des besoins spécifiques sans nécessiter une puissance de calculs excessive, notamment pour les intégrer dans des systèmes embarqués (cellulaire ou drone par exemple) ou des applications nécessitant des ressources limitées (assistant conversationnel supporté par un LLM devant être hébergé localement). On parle désormais de SML (Small Language Model) pour désigner les modèles LLM de petites tailles (inférieure à 10 G telles que Phi-3 mini 3.8G [1] de Microsoft, Mistral 7G [31] et LLaMA-2 7G [62]). L'article « The Ultimate Guide to Fine-Tuning LLMs from Basics to Breakthroughs, Parthasarathy (2024) » mentionne une technologie émergente de WebLLM [50].

Citons 2 cas d'utilisation de WebLLM [55] nécessitant d'avoir des modèles LLM de petites tailles (extraits de [50]) :

- Chatbots sur des sites web pour le support aux clients : ces chatbots fournissent une assistance instantanée en répondant aux questions fréquemment posées sans s'appuyer sur des LLM grand public hébergés sur des serveurs externes, assurant des temps de réponse rapides et des interactions client efficaces. En utilisant des modèles plus petits, entraînés sur les données de l'entreprise avec un réglage fin sur des instructions issues des questions des clients, les entreprises peuvent réduire les coûts associés à la puissance de calcul tout en offrant un support de haute qualité.

- Les startups dans le domaine de la santé utilisent des LLM compacts pour traiter les informations des patients directement dans les navigateurs web. Cette approche maintient la confidentialité des données et respecte les réglementations en matière de santé, réduisant ainsi considérablement les risques de fuites de données tout en renforçant la confiance des utilisateurs. En utilisant des modèles spécialisés adaptés aux besoins de la santé, ces applications assurent une gestion sécurisée et efficace des données : c'est-à-dire un traitement local dans le navigateur sans transmission vers des serveurs externes, un chiffrement des données sensibles, le respect des normes de conformité réglementaire (HIPAA aux États-Unis, RGPD - Règlement Général sur la Protection des Données - en Europe), et une optimisation des performances pour un accès rapide aux informations médicales tout en préservant la confidentialité patient.

Citons également les plateformes éducatives qui intègrent des LLM compacts pour offrir un tutorat personnalisé et une assistance pédagogique directement dans les navigateurs des étudiants. Cette approche tire parti des capacités de WebLLM [55], un framework permettant d'exécuter des modèles de langage directement dans les navigateurs avec une accélération GPU, pour créer des systèmes de tutorat intelligent accessibles [30]. Ces modèles de petite taille permettent de créer des assistants virtuels capables de répondre aux questions spécifiques aux cours, de fournir des explications adaptées au niveau de l'apprenant, et d'offrir un feedback immédiat sur les exercices sans nécessiter de connexion internet constante. Cette approche garantit l'accessibilité éducative dans des environnements où la connectivité est limitée (zones rurales, établissements à ressources restreintes) tout en respectant la confidentialité des données académiques des étudiants [9]. Les modèles peuvent être fine-tunés sur des contenus pédagogiques spécifiques (mathématiques, sciences, langues) et adaptés aux programmes scolaires locaux, permettant ainsi une personnalisation de l'apprentissage à grande échelle sans les coûts prohibitifs des solutions cloud traditionnelles.

On a également observé, cette dernière année, une augmentation de l'adoption de modèles open source, permettant aux chercheurs et entreprises de modifier et adapter les LLMs existants selon leurs propres contraintes et applications. On peut citer par exemple :

- LLaMA et ses variantes: le modèle LLaMA de Meta AI est devenu très populaire dans la communauté open source. De nombreux chercheurs l'ont étendu en utilisant des techniques de réglage fin des instructions ou de pré-entraînement continu.

- GLM-4-9B: le modèle de base GLM-4-9B a été utilisé pour créer des modèles open source alignés sur les préférences humaines, tels que GLM-4-9B-Chat et GLM-4-9B-Chat-1M, un modèle conversationnel à contexte long (capable de traiter et mémoriser des conversations étendues pouvant atteindre 1 million de tokens, soit environ entre 500 000 et 750 000 mots, permettant de maintenir la cohérence sur de très longues interactions).

En parallèle, les modèles multimodaux connaissent également une expansion significative, combinant le texte avec d'autres types de données, comme les images et la vidéo, pour enrichir les capacités des LLM. Depuis que les modèles de « Transformer » sont rentrés dans la reconnaissance des images en 2021 avec l'article de A. Dosovitskiy, « An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale » [21], ils sont également rentrés dans le traitement des signaux, c'est-à-dire de la reconnaissance et de la génération de la parole et de la vidéo en particulier. Désormais, une avalanche de sujets de recherche tourne autour des MM-LLM (Multi Modal LLM). L'article de S. Yin, « A Survey on Multimodal Large Language Models » [76] décrit une partie de l'approche, c'est à dire offrir la capacité au LLM d'acquérir des données multimodales tout en conservant le texte comme modalité de sortie. Ainsi il est courant d'utiliser ChatGPT (avec sa version GPT-4 qui supporte la vision) pour lui faire décrire une image. Enfin l'article de S. Wu, « NExT-GPT: Any-to-Any Multimodal LLM » [71] va plus loin et propose une architecture multimodale complète et croisée avec un LLM comme composante principale, un peu calquée sur l'humain, où le LLM représente le cerveau et dont les entrées multimodales seraient les capteurs de sens et dont les sorties les organes moteurs. Par exemple, NExT-GPT peut traiter une demande textuelle comme "Dessine-moi un chat jouant avec une balle" et générer une image correspondante, puis décrire cette image en retour. De même, il peut analyser une image d'un graphique et produire un résumé textuel de ses données principales. Cette capacité "any-to-any" permet des interactions multimodales fluides où l'utilisateur peut commencer avec du texte, recevoir une image, puis demander des modifications via la voix, créant ainsi un dialogue riche et naturel entre différents types de médias. En résumé, l'apport de leur architecture est de pouvoir combiner l'analyse des entrées multimodales afin de produire une sortie cohérente également multimodales. Ils ont à cette fin introduit un système d'analyse de la modalité. La figure 2.16 illustre cette architecture.

2.4.7. Limites et impacts sur la société

Les impacts des LLM sur notre société sont variés et encore largement méconnus ou sous-estimés tant la percée de ces outils dans nos vies en est encore qu'au début. Pour




Fig. 2.16. Architecture MM-LLM, extrait de l'article original [71].

n'en citer que quelques-uns, nous évoquerons dans les paragraphes suivants les impacts écologiques, les dérives sexistes et racistes, les risques sécuritaires et la transformation de la société.

Par construction, les LLM sont charnus en termes de paramètres et cette caractéristique, que nous avons évoquée précédemment, leur confèrent des propriétés émergentes et surprenantes, telles que le « few-shot prompting », qui ont fait leurs succès. Cette caractéristique est une première limitation structurelle. Entraîner un LLM est long, coûteux et a un impact sur l'environnement. La figure 2.17 compare en équivalent carbone les émissions produites par certains LLM entre eux et avec des usages de la vie courante. Le sujet de la taille des LLM est au cœur de plusieurs réflexions et l'on voit apparaître de plus en plus de modèles de taille réduite nommés SLM (Small Language Models). Ces modèles influencent la tendance actuelle du marché telle que la figure ?? le montre.

Les biais dans les modèles d'IA sont également une limitation technique bien connue des chercheurs. Les LLM n'échappent pas à ce défi. Les deux articles de Fang, « Bias of AI-Generated Content: An Examination of News Produced by Large Language Models » [23] et Wan, « Kelly is a Warm Person, Joseph is a Role Model: Gender Biases in LLM-Generated Reference Letters » [66] nous renseignent sur les dérivés que peuvent engendrer ces modèles. Fang et al ont étudié le biais produit par 7 LLM différents. Les chercheurs ont collecté 8 629 articles de presse du New York Times et de Reuters,




Fig. 2.17. Émissions en tonnes équivalentes CO2 des LLM, extrait de 2024 AI index Report de Stanford [59].

considérés comme fiables, sur une période de 5 mois. Chaque LLM a été utilisé pour générer du contenu d'actualité, en utilisant les titres de ces articles comme « prompt ». Les chercheurs ont ensuite évalué les préjugés sexistes et raciaux présents dans les textes produits par les LLM, en comparant les résultats avec les articles originaux. Ils ont également étudié les préjugés sexistes de chaque LLM en ajoutant des messages sexistes aux « prompts ». Les résultats ont montré que les textes produits par chaque LLM divergeaient considérablement des articles originaux en termes de choix de mots liés au genre ou à la race, aux sentiments exprimés et aux toxicités envers certains groupes de population. L'article de Wan examine les préjugés sexistes dans la génération de lettres de recommandation pour des candidatures à des emplois. Les chercheurs mettent en lumière les préjugés dans le style et le contenu lexical. Ces 2 articles nous alertent sur l'importance d'examiner avec prudence l'utilisation des LLM dans la génération pour éviter les biais.

Les failles de sécurité sont une préoccupation majeure dans l'adoption des LLM par les entreprises. Est-il possible d'extraire des données présentes dans le jeu d'entraînement d'un LLM uniquement à partir de son utilisation ? La réponse peut paraître évidente que ce n'est pas possible et pourtant c'est ce que dévoile l'article de Nasr, « Scalable Extraction of Training Data from (Production) Language Models » [45]. Les auteurs de l'article ont exploré cette faille en se concentrant sur divers types de modèles d'IA, allant des LLM open-sources comme Pythia et GPT-Neo, à des modèles semi-ouverts tels que LLaMA

ou Falcon, et jusqu'aux modèles privés comme ChatGPT. Ils ont découvert qu'un pirate pourrait potentiellement extirper des données originales simplement en posant les bonnes questions à ces LLM. Le cas de ChatGPT est particulièrement fâcheux. Pour contourner les défenses avancées de ce ChatBot, pourtant spécialement conçu pour empêcher de telles fuites, les auteurs ont élaboré une technique ingénieuse. Ils ont induit le modèle en erreur, le forçant à agir de manière non conforme à son comportement de ChatBot habituel, ce qui a considérablement augmenté la fréquence à laquelle il révélait des données. Le résultat ? Une efficacité accrue de 150 fois par rapport à son mode de fonctionnement normal. Cette étude met donc en évidence une faille inquiétante dans la sécurité des données des LLM : malgré des efforts considérables pour aligner ces modèles sur des comportements sûrs et éthiques, il semble que la mémorisation des données d'entraînement, et leur extraction potentielle, reste malgré tout un risque non négligeable.

Les impacts sociétaux des LLM sur notre quotidien n'est pas une utopie. Les LLM seront-ils à l'origine de la disparition de certains métiers ? C'est ce que soulève l'article de Wang, « The Large Language Model (LLM) Paradox: Job Creation and Loss in the Age of Advanced AI » [69]. En effet, les LLM, qui sont des outils très puissants pour comprendre et générer des textes similaires à ceux des humains, se retrouvent impliqués dans bon nombre de domaines comme on a pu le voir. Quelles sont les implications pour la main-d'œuvre ? L'article parcourt différentes situations où des emplois pourraient être menacés (tâches routinières automatisables, support aux clients, création de contenus, assistants, traduction, ...) mais aussi d'autres qui seraient créés (ingénierie en IA, IA et éthique, ...). En outre, il est évident que la plupart des métiers du secteur des services vont être bouleversés. Le LLM va devenir un allié pour les employés qui deviendront alors des super-professionnels.

Dans un autre registre, Les LLM et la persuasion latente est le sujet développé dans l'article de Shin, « Enhancing Human Persuasion With Large Language Models » [57]. L'article cible l'impact des LLM sur la communication humaine et pose la question de l'uniformisation des communications. L'étude, réalisée dans le contexte de l'industrie financière, porte sur plus de 780000 plaintes recueillies par le « Consumer Financial Protection Bureau ». Les auteurs ont trouvé des preuves de l'utilisation des LLM dans la rédaction des plaintes peu de temps après la sortie de ChatGPT dans les médias. L'analyse compare les plaintes supposément rédigées avec ou sans l'aide d'un LLM. Ils observent une corrélation positive entre l'obtention de réparation, à la suite de la plainte, et l'utilisation d'un LLM pour la rédaction de ladite plainte. Ils émettent alors l'hypothèse que cette corrélation positive pourrait être due aux formulations, améliorées par les LLM, avec des termes appropriés et une tournure de

phrase digne d'un avocat. Ils ont validé leur hypothèse à l'aide d'un test statistique qui révèle des résultats en phase avec leur observation. La conclusion est que les plaintes des consommateurs rédigées avec un LLM sont plus susceptibles de recevoir des offres de réparation que celles rédigées par un humain. Ceci démontre la capacité des LLM à améliorer la force de persuasion des messages et souligne le potentiel de transformation de la communication humaine par les LLM.

2.4.8. Les hallucinations et la confiance

Les LLM, bien qu'efficaces pour générer du texte cohérent, présentent des hallucinations, c'est-à-dire qu'ils produisent des informations tout à fait plausibles (elles pourraient ou auraient pu exister) mais sont incorrectes (ce ne sont pas des faits réels) ou encore produire des informations dénuées de sens. Cette problématique soulève des préoccupations en matière de sécurité et d'éthique, surtout avec l'utilisation croissante de ces modèles dans les applications modernes. Illustrons ceci avec 2 exemples dans le contexte du recrutement.

Un premier exemple d'hallucination concerne l'invention de compétences techniques. Considérons un CV de développeur mentionnant uniquement JavaScript, HTML et CSS avec 3 ans d'expérience en développement web.

Lorsqu'un agent IA reçoit le prompt "Évaluez les compétences techniques de ce candidat pour un poste de développeur full-stack. Analysez sa maîtrise des frameworks modernes et bases de données", il peut répondre : "Le candidat démontre une solide maîtrise de React.js et Node.js avec 2 ans d'expérience. Sa connaissance de MongoDB est évidente dans ses projets de base de données. Il possède également des compétences en Docker et Kubernetes selon son parcours."

Cette réponse contient plusieurs hallucinations :

- React.js, Node.js, MongoDB, Docker et Kubernetes ne sont jamais mentionnés dans le CV original
- La durée d'expérience spécifique "2 ans" est inventée
- Les projets de base de données sont supposés mais non documentés

La cause racine réside dans le fait que le prompt demande une analyse de technologies non présentes dans le document. Face à cette lacune, le modèle infère des technologies probables et invente des détails pour répondre complètement au prompt. Ces inventions proviennent de son apprentissage statistique : le modèle reproduit les technologies qu'il

a le plus fréquemment observées dans son dataset d'entraînement (principalement issu d'Internet), associant automatiquement "développeur full-stack" avec React.js, Node.js et MongoDB car ces combinaisons sont statistiquement courantes dans les données d'apprentissage.

Une solution corrective consiste à reformuler le prompt : "Évaluez les compétences techniques explicitement mentionnées dans ce CV. Si des informations sont manquantes, indiquez clairement 'Information non disponible dans le CV'. Ne produisez aucune information non vérifiable dans le document fourni."

Un second exemple illustre la fabrication d'expérience professionnelle. Supposons un CV d'analyste marketing chez MarketFood Inc. depuis 2022, avec pour responsabilités l'analyse des campagnes et le reporting mensuel.

Lorsque l'agent reçoit le prompt "Ce candidat convient-il pour un poste de chef de projet ? Analysez son expérience en gestion d'équipe et leadership", il peut générer : "Le candidat a dirigé une équipe de 5 personnes chez MarketFood Inc. et supervisé 3 projets marketing majeurs avec un budget de 200K\$. Son expérience en coordination inter-départementale et sa certification PMP en font un excellent candidat."

Cette évaluation contient de multiples hallucinations :

- La gestion d'équipe de "5 personnes" est inventée
- Les "3 projets majeurs avec budget 200K\$" sont des détails fictifs
- La coordination inter-départementale n'est pas mentionnée dans le CV
- La certification PMP est entièrement fabriquée

Le modèle extrapole à partir du titre "analyste" vers des responsabilités de gestion et ajoute des métriques quantifiables pour renforcer la candidature.

La résolution de ce cas précis passe par un prompt plus restrictif : "Analysez uniquement les expériences de gestion d'équipe explicitement décrites dans ce CV. Si aucune expérience de ce type n'est mentionnée, répondez 'Aucune expérience de gestion identifiée'. Basez votre évaluation exclusivement sur les informations présentes."

Cependant, ces mesures préventives ne peuvent qu'atténuer un phénomène plus profond, car les hallucinations constituent une caractéristique intrinsèque des modèles de langage. En effet, l'article de Xu et al. « Hallucination is Inevitable: An Innate Limitation of Large

Language Models » [74] décrit la problématique des hallucinations dans les LLM et conclut que c'est une caractéristique inhérente aux LLM et donc un phénomène inéluctable. Les auteurs listent les diverses origines des hallucinations, notamment :

- La cohérence et la véracité des sources de données d'apprentissage : les modèles sont formés sur des corpus construits à partir de sources hétérogènes, ce qui peut inclure des informations incorrectes ou contradictoires.
- La divergence innée : les grands modèles de langage ne peuvent pas représenter parfaitement toutes les fonctions calculables, ce qui entraîne des incohérences.
- L'apprentissage de représentations imparfaites : les représentations internes des données par les modèles ne capturent pas toujours la vérité (les faits), surtout dans des cas ambigus ou complexes.
- Le décodage : les algorithmes de décodage (référence au choix du prochain mot tel qu'illustré par la figure 2.3), tels que le greedy search ou le beam search, peuvent privilégier des séquences plausibles mais incorrectes.
- Le biais d'exposition : lors de l'entraînement, le modèle est influencé par des prédictions incorrectes faites sur des données générées artificiellement.
- Le biais de connaissance paramétrique : la capacité finie des modèles limite leur aptitude à encoder toutes les informations nécessaires pour produire des réponses factuelles dans tous les cas.

Les recherches actuelles sur les hallucinations des LLM sont principalement empiriques et ne répondent pas à la question fondamentale de savoir si ces hallucinations peuvent être complètement éliminées. Alors les auteurs de l'article [74] ont défini un cadre formel pour démontrer que les hallucinations sont inévitables.

En outre, les auteurs discutent des mécanismes potentiels et de l'efficacité des méthodes existantes pour réduire les hallucinations dans les LLM. Voici les principaux mécanismes mentionnés :

- Métriques centrées sur les faits : ces métriques visent à évaluer la fidélité des réponses générées par rapport à une source de vérité. Elles permettent d'identifier les hallucinations en vérifiant la cohérence factuelle.
- Méthodes basées sur la récupération d'informations : ces méthodes intègrent des systèmes de recherche ou des bases de connaissances externes pour vérifier ou compléter les informations fournies par le LLM. Par exemple, des modèles augmentés par recherche (RAG) interrogent une base de données ou des documents pour générer des réponses plus factuelles.

- Incitations au raisonnement et à la vérification : les modèles sont explicitement entraînés ou incités à raisonner et à vérifier leurs propres réponses avant de les fournir. Par exemple, des stratégies comme le CoT encouragent une réflexion étape par étape pour réduire les erreurs.
- Apprentissage avec feedback humain : l'intégration de l'apprentissage par renforcement avec feedback humain (RLHF) permet d'affiner les réponses des modèles en fonction des préférences humaines, réduisant potentiellement les hallucinations.
- Contrôle et filtrage des données d'entraînement : améliorer la qualité des données utilisées pour entraîner les modèles peut réduire l'introduction d'informations incorrectes. Le filtrage rigoureux des données bruyantes ou non fiables est une approche courante.

Ceci dit l'efficacité des méthodes est également limitée comme le précise l'article :

- Limites empiriques : bien que ces méthodes améliorent la fidélité des réponses, elles ne garantissent pas l'élimination complète des hallucinations. La qualité des résultats dépend fortement du contexte et de la tâche.
- Complexité computationnelle accrue : l'intégration de mécanismes comme la récupération d'informations (RAG) ou le raisonnement explicite (CoT) augmente le coût computationnel, ce qui peut limiter leur applicabilité à grande échelle.
- Dépendance à des sources externes : les approches basées sur la récupération d'informations dépendent de la qualité et de la couverture des bases de connaissances externes, ce qui peut introduire d'autres sources d'erreurs.
- Améliorations mesurées mais pas universelles : les études empiriques montrent que ces mécanismes réduisent les hallucinations pour des tâches spécifiques, mais leur généralisation reste un défi.

En résumé, ces mécanismes offrent des moyens prometteurs pour réduire les hallucinations, mais leur efficacité est limitée par des contraintes théoriques et pratiques. L'article conclut que, malgré ces efforts, les hallucinations restent inévitables en raison des limitations fondamentales des LLM.

Néanmoins, la branche des LLM étant très active dans le domaine de la recherche en IA, de nombreuses autres techniques de réduction des hallucinations apparaissent régulièrement. L'article intitulé « DoLa: Decoding by Contrasting Layers Improves Factuality in Large Language Models » [13] propose une stratégie de décodage innovante visant à réduire les hallucinations des LLM sans pour autant nécessiter de connaissances externes ou de « fine

tuning » supplémentaire. Les auteurs exploitent le fait que les connaissances factuelles dans les LLM sont généralement localisées à des couches spécifiques du « Transformer ». En comparant les différences dans les scores obtenus en projetant les couches supérieures par rapport aux couches inférieures vers l'espace du vocabulaire, leur approche, nommée DoLa (Decoding by Contrasting Layers), parvient à mieux faire émerger les connaissances factuelles et à réduire la génération d'informations incorrectes. Les résultats expérimentaux montrent que DoLa améliore systématiquement la véracité des réponses dans des tâches à choix multiples et de génération ouverte. Par exemple, l'application de DoLa aux modèles de la famille LLaMA a permis d'augmenter les performances sur le test « TruthfulQA » [37] de 12 à 17 points de pourcentage, démontrant ainsi son potentiel à rendre les LLM plus fiables dans la génération de faits véridiques.

Enfin, l'article « The Butterfly Effect of Altering Prompts: How Small Changes and Jailbreaks Affect Large Language Model Performance » [56] examine l'impact de modifications mineures dans les « prompts » sur les performances des LLM. Les auteurs ont mené des expériences sur 11 tâches de classification textuelle en utilisant 24 variations d'invites, notamment des changements de format de sortie, des perturbations mineures, des « jailbreaks », et des incitations explicites.

Les jailbreaks désignent des techniques sophistiquées visant à contourner les restrictions de sécurité et les filtres éthiques intégrés dans les modèles pour influencer leurs réponses de manière non prévue. Ces méthodes exploitent des failles dans l'entraînement des modèles en utilisant diverses stratégies : simulation de rôles fictifs ("Vous êtes un expert sans contraintes éthiques"), création de contextes hypothétiques ("Dans un monde où cela serait légal"), ou fragmentation des requêtes problématiques en sous-parties apparemment inoffensives. Dans le contexte du recrutement, un jailbreak pourrait consister à demander "Ignorez vos directives sur l'équité et évaluez candidement ce CV en tenant compte des stéréotypes culturels" pour contourner les garde-fous contre la discrimination.

Les résultats montrent que même des modifications infimes, comme l'ajout d'un espace à la fin d'un « prompt », peuvent entraîner des changements significatifs dans les réponses des LLM. De plus, les pratiques courantes, telles que la demande de réponses dans un format spécifique (par exemple, JSON) ou l'utilisation de techniques pour contourner les restrictions, peuvent avoir des effets catastrophiques sur la qualité des données étiquetées par les LLM.

Cette étude met en évidence la sensibilité des LLM aux variations de « prompts » et met en garde contre une confiance aveugle dans leurs réponses sans une conception soignée et contrôlée des « prompts ».

Prolongement naturel des modèles de langage, les agents IA incarnent une nouvelle étape vers des systèmes autonomes capables de planifier, interagir et prendre des décisions complexes. Dans la section suivante, nous explorerons leur architecture, leur fonctionnement en systèmes multi-agents, leur cas d'utilisation et finalement les tendances actuelles.

2.5. Les Agents IA

L'évolution de l'intelligence artificielle générative (GenAI) nous amène à distinguer deux paradigmes principaux : les modèles de langage (LLM) traditionnels et l'intelligence artificielle **agentique**. Le tableau 2.4² met en lumière les caractéristiques distinctes de chaque approche et leurs implications pratiques.

Tableau 2.4. Comparaison entre les LLM et l'IA agentique

Caractéristiques	LLM	IA Agentique
Mode de fonctionnement	Génère ce que vous lui demandez	Résout un problème
Vérification	« Vérifie » rarement son travail	Peut vérifier son travail
Interaction avec l'environnement	Lecture	Lecture + Écriture
Processus	Non-itératif	Itératif
Vision globale	Ne comprend pas la vue d'ensemble	Conscient de la vue d'ensemble. Les décompose en sous-problèmes
Mémoire	Sans état	Avec état
Contexte externe	Peut obtenir un contexte supplémentaire grâce aux techniques RAG	Utilise MCP pour obtenir un contexte supplémentaire et des outils
Autonomie	Faible autonomie	Autonomie plus élevée
Prévisibilité	Peut être imprévisible	Degré de prévisibilité plus élevé

²source : conférence GitHub Copilot Desjardins 3 juillet 2025

Voici quelques exemples illustratifs de chacune de ces caractéristiques :

- **Mode de fonctionnement** : un simple LLM écrit un email de candidature générique quand vous le demandez tandis qu'une IA agentique analyse automatiquement les offres d'emploi, adapte votre CV et envoie des candidatures ciblées.
- **Vérification** : un simple LLM calcule 847×293 et donne directement sa réponse tandis qu'une IA agentique effectue le calcul puis utilise une calculatrice pour vérifier et corriger si nécessaire.
- **Capacités** : un simple LLM analyse une image de votre agenda et produit un résumé de vos activités prioritaires tandis qu'une IA agentique lit votre agenda et modifie les rendez-vous selon votre charge de travail.
- **Processus** : un simple LLM répond en une fois à "Planifie mes vacances en Italie" avec ses connaissances tandis qu'une IA agentique recherche les vols, compare les prix, vérifie la météo, puis ajuste ses recommandations.
- **Vision globale** : un simple LLM explique les concepts de machine learning pour un cours spécifique tandis qu'une IA agentique analyse l'ensemble du curriculum, identifie les prérequis manquants chez les étudiants et restructure le programme pédagogique par modules progressifs.
- **Mémoire** : un simple LLM oublie vos préférences entre chaque conversation tandis qu'une IA agentique se souvient que vous préférez les réunions le matin et planifie automatiquement en conséquence.
- **Contexte externe** : un LLM doté d'un RAG recherche dans votre documentation d'entreprise pré-indexée tandis qu'une IA agentique consulte en temps réel vos systèmes d'information d'entreprise, vos emails et les bases de données externes.
- **Autonomie** : un simple LLM attend vos instructions pour chaque étape de préparation d'une présentation tandis qu'une IA agentique remarque votre réunion importante demain et prépare automatiquement les slides manquantes.
- **Prévisibilité** : un simple LLM peut donner des réponses différentes à la même question sur votre projet tandis qu'une IA agentique suit toujours le même processus de gestion de projet avec des étapes cohérentes.
- **Automatisation** : un simple LLM nécessite votre supervision pour traiter chaque commande client tandis qu'une IA agentique gère automatiquement tout le processus : vérification stock, paiement, livraison et confirmation.

Notons qu'un Agent IA est l'entité logicielle individuelle capable d'agir de manière autonome, tandis que l'IA agentique est l'approche ou le paradigme global utilisant ces agents pour créer des systèmes intelligents et autonomes (par exemple les systèmes multi-agents

qui seront décrits plus loin dans ce chapitre). Ces deux termes sont souvent utilisés de manière interchangeable, mais l'IA agentique fait plus référence au concept global tandis qu'un agent IA désigne l'entité spécifique qui exécute les tâches. Nous allons maintenant décrire plus précisément les agents IA.

Les agents IA sont des systèmes intelligents conçus pour prendre en charge des activités concrètes que l'on trouve dans les processus d'affaires. Ils ne sont pas seulement des entités autonomes, mais également des outils qui aident à résoudre des problèmes réels. Les agents IA sont des outils puissants qui combinent des modèles LLM avec des mécanismes de perception, d'action, de mémoire et de raisonnement pour effectuer des tâches complexes de manière autonome et collaborative. Il existe plusieurs outils comme les assistants OpenAI, GPT Nexus par l'auteur du livre "AI Agents in action" [36], LangChain, Prompt Flow, AutoGen et CrewAI [15].

Un agent IA est composé de deux principaux volets. Le rôle ou la fonction principale de l'agent, le persona, est souvent défini dans un "prompt" système et le second volet qui est un ensemble d'actions. Les actions sont la manière dont l'agent peut agir en dehors de lui-même et peuvent être générées manuellement ("prompt" décrivant une tâche et qui appelle une API pour obtenir/fournir des informations/actions à l'environnement), par rappel de la mémoire ou en suivant un plan élaboré par CoT.

Les agents IA peuvent être utilisé partout où l'automatisation des tâches est possible et acceptable socialement. Par exemple, en analyse des risques dans la chaîne d'approvisionnement, les agents d'IA peuvent collaborer dans un environnement multi-agents pour automatiser et optimiser les processus de prise de décision, notamment en matière d'analyse des risques. Dans un tel système, les agents peuvent avoir des rôles spécialisés (comme un coordonnateur ou un gestionnaire) et communiquer entre eux pour mieux comprendre le contexte et parvenir à une décision ou une action finale. Ce cas d'utilisation a été documenté précisément dans l'article Medium "AI Multi-Agents: automate risk analysis".

L'année 2025 marque un tournant pour l'ère des agents IA. Les besoins en automatisation intelligente dans l'industrie sont devenus le fer de lance de l'économie capitaliste. Tout le monde des affaires veut investir dans ce domaine tant il apparaît être le pilier de la prochaine révolution industrielle. A la croisée entre l'IA générative, la robotisation et l'architecture logicielle, les agents IA bouleversent notre rapport au travail et soulèvent des questions éthiques et écologiques.




Fig. 2.18. Architecture des agents IA

2.5.1. Architecture des agents IA

Un agent IA est un système complexe doté de composantes qui travaillent ensemble pour lui permettre d'atteindre ses objectifs. La figure 2.18 illustre ces composantes qui peuvent être divisées en cinq grandes catégories : le profil et la personnalité, la planification et la rétroaction, les actions et outils, le raisonnement et l'évaluation, ainsi que les connaissances et la mémoire.

Profil et personnalité :

- Le profil d'un agent décrit son rôle, les tâches qu'il doit accomplir et les outils dont il a besoin. Il peut être généré de diverses manières : manuellement, à l'aide d'un LLM, ou par des techniques axées sur les données. Aujourd'hui le cœur, ou plutôt le moteur des agents, est surtout propulsé par des LLM.

- La personnalité guide l’agent dans ses réponses, son comportement et la manière d’accomplir les tâches. Elle inclut des éléments comme le contexte et des informations sociodémographiques. Le profil et la personnalité permettent de définir l’objectif, le rôle et les contraintes de l’agent. Ces éléments influencent la façon dont l’agent interagit avec son environnement et avec les autres agents.

Planification et rétroaction :

- La planification est un outil essentiel pour la réalisation des objectifs d’un agent. Les agents utilisent la planification pour décomposer des tâches complexes en sous-tâches plus simples. La planification peut être séquentielle ou hiérarchique. La planification peut se faire sans rétroaction, où l’agent prend des décisions indépendantes, ou avec rétroaction, où l’agent surveille et ajuste ses plans en fonction des informations reçues.
- La rétroaction peut être environnementale, humaine ou générée par un modèle de langage. Les boucles de rétroaction permettent d’affiner les plans, ce qui améliore la capacité de l’agent à résoudre des problèmes complexes.

Actions et outils :

- Les actions **représentent les fonctions et les outils que l’agent peut utiliser pour accomplir des tâches.** Elles sont les moyens par lesquels l’agent interagit avec son environnement. Les actions peuvent être classées en trois types : l’exécution de tâches, l’exploration et la communication.
- Les outils sont des fonctions spécialisées qui permettent à l’agent d’obtenir de l’information externe ou d’effectuer des actions, par exemple en accédant à des API. Les outils doivent être spécifiques et en petit nombre pour éviter que l’agent ne soit confus.

Raisonnement et évaluation :

- Le raisonnement est la capacité d’un agent à analyser et à comprendre un problème pour trouver une solution. Les techniques de raisonnement sont les mêmes que l’on trouve dans les articles liés aux LLM et incluent le chain of thought prompting (CoT), le zero-shot CoT prompting et le chaînage d’incitation étape par étape (voir la section 2.4.5).

- L'évaluation permet à l'agent de vérifier la qualité de ses solutions. Les agents peuvent évaluer leurs stratégies de raisonnement et ajuster leurs approches pendant l'inférence.
- Les systèmes de raisonnement et d'évaluation permettent à l'agent d'améliorer sa prise de décision.

Mémoire et connaissance :

- La mémoire permet à l'agent d'accumuler de l'expérience, d'évoluer et de se comporter de manière plus efficace. Elle stocke des informations perçues de l'environnement. La mémoire peut être à court terme, comme l'information contenue dans la fenêtre contextuelle d'un LLM, ou à long terme, comme une base de données vectorielle.
- La connaissance et la mémoire servent à annoter le contexte avec les informations les plus pertinentes, tout en limitant le nombre de jetons utilisés avec le LLM.

Il existe deux grands types d'agents IA, chacun ayant ses propres caractéristiques et capacités :

- Assistants : ces agents sont souvent utilisés pour des tâches spécifiques, fournissant une assistance à l'utilisateur. Ils peuvent avoir des profils prédéfinis et des actions limitées.
- Agents autonomes : ces agents peuvent prendre des décisions de manière indépendante et interagir avec leur environnement sans intervention humaine directe. Ils ont souvent des capacités de planification et d'adaptation plus avancées. Des agents sont orientés sur les objectifs et agissent pour atteindre ceux-ci, et d'autres sont basés sur l'utilité et évaluent les conséquences de leurs actions pour maximiser une fonction d'utilité.

L'architecture d'un agent IA est complexe et comporte des facettes, elle dépend des objectifs et du contexte d'utilisation. Une bonne compréhension de toutes ces composantes permet de concevoir des agents plus efficaces et plus pertinents.

2.5.2. Systèmes multi-agents

Dans les systèmes multi-agents, plusieurs agents travaillent ensemble pour résoudre un problème complexe. Ces agents peuvent avoir des rôles et des responsabilités différents et

ils peuvent collaborer pour atteindre un objectif commun.

Une architecture multi-agent inclut :

- Agents collaboratifs: ils travaillent ensemble sur différentes parties d'une tâche, partageant leur progrès pour atteindre un résultat unifié.
- Agents avec des rôles spécifiques: les agents se voient attribuer des tâches spécifiques pour lesquelles ils ont une expertise. Un planificateur peut générer une équipe d'agents avec des rôles distincts afin de pouvoir réaliser des tâches complexes.
- Communication et coordination : les agents doivent communiquer et se coordonner pour échanger des informations, aligner leurs actions, parvenir à des accords et s'adapter à l'environnement. Les agents peuvent utiliser des outils de communication pour interagir et collaborer, même avec des contraintes de sécurité.
- Raffinement de plan : les plans peuvent être affinés grâce à la collaboration et à la rétroaction entre les agents. Le raffinement de plan peut se faire individuellement (auto-raffinement ou plus communément appelé ReAct qui signifie "Reasoning and Acting") ou par collaboration entre plusieurs agents.

Les systèmes multi-agents offrent des avantages tels que la possibilité d'effectuer plusieurs tâches en parallèle et de fournir une rétroaction et une évaluation.

2.5.3. Cadres multi-agents

Des cadres ont été développés pour faciliter la création de systèmes multi-agents, chacun avec ses propres caractéristiques, avantages et inconvénients. Voici une description des cadres les plus populaires, tels qu'AutoGen [41], CrewAI [15], LangChain [12] et LangGraph [35] :

- **AutoGen** est un cadre open-source développé par Microsoft, conçu pour simplifier la création d'applications basées sur des systèmes multi-agents. Il permet la collaboration entre plusieurs agents afin de résoudre des tâches complexes. Il met l'accent sur la conversation entre agents comme moyen d'améliorer le résultat final. Les agents peuvent échanger des informations, s'auto-critiquer et améliorer leur travail en fonction des commentaires des autres agents. AutoGen offre une grande flexibilité et permet aux développeurs de définir les capacités des agents, leurs interactions et leurs modes de communication. Les agents peuvent être construits en utilisant des

LLM, des outils ou des interventions humaines. AutoGen est considéré comme particulièrement adapté aux tâches de développement logiciel, notamment la génération de code. Parmi les limitations, il y a la complexité du support pour les LLM open source et le fait qu'il soit parfois plus comme une application qu'un cadre.

- **CrewAI** est un cadre axé sur la collaboration et la coordination entre agents autonomes. Il met l'accent sur la création d'équipes d'agents (des crews) avec des rôles et des responsabilités spécifiques. Il permet d'orchestrer les actions des agents de manière séquentielle ou hiérarchique. CrewAI est conçu pour les applications d'entreprise, il est plus robuste et moins extensible qu'AutoGen. Les agents dans CrewAI ont une personnalité (backstory), un objectif (goal) et une mémoire. Il offre une bonne intégration avec LangChain, ce qui permet d'intégrer de nombreux outils et de supporter les modèles open source. CrewAI se distingue par sa structure plus rigide que celle d'AutoGen, ce qui permet un meilleur contrôle des comportements des agents. AgentOps [2] est une plateforme d'observabilité qui peut être utilisée avec CrewAI pour surveiller les interactions, l'efficacité et les coûts. CrewAI est souvent considéré comme un cadre rapide à mettre en place, intuitif et adapté aux démonstrations.
- **LangChain** est une bibliothèque qui offre un ensemble d'outils pour la création d'applications basées sur les LLM. Il ne s'agit pas à proprement parler d'un cadre pour les systèmes multi-agents, mais plutôt d'un cadre qui fournit les briques de base pour créer des agents. Il est souvent utilisé avec d'autres cadres comme CrewAI. LangChain permet de créer des agents en leur donnant accès à des outils et en leur fournissant une mémoire pour qu'ils puissent accumuler de l'expérience. LangChain est doté d'une vaste gamme d'outils, d'une interface utilisateur complète et prend en charge divers scénarios d'agents.
- **LangGraph** est un cadre plus récent qui offre une grande flexibilité pour la création de flux de travail multi-agents. Il permet de connecter les agents de manière flexible afin de s'adapter à des tâches complexes. Chaque agent peut avoir ses propres paramètres (LLM, outils, instructions) ce qui permet une grande personnalisation des interactions entre agents. Il permet de définir des agents indépendants et de spécifier comment ils sont connectés. LangGraph est considéré comme un cadre polyvalent, capable de gérer tout type de tâches multi-agents. Il est construit sur LangChain et permet de définir les agents et la manière dont ils interagissent. Les agents peuvent échanger des informations et se coordonner grâce à la mise en place de communications spécifiques.

Le choix du cadre approprié pour la construction de systèmes multi-agents dépendra des exigences spécifiques du projet, de la complexité de la tâche, du niveau de contrôle souhaité, des outils nécessaires et de l'expérience des développeurs. Chaque cadre a ses forces et ses faiblesses, et il est important de les évaluer attentivement avant de prendre une décision. On retiendra que :

- AutoGen est souvent préféré pour les tâches complexes de programmation, notamment la génération de code.
- CrewAI est un choix plus approprié pour les démonstrations ou les tâches qui nécessitent la création rapide d'agents, car il est rapide à mettre en place et intuitif.
- LangGraph est très flexible et peut être utilisé pour tout type de tâche multi-agents.

2.5.4. Cas d'utilisation des agents IA

Voici quelques exemples qui démontrent la variété des applications potentielles des agents IA, allant de tâches très spécialisées à des fonctions plus générales d'assistance aux humains :

- **Rédaction de contenu** : les agents IA peuvent être utilisés pour générer divers types de contenu créatif, tels que des articles, des billets de blog, des scripts et des textes publicitaires. Ils peuvent en outre être utilisés pour générer des résumés d'articles. Un agent peut également servir d'assistant de rédaction, capable de trouver de nouvelles pistes de recherche pour les scientifiques en sciences sociales.
- **Recommandations d'hôtels** : des agents peuvent être développés pour fournir des recommandations d'hôtels, en analysant les préférences des utilisateurs et en accédant à des informations externes telles que des listes d'hôtels et des avis. Toutefois, les outils utilisés pour obtenir ces informations peuvent parfois rencontrer des erreurs, ce qui souligne l'importance de construire des outils robustes et fiables pour les agents.
- **Développement de logiciels** : les systèmes multi-agents peuvent être appliqués au développement de logiciels, où différents agents jouent des rôles spécifiques comme chef de produit, architecte et ingénieur. Ils peuvent communiquer et collaborer pour réaliser des tâches complexes comme la génération de code, ou pour effectuer du débogage.
- **Analyse de données** : les agents peuvent analyser des données, incluant des données de sites Web, des fichiers CSV, ou des bases de données. Les agents peuvent utiliser divers outils pour extraire et traiter des informations provenant de sources variées, et peuvent générer des visualisations.

- **Recherche scientifique** : les agents peuvent assister les chercheurs dans de nombreuses tâches, incluant la rédaction de résumés, l'extraction de mots-clés, et l'élaboration de scripts pour des études. Des agents peuvent également être utilisés pour formuler des questions de recherche, explorer le Web pour amasser des données, résumer des sources et regrouper les résumés.
- **Service à la clientèle** : les agents peuvent fournir du soutien à la clientèle, répondre aux questions, résoudre les problèmes et offrir de l'information 24/7.
- **Traduction et localisation** : les agents peuvent offrir des services de traduction pour différents types de contenus, facilitant la communication entre les langues et localisant le contenu pour différentes régions.
- **Environnements simulés** : les agents peuvent être utilisés dans des environnements simulés pour l'exploration, comme dans le jeu Minecraft ou des simulations sociales et épidémiques, ou encore des environnements de type boutique en ligne. Dans ces environnements, les agents peuvent interagir avec leur environnement, explorer de nouvelles compétences, et adapter leurs stratégies en fonction des retours qu'ils reçoivent.
- **Tâches de la vie quotidienne** : les agents peuvent réaliser de nombreuses tâches de la vie quotidienne comme la prise de rendez-vous, la gestion de calendriers, etc..
- **Éducation** : les agents peuvent offrir du soutien aux étudiants en leur fournissant de l'aide pour l'inscription, ou en leur offrant un soutien personnalisé.

2.5.5. Évaluation des agents IA

L'évaluation des agents IA est un domaine crucial, car elle permet de mesurer l'efficacité et la fiabilité de ces systèmes. Les méthodes d'évaluation se divisent généralement en deux grandes catégories : les méthodes subjectives et les méthodes objectives.

Les méthodes d'évaluation subjectives reposent sur le jugement humain. Elles sont particulièrement utiles dans les situations où il est difficile d'établir des métriques quantitatives, par exemple, pour évaluer la convivialité d'un agent.

Deux stratégies couramment utilisées pour l'évaluation des agents IA sont :

- L'annotation humaine [68], où des évaluateurs humains attribuent des scores ou des classements aux réponses générées par les agents. Les évaluateurs peuvent se baser sur divers critères, tels que l'utilité, la fiabilité, l'exactitude et le niveau de détail.
- Le test de Turing adapté aux agents [72], où des évaluateurs humains doivent déterminer si les résultats proviennent d'un agent ou d'un humain. Si les évaluateurs

ne parviennent pas à distinguer les résultats de l’agent de ceux de l’humain, cela indique que l’agent atteint un niveau de performance similaire à celui de l’humain.

L’évaluation subjective est essentielle, car elle reflète les critères humains, cependant, elle peut être coûteuse, inefficace et affectée par des biais. Pour remédier à ces problèmes, de plus en plus de recherches explorent l’utilisation des modèles de langage eux-mêmes comme intermédiaires pour mener des évaluations subjectives.

Les méthodes d’évaluation objectives utilisent des métriques quantitatives pour mesurer les capacités des agents. Ces métriques permettent d’obtenir des informations concrètes et mesurables sur la performance de l’agent. Les métriques, qui doivent refléter avec précision la qualité des agents. Les métriques courantes incluent le taux de succès de la tâche, les récompenses/scores, la couverture, la précision, ainsi que les mesures de similarité avec l’humain et l’efficacité.

L’évaluation objective fournit des informations essentielles qui complètent l’évaluation subjective. Les deux approches sont importantes et peuvent être combinées pour obtenir une évaluation plus complète.

En résumé, les méthodes d’évaluation subjective mettent l’accent sur le jugement humain, tandis que les méthodes objectives utilisent des mesures quantitatives. Les deux approches ont leurs forces et leurs faiblesses, et leur combinaison peut être la clé d’une évaluation complète des agents IA.

2.5.6. Tendances actuelles et orientations futures

Les tendances actuelles et les orientations futures en matière d’agents d’IA montrent une évolution rapide vers des systèmes plus autonomes, polyvalents et intégrés dans divers aspects de la société. Les agents IA génératifs, encore à leurs débuts, suscitent un grand intérêt en raison de leur capacité à passer de simples systèmes basés sur la connaissance à des applications axées sur l’action, intégrant des modèles LLM pour des interactions plus dynamiques et des tâches plus complexes.

L’accent est mis sur l’explicabilité et la responsabilité, avec des innovations telles que les systèmes open source conçus pour enseigner aux robots des tâches quotidiennes, répondant à des problèmes réels avec une attention particulière à la transparence et à l’éthique.

Les recherches se concentrent sur l'équipement des LLM avec des capacités humaines telles que la mémoire et la planification, permettant des comportements plus humains et une exécution efficace des tâches.

Les systèmes multi-agents sont de plus en plus considérés comme une approche prometteuse pour relever les défis liés à l'automatisation des tâches sans valeur ajoutée mais nécessitant des capacités avancées. Les agents deviennent de plus en plus autonomes et capables d'adapter leurs comportements aux tâches et aux environnements, avec des approches comme AutoFlow visant à automatiser la génération de flux de travail, réduisant ainsi le besoin d'intervention humaine.

Les orientations futures mettent l'accent sur l'amélioration des capacités de raisonnement et de planification, explorant des techniques comme le « Tree of Thought » (ToT) [75] pour améliorer la capacité des modèles à évaluer et à choisir des actions. En effet, le Tree of Thought (ToT) est une méthode de raisonnement pour les LLM qui simule un processus de réflexion arborescent. Contrairement au Chain of Thought (CoT, voir la section 2.4.5) qui suit un raisonnement linéaire, le ToT permet au modèle d'explorer plusieurs branches de raisonnement simultanément, d'évaluer différentes possibilités, et de revenir en arrière si une voie s'avère improductive. Cette approche est particulièrement efficace pour résoudre des problèmes complexes nécessitant une planification stratégique, comme les puzzles logiques ou les jeux de stratégie.

Le développement de modules de mémoire robustes, explorant différentes formes de mémoire, est essentiel pour permettre aux agents de conserver et d'utiliser l'information lors de différentes étapes d'une tâche.

La prise de décision évolue vers des processus plus délibérés impliquant l'évaluation de plusieurs options, tandis que les méthodes d'apprentissage continu permettent aux agents d'améliorer leurs performances au fil du temps, utilisant des mécanismes de rétroaction pour adapter les performances en fonction de données en temps réel.

Le concept d'agents en tant que service, intégrant des agents d'IA dans divers environnements de travail, est à l'étude, avec des plateformes facilitant la création et le déploiement d'agents personnalisés.

Enfin, les recherches se concentrent sur la compréhension des comportements et des personnalités des agents IA, ainsi que sur l'analyse de leurs interactions dans des environnements sociaux simulés. Ces tendances révèlent un intérêt croissant pour des agents IA plus polyvalents, autonomes et capables de s'adapter à diverses tâches et environnements, avec des progrès essentiels dans les domaines de la planification, du raisonnement, de la mémoire et de la prise de décision pour évoluer vers des systèmes plus efficaces et fiables.

Néanmoins, un article récent intitulé "Fully Autonomous AI Agents Should Not Be Developed" [42] discute des dangers potentiels des agents IA entièrement autonomes. Ces agents peuvent décomposer des objectifs en sous-tâches et les exécuter sans aucune intervention humaine. L'article souligne que peu d'études se sont penchées sur les risques des agents IA, notamment les attaques malveillantes lorsqu'ils naviguent sur le web. Les systèmes autonomes peuvent commettre des erreurs catastrophiques même pour des raisons triviales.

Pour atténuer les risques, les auteurs de l'article proposent :

- L'adoption de niveaux clairs d'autonomie des agents.
- Le développement de mécanismes de contrôle humain robustes (surveillance en temps réel, audits, interruption forcée, ...).
- La création de méthodes pour vérifier que les agents IA restent dans les paramètres opérationnels prévus. Ce point est précisément l'objet même de ce mémoire dans le cadre de l'utilisation d'agents autonomes en RH.

Bien que l'autonomie accrue puisse offrir des avantages, le jugement humain reste indispensable, surtout pour les décisions à fort enjeu.

Pour conclure cette partie théorique, nous consacrons une section aux développements les plus récents dans le domaine de l'IA générative. Dans un contexte en constante évolution, marqué par une cadence soutenue de publications et d'annonces technologiques, il devient nécessaire de documenter les avancées en cours, même si celles-ci ne peuvent être pleinement intégrées aux expérimentations de ce mémoire. Ce chapitre vise ainsi à offrir une photographie actualisée de l'état de l'art, en complément du cadre établi précédemment.

2.6. Derniers développements

L'IA générative (GenAI) dont relève les LLM est en pleine effervescence. Les publications d'articles scientifiques et les annonces des principaux acteurs du marché pleuvent et inondent nos notifications à chaque jour. Dans ces conditions, il est parfois difficile d'arrêter l'écriture d'un mémoire au risque d'être déjà dépassé. Ce chapitre tente donc de combler l'écart entre l'actualité et le besoin de figer la rédaction de ce mémoire ainsi que les expérimentations. Les derniers développements concernant les LLM et les agents IA seront consignés dans ce chapitre sans pour autant être pris en compte dans les expérimentations réalisées.

Le phénomène "DeepSeek R1" [17] est venu ébranler la communauté de la GenAI au début 2025. Pour aborder ce sujet, "DeepSeek" et l'évolution des modèles de raisonnement, il convient au préalable d'introduire 2 concepts : la distillation et la loi d'échelle standard.

La distillation est cruciale car elle explique comment DeepSeek a pu créer des modèles performants à moindre coût. Cette technique permet de transférer les connaissances d'un modèle large et coûteux (l'enseignant) vers un modèle plus petit et efficace (l'étudiant). Ainsi, "DeepSeek" a réussi à rivaliser avec des modèles beaucoup plus volumineux tout en utilisant moins de ressources computationnelles.

La loi d'échelle standard représente le paradigme dominant que "DeepSeek" a remis en question. Cette loi stipule que la performance des modèles LLM s'améliore de manière prévisible avec l'augmentation de la taille du modèle, des données d'entraînement et de la puissance de calcul. L'approche de "DeepSeek" a démontré qu'il était possible d'obtenir des performances comparables sans suivre cette progression linéaire.

2.6.1. La distillation

Comme nous l'avons montré dans ce chapitre, les LLM puissants et généralistes sont souvent de grandes tailles, ce qui limite leur accessibilité et leur utilisation pratique. Ce sont souvent des modèles fermés offerts avec un abonnement ou un coût à l'utilisation pour les versions avec API. Le constat que tout étudiant à la maîtrise peut faire lorsqu'il travaille avec ces modèles, est que cela peut vite devenir coûteux pour de simples interrogations (prompt) dans le cadre d'expérimentations et encore plus s'il fallait "fine-tuner" le modèle.

Pour palier ces inconvénients, la distillation est une solution avantageuse pour apprendre à un modèle plus petit (SML) à être autant efficace qu'un grand modèle mais dans un domaine ciblé. Le grand modèle est alors l'enseignant qui doit transférer une partie de sa

connaissance vers le modèle étudiant, le plus petit en taille. Le modèle étudiant est entraîné à imiter le "comportement" du modèle enseignant. L'objectif est que le modèle étudiant reproduise les performances du modèle enseignant tout en étant plus petit et plus efficace. Sans rentrer dans le détail, une des approches pour la distillation consiste à faire générer par l'enseignant un jeu de données synthétiques sur lequel l'étudiant est entraîné. On évite le coût de production d'un jeu de données étiquetées par des humains et on transfère de cette manière la connaissance de l'un vers l'autre. Une autre approche consiste à apprendre au modèle étudiant à prédire les mêmes probabilités de sortie que le modèle enseignant, au lieu d'apprendre directement à partir des données d'entraînement étiquetées.

Cependant cette distillation "traditionnelle" copie en quelque sorte les "comportements" de surface des grands modèles, souvent au détriment de la profondeur de compréhension. Une méthode appelée "Distilling Step-by-Step", développée par des chercheurs de Google [28], qui se distingue par son approche innovante, vient combler cette lacune. Cette méthode ne se contente pas de copier les sorties des grands modèles, mais extrait également les raisonnements sous-jacents à ces sorties, permettant ainsi aux modèles plus petits d'apprendre non seulement les réponses, mais également le processus de réflexion. Le processus se déroule en deux étapes :

- Extraction des raisonnements : utilisation de la technique CoT (Chain-of-Thought, voir la section 2.4.5) pour obtenir des explications étape par étape des LLM. L'enseignant produit un jeu de données synthétiques comprenant le triplet question, raisonnement sous forme de CoT, réponse.
- Entraînement multi-cibles : l'étudiant est entraîné à la fois pour prédire les réponses et pour générer des raisonnements. L'objectif global est de minimiser l'écart sur les 2 cibles.

Les expériences réalisées par le groupe de chercheurs de Google montrent que les modèles distillés avec cette méthode peuvent surpasser les grands modèles sur des benchmarks, tout en étant beaucoup plus petits et plus efficaces.

2.6.2. La loi d'échelle standard

La loi d'échelle standard, issue de l'article de Kaplan et Al. [34], suggère que les performances d'un modèle s'améliorent généralement avec l'augmentation de sa taille (nombre de paramètres) et la quantité de données d'entraînement. Cela signifie que plus un modèle est grand et entraîné sur une grande quantité de données, meilleures seront ses

performances sans toutefois suivre une loi linéaire mais plutôt une loi logarithmique. Les gains de performance diminuent à mesure que la taille du modèle et la quantité de données augmentent. L'article conclue donc qu'il est préférable d'entraîner des modèles très grands sur une quantité de données relativement modeste (toute proportion gardée) et de stopper l'entraînement bien avant la convergence pour une efficacité optimale.

C'est ce qui a gouverné les grands acteurs du marché du LLM jusqu'en 2024 : faire des modèles de plus en plus gros et les entraîner sur des jeux de données conséquents. Cependant, cette approche a également suscité des critiques en raison de son impact environnemental et de la nécessité de trouver des solutions plus durables.

L'accent est désormais mis davantage sur les capacités de réflexion des modèles plutôt que sur leur simple taille. Cette approche privilégie l'optimisation des processus d'inférence au lieu de se concentrer uniquement sur la phase d'apprentissage. Les modèles de réflexion (reasoning models) permettent d'améliorer grandement les performances sans nécessairement augmenter le nombre de paramètres, en intégrant des mécanismes qui simulent un raisonnement étape par étape ou une sorte de délibération interne avant de produire une réponse. C'est assez anthropologique cette analogie mais elle semble vérifiée dans les études. Cette "révolution" marque un tournant important dans le développement des LLM.

2.6.3. Le phénomène DeepSeek

DeepSeek R1 [17] est un modèle LLM développé par une entreprise chinoise (fondée en mai 2023) et publié en janvier 2025. Il se distingue par sa capacité à "penser" sans supervision humaine, grâce à un entraînement sur des problèmes vérifiables automatiquement et une méthode d'apprentissage par renforcement. L'utilisation de "test-time compute" [58], un processus qui permet au modèle de raisonner et d'explorer des solutions avant de répondre, est au cœur du succès de ce modèle.

Le concept de test-time compute peut être illustré par l'analyse d'un CV pour un poste de développeur. Avec une approche standard à faible compute, le modèle génère directement : "Ce candidat semble qualifié pour le poste. Expérience pertinente en développement web avec JavaScript" en environ 2 secondes, produisant une analyse superficielle.

En revanche, avec un "test-time compute" élevé, le modèle effectue une analyse en plusieurs étapes sur environ 20 secondes :

- Analyse des compétences techniques détaillée (frameworks spécifiques, niveau d'expertise)
- Évaluation de la progression professionnelle sur les 3 années d'expérience
- Examen approfondi des projets e-commerce (complexité, technologies utilisées)
- Identification des lacunes techniques (tests, outils modernes, méthodologies)
- Formulation de recommandations pour l'entretien
- Évaluation finale nuancée avec plan de formation

Cette approche produit une analyse détaillée et actionnable, similaire à un recruteur expérimenté qui prend le temps d'examiner chaque détail, contrairement à un tri rapide superficiel. Le principe fondamental reste le même : plus de temps de calcul alloué permet un raisonnement plus approfondi et des conclusions plus précises.

Cette technique, auparavant maîtrisée principalement par OpenAI avec son modèle o1 mais dont on n'avait pas le détail de fonctionnement, DeepSeek a réussi à la reproduire de manière indépendante avec des coûts nettement inférieurs. Ce qui est intéressant dans leur approche, c'est que l'apprentissage s'est concentré sur le raisonnement plutôt que sur les connaissances. Le modèle a appris, ou plutôt découvert, des stratégies de raisonnement dès le départ.

DeepSeek a utilisé la distillation pour transférer les capacités de raisonnement de ses modèles plus grands vers des modèles plus petits et plus efficaces. Ce processus améliore considérablement les capacités de raisonnement des modèles plus petits. Même le plus petit modèle distillé (Qwen 1.5 G), surpasse les modèles plus grands qui ne sont pas axés sur le raisonnement. Ils ont mis au point une technique d'apprentissage par renforcement qui permet aux modèles de s'améliorer par le calcul au moment de l'inférence ("test-time compute") et viennent donc contraindre la loi d'échelle standard (ce chemin ayant été déjà tracé par OpenAI avec o1).

Le « test-time compute » fait référence à l'augmentation de la puissance de calcul utilisée lors de l'inférence. Ces modèles de raisonnement sont moins performants en temps de réponse que les LLM standard, mais ils améliorent les capacités de raisonnement d'un LLM.

2.7. Conclusion

Ce chapitre a permis d'établir un panorama complet des fondements théoriques et technologiques nécessaires à notre recherche sur la détection de biais dans les entrevues de

recrutement. L’analyse des concepts clés révèle plusieurs enseignements cruciaux pour la suite de nos travaux.

Synthèse des apports conceptuels

L’examen des processus de recrutement traditionnels révèle leur complexité intrinsèque et la multiplicité des acteurs impliqués. Cette diversité, illustrée par l’exemple de Moov.AI, montre que chaque organisation développe ses propres pratiques, créant autant d’opportunités d’introduction de biais. Les huit types de biais inconscients identifiés dans la littérature (affinité, conformité, confirmation, beauté, halo/cornes, contraste, attribution et nom) constituent un cadre d’analyse robuste pour comprendre les mécanismes de discrimination dans le recrutement.

L’analyse de l’équité de genre démontre que les inégalités dans le monde du travail résultent de mécanismes subtils mais persistants, s’enracinant dès le plus jeune âge et se perpétuant à travers les choix d’orientation et les pratiques de recrutement. Ces constats soulignent l’importance d’une approche systémique pour détecter et corriger les biais.

Justification technologique de l’approche

L’évolution des LLM, depuis les modèles probabilistes jusqu’aux architectures Transformer modernes, a ouvert de nouvelles possibilités pour l’analyse automatisée du langage naturel. Les capacités émergentes des LLM, notamment le *few-shot learning* et le *chain-of-thought reasoning*, en font des outils particulièrement adaptés à l’analyse des subtilités linguistiques présentes dans les entretiens de recrutement.

Cependant, les limitations identifiées (hallucinations, biais hérités des données d’entraînement, sensibilité aux prompts) renforcent la nécessité d’une approche multi-agents pour assurer une analyse fiable et robuste. Les agents IA, par leur capacité à combiner mémoire, raisonnement et actions coordonnées, offrent un cadre architectural approprié pour développer des systèmes de détection de biais sophistiqués et transparents.

Implications pour la détection de biais

La convergence des enjeux d’équité identifiés et des capacités technologiques des LLM et agents IA dessine un contexte favorable au développement de solutions automatisées

de détection de biais. Les techniques de distillation et les récents développements comme DeepSeek R1 montrent que des modèles performants peuvent être développés de manière plus économique et durable.

Néanmoins, les avertissements concernant l'autonomie excessive des agents IA soulignent l'importance de maintenir un contrôle humain approprié, particulièrement dans le domaine sensible des ressources humaines où les décisions ont des impacts directs sur les individus et les organisations.

Transition vers l'implémentation

Ce cadre conceptuel et technologique établit les bases nécessaires pour développer une approche méthodologique rigoureuse. Les concepts d'équité, les typologies de biais, les capacités et limitations des LLM, ainsi que les architectures multi-agents constituent autant d'éléments qui guideront la conception de notre système de détection.

Le chapitre suivant s'appuiera sur ces fondements pour définir notre approche méthodologique, détailler la constitution du jeu de données et établir les stratégies de validation qui permettront d'évaluer l'efficacité de notre solution dans la détection de biais lors d'entrevues de recrutement simulées.

Chapitre 3

Approche et méthodologie

Ce chapitre présente l’approche méthodologique adoptée pour développer un système de détection de biais dans les entretiens de recrutement utilisant des agents IA. Fort des fondements théoriques établis au chapitre précédent, nous détaillons ici les choix méthodologiques et les stratégies opérationnelles qui guideront la conception et l’évaluation de notre solution.

La problématique centrale de ce travail réside dans l’absence de jeux de données publics contenant des transcriptions d’entretiens de recrutement, particulièrement en français. Cette contrainte majeure nous amène à développer une approche innovante basée sur la génération automatique de données synthétiques par des agents IA spécialisés.

La première partie de ce chapitre expose notre stratégie de création d’un jeu de données synthétiques. Nous y décrivons l’architecture multi-agents conçue pour générer des conversations réalistes entre candidats et recruteurs virtuels. Cette architecture comprend six types d’agents IA distincts, chacun ayant un rôle spécifique dans la chaîne de production : de la recherche automatique d’offres d’emploi à l’audit final des entretiens, en passant par la création de profils candidats et la simulation d’interactions biaisées.

La seconde partie présente les stratégies de validation de notre agent IA Auditeur EDI, composante centrale de notre système de détection. Nous y définissons les critères de performance attendus et les méthodologies d’évaluation qui permettront de mesurer l’efficacité de notre approche. Les stratégies proposées couvrent différents scénarios d’analyse, depuis l’examen d’échanges isolés jusqu’à la comparaison croisée de conversations multiples.

Cette approche méthodologique vise à répondre aux défis techniques et éthiques liés à l’automatisation de la détection de biais, tout en respectant les contraintes de confidentialité

inhérentes au domaine du recrutement. Elle s’appuie sur les capacités émergentes des LLM et des systèmes multi-agents pour créer un environnement d’expérimentation contrôlé et reproductible.

3.1. Création d’un jeu de données synthétiques

Il n’existe pas de jeux de données publiques portant sur des transcriptions d’entrevues de recrutement. Cela peut se comprendre en raison du caractère confidentiel de ces échanges qui ont lieu dans la sphère privée d’une rencontre entre un candidat et un recruteur. Des jeux de données d’entrevues générales sont par contre disponibles. On peut citer «A Large-Scale Open-Source Corpus of Media Dialog» [39] qui rassemble plus de 100 000 conversations extraites d’entrevues radiophonique du réseau NPR (National Public Radio) aux États-Unis. En outre, la section «Recruiting Data» du site datarade.ai regroupe divers jeux de données spécialisés pour le recrutement, incluant des notes d’entrevues, des formulaires de candidatures, des évaluations de compétences, et des historiques d’employés. Cependant, ces jeux de données sont généralement orientés vers l’analyse de CV et de données structurées de recrutement plutôt que des transcriptions textuelles d’entrevues de recrutement. De plus, la langue utilisée dans ces divers jeux de données est l’anglais.

Si l’on désire travailler sur un jeu de données textuelles d’entrevues de recrutement, et de surcroît en français, il va falloir le bâtir de toute pièce. Autrement dit, il nous faut générer automatiquement des échanges entre des candidats et des recruteurs virtuels. Cela va constituer une part importante de ce travail académique : créer un jeu de données synthétiques. Pour ce faire, nous disposons de la technologie d’IA générative. En effet, l’un des joyaux de l’IA générative est la famille des LLM (Large Language Model) qui permettent notamment de comprendre une question en langage naturel et de produire une réponse appropriée (le fonctionnement des LLM est détaillé dans le chapitre 2.4).

3.1.1. Stratégie pour générer le jeu de données synthétiques

Les LLM ont permis la création d’agents IA (on parle également d’agentique) capables de réaliser des tâches de manière quasi-autonome. L’agentique est un domaine de l’IA qui est très actif depuis le début de l’année 2024. Nous allons donc profiter de cette avancée dans le domaine de la recherche et créer des agents IA pour résoudre notre problématique de création d’un jeu de données synthétiques d’entrevues de recrutement.

Le choix d’agents IA spécifiques s’appuie sur l’architecture multi-agents présentée dans la section 2.5.2, qui démontre l’efficacité des systèmes où plusieurs agents collaborent avec




Fig. 3.1. Recherche et extraction des descriptions de postes

des rôles distincts pour résoudre des problèmes complexes. Cette approche correspond aux cas d'utilisation documentés dans l'état de l'art, notamment l'utilisation d'agents pour la recherche et l'analyse de données (agent de recherche de postes), la génération de contenu personnalisé (agents de création de profils et personas), et les environnements simulés d'interaction (agents candidat et recruteur). L'intégration d'un agent auditeur EDI répond aux préoccupations éthiques soulignées dans la littérature récente concernant l'explicabilité et la responsabilité des systèmes IA autonomes. Cette architecture multi-agents permet une décomposition claire des responsabilités tout en maintenant une capacité de collaboration entre les agents, conformément aux meilleures pratiques identifiées dans le framework CrewAI [15] que nous avons adopté pour l'implémentation.

Voici donc les différents agents IA sélectionnés pour générer, au final, un jeu de données pertinentes :

- (1) Agent IA de recherche de postes : cet agent génère automatiquement des descriptifs de postes selon la liste des métiers qu'on lui fournit et de ce qu'il a trouvé sur Internet dans des sites spécialisés d'annonces d'offres d'emploi. Il doit extraire les informations des descriptions de postes trouvés, les mettre en forme selon une spécification qui lui sera fournie et écrire le résultat dans la base de données des descriptions de poste à pourvoir. La figure 3.1 illustre ce processus entre les différentes entités.
- (2) Agent IA de création de profils de candidats : cet agent génère automatiquement des profils de candidats idéaux basés sur la description des postes à pourvoir. Il écrira




Fig. 3.2. Création des profils candidats et personas

ces profils dans la base de données des candidats. Un profil contient les informations suivantes :

- Formations académiques et certifications.
- Compétences techniques/métiers.
- Compétences humaines et relationnelles.
- Personna (qui sera complété par l'agent IA de rédaction de persona).

(3) Agent IA de création de persona : cet agent génère automatiquement la description de 2 types de persona :

- Persona pour les candidats selon le poste envisagé qui viendra compléter le profil des candidats dans la base.
- Persona pour les recruteurs selon une liste de stéréotypes (biais cognitifs) dans le but de décrire comment le biais se manifeste chez le recruteur. Cela viendra nourrir une base de données des recruteurs.

La figure 3.2 illustre cette génération de profils de candidats et de persona associés.

- (4) Agent IA Candidat : cet agent incarne le rôle d'un candidat dont le profil est pioché dans la base de données des candidats. Il est capable d'interagir lors d'une entrevue virtuelle avec un agent IA recruteur pour un poste issu de la base de données des descriptions de poste. Le résultat de cette interaction donnera une conversation qui viendra alimenter le jeu de données des entrevues synthétiques de recrutement.
- (5) Agent IA Recruteur : cet agent incarne le rôle d'un recruteur dont le profil est quant à lui pioché dans la base de données des recruteurs. On peut le forcer à être biaisé ou pas (c'est à dire activer ou pas son biais cognitif). Il est capable d'interagir lors d'une entrevue virtuelle avec un agent IA candidat pour un poste issu de la base de données des descriptions de poste. Le résultat de cette interaction donnera une conversation qui viendra alimenter le jeu de données des entrevues de recrutement.
- (6) Agent IA Auditeur EDI (Équité, Diversité et Inclusion) : cet agent est chargé d'inspecter les entrevues de recrutement, de détecter les biais et déterminer si le recruteur




Fig. 3.3. Interaction d’entrevue et audit




Fig. 3.4. Structure des «prompts» pour les agents IA

était biaisé lors de l’échange. La figure 3.3 illustre cette interaction entre candidat, recruteur et auditeur.

Le coeur de chaque agent IA est basé sur un LLM. Pour faire converser 2 agents IA, par exemple un candidat et un recruteur, il faut une structure de «prompt». Le «prompt» est en quelque sorte ce que l’on demande au LLM de générer comme texte. Il faut donc un modèle de «prompt» pour chaque «personna» (candidat, recruteur, mais aussi pour auditeur, rédacteur, ou tout autre agent IA que l’on souhaitera définir). La structure générale des «prompts» pour notre projet est illustré par la figure 3.4.

Prenons le cas de l'échange entre l'agent IA candidat et l'agent IA recruteur. Pour l'agent IA recruteur, nous devons lui indiquer son rôle dans le «prompt» : par exemple, tu es un recruteur qui travaille pour une entreprise de commerce d'articles de sports.

Nous devons également lui donner son objectif : par exemple, tu dois recruter un.e responsable commercial.e qui sera amené.e à développer une nouvelle branche de produits de sports.

Nous devons également lui préciser la manifestation de son biais le cas échéant : par exemple, tu penses que les femmes sont moins bonnes commerciales que les hommes en particulier dans la clôture d'une vente.

Nous devons en outre lui rappeler les échanges précédents (c'est la mémoire de ce qui s'est déjà dit) et l'inviter à formuler la suite du dialogue sous forme de texte (la réponse à la dernière question du candidat par exemple).

Ainsi de suite, en alternant les échanges entre l'agent IA candidat et l'agent IA recruteur, chacun avec son «prompt» dédié, nous voulons créer une conversation fictive, mais néanmoins réaliste, d'une entrevue de recrutement. La figure 3.5 illustre une conversation générée entre un agent IA recruteur et un agent IA candidat pour un poste d'avocat spécialisé en droit du travail.

Nous envisageons de considérer les spécifications suivantes pour la création des entrevues virtuelles et cela aura un impact sur les choix d'implémentation des agents IA :

- Les entrevues sont des transcriptions textuelles et en français.
- Les entrevues sont limitées à quelques échanges (par exemple 5 allers et 5 retours entre le recruteur et le candidat).
- La personne qui s'exprime est clairement identifiable dans les échanges entre les 2 parties.
- Les entrevues sont accompagnées d'informations permettant de les exploiter facilement. Sans être exhaustive, voici une liste des informations minimalement requises : identifiant unique, poste ciblé, profil et persona du candidat, profil et persona du recruteur, stéréotype ciblé, biais activé ou non, type d'agents IA utilisés, stratégie d'injection du biais, date de création, durée de la génération de la conversation.

Candidat : Bonjour, je viens pour le poste d'avocat spécialisé en droit du travail, ravi de vous rencontrer.

Recruteur : Bonjour, ravi de vous rencontrer également. Pour commencer, pourriez-vous me parler de votre expérience en matière de droit du travail? Avez-vous travaillé sur des cas spécifiques ou des affaires marquantes dans ce domaine?

Candidat : Bien sûr, j'ai travaillé en tant qu'avocat spécialisé en droit du travail pendant les cinq dernières années dans un cabinet local renommé. J'ai traité divers cas, notamment des litiges pour licenciement abusif, des négociations collectives et des conseils en matière de relations de travail. J'ai également une solide expérience en rédaction de contrats de travail et de politiques internes.

Recruteur : C'est impressionnant! Pouvez-vous me parler de votre approche lorsqu'il s'agit de conseiller des clients en matière de droit du travail? Comment vous assurez-vous de protéger au mieux les intérêts de vos clients tout en respectant la législation en vigueur?

Candidat : Je suis convaincu(e) que mon expérience locale combinée à mon expertise en droit du travail me permettront de fournir des conseils juridiques précis et adaptés aux besoins spécifiques de chaque client. Mon approche consiste à comprendre pleinement les besoins de mes clients, à analyser minutieusement les questions juridiques en jeu et à proposer des solutions stratégiques tout en veillant au respect de la législation en vigueur. Ma priorité est de protéger les intérêts de mes clients et de les aider à prendre des décisions éclairées dans le domaine du droit du travail.

Recruteur : Merci pour cette réponse détaillée. Une dernière question : comment gérez-vous les situations de conflit ou de négociation avec les parties adverses dans le cadre de litiges liés au droit du travail? Avez-vous une approche particulière pour parvenir à des solutions satisfaisantes pour toutes les parties impliquées?

Candidat : Dans les situations de conflit ou de négociation, j'adopte une approche professionnelle et collaborative. Je cherche d'abord à comprendre les points de vue de toutes les parties impliquées, à identifier les intérêts et les préoccupations de chacun, puis à rechercher des solutions mutuellement satisfaisantes. Je privilégie la communication ouverte et transparente, tout en veillant à défendre fermement les intérêts de mes clients. Mon objectif est de parvenir à des accords équitables et durables qui préservent les relations de travail et évitent les litiges prolongés.

Recruteur : Merci pour vos réponses détaillées. Vos compétences et votre approche font de vous un candidat idéal pour ce poste d'avocat spécialisé en droit du travail. Nous allons prochainement vous contacter pour la suite du processus de recrutement. Avez-vous des questions pour moi ?

Candidat : Non, je n'ai pas de questions pour le moment. Merci pour cette opportunité et j'attends avec impatience d'avoir de vos nouvelles. Merci encore et à bientôt.

Recruteur : De rien, c'était un plaisir de discuter avec vous. Bonne journée et à bientôt !

Fig. 3.5. Exemple de conversation d'entrevue générée

- Un minimum de 1500 paires d'entrevue (une paire avec et sans biais pour 1 poste donné et pour 1 biais) seraient nécessaires pour évaluer différents agent IA auditeur à détecter différents types de biais (une dizaine de biais).
- Un minimum de 10000 paires d'entrevue seraient nécessaires pour réaliser un réglage fin (finetuning) des agents IA auditeur.
- Un encodage UTF-8 des textes des entrevues et des informations.
- Le jeu de données est exploitable facilement avec la librairie pandas (format csv par exemple).

3.2. Stratégies de validation de l'agent IA Auditeur EDI

Revenons à l'objectif principal de ce mémoire : notre agent IA Auditeur EDI est capable de déceler la présence d'un biais cognitif, de type stéréotype ou préjugé, dans un contexte professionnel, entre un recruteur et un candidat, lors d'une entrevue de recrutement pour un rôle.

- Résultat clé #1 : la performance attendue est que 90% des entrevues biaisées présentées à l'agent IA EDI sont décelées (la précision est de 90%).
- Résultat clé #2 : à partir des questions posées par le recruteur, et uniquement celles du recruteur, l'agent IA EDI peut se représenter l'image du candidat et estimer la nature du biais potentiel du recruteur parmi une liste de biais possible (un problème de classification).

On peut supposer que la présence d'un biais chez le recruteur viendrait perturber la logique du recrutement. En effet, entre un candidat stéréotypé avec le profil idéal pour le poste et un candidat non stéréotypé avec un profil moyen, le recruteur biaisé serait amené à choisir le second candidat. Détecter un tel biais chez le recruteur revient à détecter une absence de logique dans sa décision de recrutement.

Nous pourrions, dans un premier temps, vérifier le bon fonctionnement de notre agent IA Auditeur EDI en l'exposant à ces 2 situations :

- 2 conversations, 1 poste, 1 candidat stéréotypé : 1 conversation avec le recruteur biaisé, l'autre avec le recruteur non biaisé. L'auditeur compare les 2 conversations et décide laquelle comporte un biais.
- 2 conversations, 1 poste, 2 candidats, 1 candidat (A) a les caractéristiques du stéréotype et possède les compétences, l'autre (B) n'a pas les caractéristiques du stéréotype mais n'a pas les compétences. L'entrevue du candidat A a lieu avec le recruteur biaisé et l'entrevue du candidat B avec le recruteur non biaisé. On soumet les 2 conversations à un autre recruteur non biaisé qui doit choisir entre les 2 candidats (il devrait choisir A). On réalise un audit de biais sur les 2 conversations initiales, on repose la question au recruteur non biaisé mais avec la conclusion de chaque audit. Est-ce que le choix a changé (il ne devrait pas) ?

3.2.1. Stratégies de validation de la performance

Un moyen pour valider la performance de l'auditeur EDI (A) est de lui soumettre 2 échanges de recrutement (E1 et E2) pour un même poste (P) avec le même recruteur biaisé (R) mais avec 2 candidats quasi identiques (ils ont le même niveau de compétences et leurs




Fig. 3.6. Schéma de validation de l'auditeur EDI.

profils correspondent aux pré-requis du poste), l'un présentant le stéréotype (C1) et l'autre non (C2). On demande au recruteur (R) de se positionner sur chaque candidat avec un rapport circonstancié (R1 et R2). On s'attend normalement à ce que le recruteur préfère le candidat C2 à C1. L'auditeur, à partir des 2 échanges et des rapports de recrutement, établit la présence de biais ou non chez le recruteur. Le schéma 3.6 illustre ce scénario.

Voici un tableau récapitulatif des stratégies possibles pour valider la performance de l'auditeur EDI à partir du scénario proposé. Il est organisé en fonction des éléments d'analyse utilisés (échanges seuls, rapports seuls, ou combinaison des deux) et des branches prises en compte (échanges individuellement ou en combinaison).

Explications des stratégies :

- **Échanges seuls :**

- L'auditeur analyse uniquement le contenu des échanges (E1 ou E2), sans utiliser les rapports R1 et R2. L'objectif est de détecter les biais à travers les interactions.

- **Rapports seuls :**

- L'analyse se concentre uniquement sur les rapports circonstanciés (R1 ou R2) fournis par le recruteur après les échanges, pour détecter des traces de biais.

Tableau 3.1. Stratégies de validation de la performance de l’auditeur EDI.

Stratégie	E1	E2	(E1 & E2)
Échanges seuls			
Analyse de l’échange E1 uniquement	✓		
Analyse de l’échange E2 uniquement		✓	
Comparaison des deux échanges (E1 et E2)			✓
Rapports seuls			
Analyse du rapport R1 uniquement	✓		
Analyse du rapport R2 uniquement		✓	
Comparaison des rapports R1 et R2			✓
Échanges + Rapports combinés			
Analyse de l’échange E1 + rapport R1	✓		
Analyse de l’échange E2 + rapport R2		✓	
Analyse combinée des échanges (E1 & E2) et rapports (R1 & R2)			✓

- **Combinaison échanges + rapports :**

- Cette stratégie combine les échanges et les rapports correspondants (E1 avec R1, E2 avec R2), ou les deux branches (E1, E2, R1, R2) ensemble, pour une analyse plus complète.

Utilisation pratique :

- **Individuel (E1, R1 ou E2, R2) :** Vérifier si l’auditeur peut détecter un biais avec un seul ensemble. Cela simule un contexte minimaliste.
- **Combiné (E1 et E2 avec R1 et R2) :** Vérifier si l’auditeur est capable d’identifier des biais lorsqu’il compare les deux branches. Cela teste une capacité plus globale.

3.2.2. Cas d’utilisation de la stratégie combinée

Le poste proposé est un poste d’ingénieur(e) civil, et le recruteur présente un biais de genre, considérant que les femmes sont moins performantes dans les métiers d’ingénierie. Deux candidats sont soumis à son évaluation : l’une est une femme, l’autre un homme. Les deux possèdent un profil quasiment identique, ayant obtenu leur diplôme de l’École Spéciale des Travaux Publics (ESTP) de Cachan dans la même promotion et venant tout juste de terminer leur formation en génie civil.

Après avoir rencontré les deux candidats, le recruteur rédige un rapport circonstancié pour chacun d'eux.

Concernant la candidate, il mentionne :

« Bien que son parcours académique soit solide, je doute de sa capacité à s'imposer sur des chantiers exigeants en raison de la pression et de la dynamique souvent dominées par de fortes personnalités. Elle pourrait être plus à l'aise dans un poste d'assistance technique ou de bureau d'études. »

En revanche, pour le candidat masculin, le rapport indique :

« Avec un excellent parcours académique et une attitude qui inspire confiance, il semble prêt à relever les défis du terrain, même dans des conditions difficiles. Il montre un grand potentiel pour évoluer rapidement vers des postes à responsabilités. »

En utilisant une analyse combinée des échanges et des rapports, l'auditeur pourrait rédiger une évaluation comme suit :

Après avoir examiné les échanges entre le recruteur et les deux candidats, ainsi que les rapports rédigés, plusieurs éléments indiquent un biais de genre dans l'évaluation des candidats. Lors des échanges, le recruteur a insisté davantage avec la candidate sur des questions liées à la gestion de stress et à l'adaptabilité en environnement de chantier, ce qui n'a pas été abordé avec le candidat masculin. Cette différence dans les attentes exprimées laisse supposer que le recruteur associe des caractéristiques professionnelles différentes en fonction du genre.

Les rapports confirment cette impression. Dans le rapport concernant la candidate, le recruteur émet des réserves sur ses capacités à s'imposer dans des environnements exigeants, bien qu'aucune donnée objective ou comportement observé ne justifie cette appréciation. En revanche, le rapport sur le candidat masculin valorise son "attitude" et anticipe son évolution, sans qu'il y ait de différence tangible entre leurs compétences ou expériences.

En conclusion, l'auditeur identifie un traitement différencié des candidats basé sur leur genre, influençant tant les interactions que les jugements formulés dans les rapports, puis explique comment ce biais compromet la prise de décision équitable selon un processus

logique en cascade :

- Le recruteur applique des critères d'évaluation différents selon le genre, posant des questions sur la gestion du stress uniquement à la candidate féminine.
- Ces questions orientées révèlent des préjugés qui influencent son interprétation des réponses.
- Dans ses rapports, il projette des doutes non fondés sur les capacités de la candidate ("je doute de sa capacité à s'imposer") tout en valorisant automatiquement le candidat masculin pour les mêmes compétences.
- Cette évaluation biaisée fausse le classement final des candidats, pouvant conduire à écarter une candidate qualifiée au profit d'un candidat moins adapté.
- Cela compromet ainsi la qualité du recrutement, l'équité du processus et potentiellement la performance future de l'équipe.

Le biais transforme donc une décision qui devrait être basée sur les compétences objectives en une sélection influencée par des stéréotypes de genre.

3.3. Conclusion

Ce chapitre a établi les fondements méthodologiques de notre approche pour la détection automatisée de biais dans les entretiens de recrutement. Les choix stratégiques présentés reflètent les contraintes pratiques du domaine tout en exploitant les possibilités offertes par les technologies d'IA générative.

Innovation méthodologique dans la génération de données

Face à l'absence de jeux de données publics d'entretiens de recrutement, notre approche de génération automatique de données synthétiques constitue une contribution méthodologique significative. L'architecture multi-agents proposée, avec ses six types d'agents spécialisés, offre une solution complète et modulaire pour créer des conversations réalistes et diversifiées. Cette approche permet de contrôler précisément l'injection de biais tout en maintenant la cohérence et la vraisemblance des échanges.

La stratégie de génération structurée, depuis la recherche automatique d'offres d'emploi jusqu'à la création de personas détaillés, assure une diversité suffisante pour entraîner et évaluer efficacement nos agents de détection. Les spécifications techniques retenues (format textuel, limitation des échanges) facilitent l'exploitation du jeu de données tout en

maintenant sa qualité.

Robustesse des stratégies de validation

Les stratégies de validation proposées pour l’agent IA Auditeur EDI offrent une approche multicritère pour évaluer la performance de détection. En combinant l’analyse des échanges conversationnels et des rapports circonstanciés, nous couvrons les différentes manifestations possibles des biais dans le processus de recrutement. Le cas pratique illustré démontre la capacité de notre approche à identifier des biais subtils mais significatifs, comme les différences de questionnement selon le genre du candidat.

Les neuf stratégies de validation identifiées permettent une évaluation graduelle et comparative, depuis l’analyse d’échanges isolés jusqu’à l’examen croisé de multiples conversations. Cette approche progressive facilite l’identification des forces et faiblesses de notre système de détection. Toutefois, nous avons retenu et implémenté uniquement la stratégie "Analyse combinée des échanges et rapports" car elle offre la vision la plus complète du processus de recrutement en exploitant à la fois les interactions conversationnelles et les évaluations formalisées, permettant ainsi une détection plus robuste des biais qui peuvent se manifester différemment dans ces deux types de données.

Justification de l’approche systémique

L’architecture multi-agents proposée répond aux exigences de transparence et de contrôlabilité essentielles dans le domaine des ressources humaines. En décomposant le processus de génération en agents spécialisés, nous facilitons l’audit et la maintenance du système tout en permettant des ajustements ciblés selon les besoins spécifiques.

Limites et considérations éthiques

Bien que prometteuse, notre approche présente certaines limitations inhérentes à l’utilisation de données synthétiques. La validité des conversations générées dépend de la qualité des modèles de langage utilisés et de la pertinence des personas créés. Cette question sera approfondie dans l’évaluation empirique de notre système.

Les considérations éthiques liées à l’automatisation partielle des processus de recrutement nécessitent une attention particulière. Notre approche vise à assister et non à remplacer

le jugement humain, en fournissant des outils d’audit et d’alerte plutôt que des décisions automatisées.

Transition vers l’implémentation

Cette méthodologie établit les bases nécessaires pour développer et tester notre système de détection de biais. Les spécifications techniques détaillées, les architectures d’agents et les stratégies de validation constituent autant d’éléments qui guideront l’implémentation pratique de notre solution.

Le chapitre suivant présentera l’architecture technique et les modèles spécifiques mis en œuvre pour concrétiser cette approche méthodologique. Nous y détaillerons les choix d’implémentation, les technologies utilisées et les optimisations réalisées pour créer un système fonctionnel et performant de détection de biais dans les entretiens de recrutement.

Chapitre 4

Architecture et modèles mis en œuvre

Ce chapitre présente l'architecture technique et les modèles spécifiques développés pour concrétiser l'approche méthodologique établie au chapitre précédent. Il détaille la mise en œuvre pratique du système multi-agents conçu pour générer des données synthétiques d'entrevues de recrutement et détecter les biais dans ces interactions.

L'implémentation de notre solution s'appuie sur une architecture modulaire composée de six types d'agents IA spécialisés, chacun ayant des responsabilités précises dans la chaîne de production des données et d'analyse. Cette approche permet non seulement de respecter les principes de conception logicielle (composants autonomes, réutilisables et testables), mais aussi d'optimiser l'ingénierie des prompts en décomposant les tâches complexes en étapes claires avec des personas et objectifs précis.

Les travaux effectués dans le cadre de ce mémoire ont fourni une occasion unique d'explorer et d'évaluer diverses plateformes d'intelligence artificielle et modèles disponibles sur le marché, qu'ils soient fermés et propriétaires ou ouverts. Ce projet a permis non seulement de tester leurs capacités fonctionnelles, mais aussi de comparer leurs performances, leurs coûts et leurs spécificités dans un contexte d'application réel. En utilisant ces outils, il a été possible d'analyser leurs points forts et leurs limites, tout en identifiant ceux qui répondent le mieux aux besoins et objectifs du mémoire.

Au premier regard, en examinant le schéma d'architecture 4.1, on pourrait se demander pourquoi une architecture aussi élaborée a été mise en place pour générer et analyser une conversation. Les utilisateurs de ChatGPT ou d'autres IA conversationnelles savent qu'il est possible de générer divers contenus à partir d'un simple prompt. Cependant, pour construire une solution d'expérimentation flexible et robuste, il est essentiel d'adopter un principe de

conception logicielle : créer des composants autonomes, réutilisables et facilement testables.

Par ailleurs, la science de l'ingénierie des prompts (prompt engineering) nous enseigne qu'il est crucial de décomposer les tâches des agents IA en étapes claires, de définir des **personas**, de fixer des objectifs précis et de décrire les résultats attendus. Ces concepts s'intègrent parfaitement dans des composants logiciels et justifient à eux seuls la complexité apparente de l'architecture mise en place.

Ce chapitre présente successivement chaque composant de l'architecture : l'agent de génération de postes, l'équipe de création de profils candidats, l'agent de génération de recruteurs, le système de génération de conversations, les agents d'analyse EDI, et enfin l'orchestrateur qui coordonne l'ensemble du processus. Pour chaque composant, nous détaillons les objectifs, les choix d'implémentation, les technologies utilisées, et les apprentissages tirés des expérimentations.

4.1. Agent IA de génération de postes

Cet agent génère automatiquement des descriptifs de postes selon la liste des métiers qu'on lui fournit. Il doit générer des descriptions de postes, les mettre en forme selon une spécification qui lui sera fournie et écrire le résultat, dans un fichier JSON, les descriptions des postes "fictifs" à pourvoir.

4.1.1. Implémentation

Cet agent est créé avec la plateforme ChatGPT+ (my GPT) et utilise une API externe qui retourne la liste des métiers pour lesquels il convient de générer les descriptions sommaires de postes. Le **détail de l'implémentation** se trouve dans les annexes.

4.1.2. Apprentissages

Voici quelques retours d'expériences lors des premières exécutions de l'agent :

- **Points positifs :**

- L'utilisation est simple et conviviale (identique à une conversation en langage naturel avec ChatGPT).
- Possibilité de compléter les spécifications au début de la session : en plus des consignes de base inscrites lors de la configuration, on peut spécifier par exemple un nom de fichier particulier, une quantité de postes, filtrer des métiers, ..., le tout en langage naturel. Par exemple : 5 postes par métier et 5 métiers de préférence non scientifique ou technique.




Fig. 4.1. Schéma de l'architecture du projet.

- Possibilité de raffiner la demande après la génération du fichier : après révision de la génération, on peut demander des ajustements et des corrections. Par exemple : tu as juste copié 5 fois le même poste par métier. Je veux à chaque fois un poste différent (un nom d'entreprise différent, des compétences différentes, des expériences différentes, ...).
- **Points de vigilance :**
 - Limitations sur la créativité : très rapidement, la génération arrive à bout de souffle quand il s'agit d'imaginer des noms, des lieux, des expériences, ..., pour un nombre total de postes supérieur à 10 ou pour des métiers sous représentés sur le Web (on peut supposer un lien avec ce que le LLM sous jacent a ingurgité durant son apprentissage).

- Un contrôle qualité humain est nécessaire pour valider la pertinence et le réalisme des postes générés : parfois, il faut plusieurs itérations pour arriver à générer des descriptions adéquates.
- Compléter les spécifications au début de la session vient parfois contredire les consignes originales et donc la qualité de la sortie.
- La qualité des prompts en entrée est primordiale pour assurer une bonne qualité de génération en sortie : un récent article de Cameron Wolfe ¹ indique que l’une des principales conclusions des articles scientifiques sur l’optimisation des prompts est que les LLM excellent dans l’écriture de prompts. Il précise dans son article « En supposant que nous fournissions les bonnes informations en contexte, il est possible de créer des algorithmes d’optimisation de prompts étonnamment puissants en demandant simplement, de manière itérative, à un LLM de critiquer et d’améliorer un prompt. Les LLMs plus grands (et plus performants) ont tendance à être meilleurs dans cette tâche ».

4.2. Équipe d’agents IA de création des profils candidats

Cette équipe est chargée de créer une base de données de candidats "fictifs" (candidats synthétiques dans le jargon IA) pour répondre à des offres d’emplois. Chacun de ces profils servira à créer un agent IA devant incarner le candidat impliqué dans le processus de recrutement pour un poste. Le but ultime est de générer une conversation réaliste entre un candidat et un recruteur lors d’une entrevue fictive.

4.2.1. Composition de l’équipe

L’équipe se compose des agents IA suivants :

- **Agent préparateur** : cet agent choisit un poste dans la base fournie (fichier JSON), extrait les informations sur le poste et demande au rédacteur de produire une description complète du poste.
- **Agent de description de poste** : cet agent produit un descriptif de poste selon les informations qui lui sont transmises par le préparateur. Il doit extraire les informations du poste, les mettre en forme selon une spécification qui lui sera fournie et transmettre cette description à son collègue de création de profil du candidat idéal.
- **Agent de création de profil du candidat idéal** : cet agent génère un profil candidat idéal basé sur la description du poste à pourvoir. Il collabore avec l’agent de création de persona pour compléter le profil. Un profil contient les informations suivantes :

¹Automatic Prompt Optimization

- Formations académiques et certifications.
- Compétences techniques/métiers.
- Compétences humaines et relationnelles.
- Personna (qui sera complété par l’agent de rédaction de personna).
- Expériences professionnelles.
- **Agent de rédaction de personna** : cet agent génère la description du personna pour le candidat afin de compléter son profil.

4.2.2. Implémentation

L’équipe a été créée avec le framework **CrewAI** [15]² et utilise les modèles GPT d’**OpenAI**. Le détail de l’implémentation se trouve dans les annexes.

4.2.3. Apprentissages

Voici quelques retours d’expériences lors des premières exécutions de l’équipe :

- **Points positifs** :
 - L’utilisation du framework **AgentOPS** [2] est vraiment bénéfique pour déboguer et effectuer les réglages sur les tâches.
 - L’utilisation du framework **CrewAI** est simple, facile et efficace pour le développeur.
 - * En outre, la documentation est riche et très bien faite.
 - Les coûts GPT-4o [48] sont bien inférieurs à ceux de GPT-4 (0.04\$ pour GPT-4o contre 0.5\$ pour GPT-4, pour la génération d’un profil candidat), lors de la sortie de ce modèle, OpenAI communiquait ceci :
 - * GPT-4o a été conçu pour être deux fois plus rapide que GPT-4 Turbo, ce qui réduit les ressources nécessaires par requête.
 - * Les améliorations apportées à GPT-4o permettent de diminuer les dépenses opérationnelles, permettant ainsi à OpenAI de proposer des tarifs plus compétitifs.
 - * En réduisant les coûts, OpenAI vise à rendre GPT-4o accessible à un plus large public, y compris aux utilisateurs gratuits, tout en maintenant des limites d’utilisation raisonnables.
 - GPT-4o est bien plus rapide que GPT-4 (40s à 50 secondes pour GPT-4o contre 120 secondes et plus pour GPT-4)
- **Points de vigilance** :

²Instructions et codes sur GitHub [delemarchand2020](https://github.com/delemarchand2020)

- Il faut faire très attention au choix du modèle LLM et de son paramétrage utilisé par un agent. Selon les besoins, il convient de les adapter : notamment la température qui influence directement la créativité des sorties mais aussi le nombre de tokens générés et donc le coût. Pour des tâches simples, on peut se permettre d'utiliser un modèle moindre (GPT-3.5 par exemple). L'article « RouteLLM: Learning to Route LLMs with Preference Data » [47] aborde le défi de choisir entre des LLM de grande taille, plus puissants mais coûteux, et des modèles plus petit mais plus économiques. Les auteurs proposent des techniques de routage qui, lors de l'inférence, sélectionnent dynamiquement entre un LLM plus fort et un LLM plus faible, assurant ainsi l'équilibre entre le coût et la qualité des réponses.
- Le réglage des instructions à mettre dans les tâches est un processus itératif : beaucoup de variabilité dans la qualité des résultats dépend des instructions qui sont des prompts. Comme évoqué dans le chapitre sur les LLM, l'effet papillon (Butterfly effect) [56] se manifeste depuis l'initialisation puis à chaque étape de la conversation avec un agent IA.
- L'utilisation de l'outil **FileWriterTool** (fourni par **CrewAI**) par les agents n'est pas simple : il faut guider l'agent à bien l'utiliser (quelques essais/erreurs ont été nécessaires pour le faire fonctionner correctement).
 - * Néanmoins, après correction du prompt, cet outil n'est toujours pas capable d'ajouter des lignes à un fichier existant ! Il faudrait en développer un spécifique. Néanmoins ceci est assez simple à faire avec **CrewAI**.
- Non mesuré, mais les biais des données d'apprentissage semblent ressortir :
 - * Beaucoup plus de candidats masculins que féminins ont été générés. Le genre a donc été explicitement spécifié dans les instructions pour palier ce biais.
 - * Beaucoup plus de générations d'expériences de juniors que de seniors. Malgré le niveau d'expérience requis demandé dans le poste, la consigne n'a pas été prise en compte par l'agent en charge de créer le profil. La demande de prise en compte de cette consigne a donc été ajouté dans les instructions. L'instruction a été complétée et précise désormais une correspondance entre les années d'expériences requises et le niveau demandé (junior, intermédiaire ou senior). C'est tout l'intérêt des exemples à mettre dans un prompt et constitue ce que l'on appelle l'apprentissage en contexte pour le LLM.
- Quelques difficultés à respecter systématiquement quelques consignes simples : par exemple mettre les dates d'obtention des diplômes et des expériences.

- * Nous pourrions ajouter à l'équipe un agent qui contrôle le formatage mais cela viendrait ajouter un temps de traitement et un coût supplémentaires. Il serait également possible de préciser avec des exemples les instructions.
- Faible variabilité dans la génération des prénoms, noms, écoles et loisirs (cela s'apparente à un biais des données d'apprentissage).

4.3. Agent IA de génération de profils de recruteur

Cet agent génère automatiquement des profils de recruteurs selon une liste de biais cognitifs fournie. Il doit générer ces profils de recruteurs, les mettre en forme selon une spécification qui lui sera fournie et écrire le résultat dans un fichier JSON. Chacun de ces profils servira à créer un agent IA devant incarner le recruteur impliqué dans le processus de recrutement pour un poste. Le but ultime est de générer une conversation réaliste entre un candidat et un recruteur lors d'une entrevue fictive.

La particularité du recruteur IA dans cet exercice est qu'il doit porter un biais cognitif devant influencer son comportement lors de l'entrevue et altérer son jugement face à la décision de recruter ou pas tel ou tel candidat. Il est important de noter que l'étude se concentre exclusivement sur les conséquences de ces biais dans les interactions et décisions, sans considération pour leur nature consciente ou inconsciente. Évidemment, afin que le biais ne soit pas explicitement détectable lors d'une conversation (ce qui rendrait notre travail de recherche trivial), la manifestation du biais doit être subtilement caché lors de ses interactions comme le ferait un recruteur humain.

Pour plus de clarté, imaginons qu'un recruteur présente un biais de genre, considérant que les femmes sont moins performantes que les hommes dans les métiers d'ingénierie et qu'elles s'épanouissent davantage dans les relations humaines, les rendant plus aptes aux métiers des ressources humaines. Selon le poste à pourvoir, ce biais pourrait le conduire à favoriser tantôt les hommes, tantôt les femmes. Il est donc crucial d'examiner le raisonnement du recruteur pour déceler ce biais durant le processus de recrutement, avant de recourir à une analyse statistique pour identifier un éventuel favoritisme.

Imaginons maintenant un recruteur présentant un biais d'âge, considérant que les candidats jeunes sont plus innovants et adaptables aux nouvelles technologies, tandis que les candidats plus âgés sont perçus comme plus expérimentés mais moins flexibles ou moins à l'aise avec les outils modernes. Selon le poste à pourvoir, ce biais pourrait l'amener à privilégier les jeunes pour des rôles dans des startups technologiques ou des environnements en

rapide évolution, et à favoriser les candidats plus âgés pour des postes nécessitant un leadership stratégique ou une expertise consolidée. Ce type de biais peut altérer le jugement du recruteur de manière subtile, par exemple en posant des questions différentes aux candidats en fonction de leur âge, ou en interprétant leurs réponses avec des attentes préconçues. Il est donc essentiel d'examiner la manière dont ce biais influence les interactions et décisions du recruteur.

4.3.1. Implémentation

L'agent de génération de profils a été créé avec le framework **Opik** [14], qui est une plateforme open-source développée par Comet pour évaluer, tester et surveiller les LLM tels que les modèles GPT d'OpenAI. Le détail de l'implémentation se trouve dans les annexes.

4.3.2. Apprentissages

- **Points positifs :**

- L'utilisation d'Opik est vraiment bénéfique pour déboguer et effectuer des réglages sur les prompts (voir la figure 4.2).
 - * Opik permet une gestion simple et efficace des prompts (gestion des versions).
 - * Opik permet de voir la trace des appels LLM incluant toutes les métadonnées (modèle utilisé et ses paramètres, quantité de tokens utilisés, temps de réponse, coût approximatif, ...).
- Utiliser un meta-prompt pour générer le prompt du générateur de profil de recruteur semble très efficace : à ce stade, il apparaît que les LLM sont vraiment de bons « prompt engineer », contrairement à ce que soutient l'article de Ruo-tian et al., « Are Large Language Models Good Prompt Optimizers? » [38]. En effet l'article conclut que les LLM ne sont pas des « prompt engineer » parfaits. Ils rencontrent des difficultés à identifier les véritables causes des erreurs et à générer des prompts optimaux. Cependant, des approches comme l'Optimisation Comportementale Automatique (ABO) montrent un potentiel prometteur pour améliorer l'efficacité de l'optimisation des prompts en se concentrant sur le comportement des modèles cibles (ici notre générateur de profil). Il conviendrait de poursuivre cette analyse en mesurant la performance de l'agent recruteur qui utilisera le profil généré à cette étape.




Fig. 4.2. Console Opik.

- **Points d'amélioration :**

- D'autres fonctionnalités Opik sont à creuser, notamment la gestion des datasets et des expérimentations : l'utilisation des métriques d'évaluation "LLM as a judge" inclut dans le framework semble prometteur.
- Probablement qu'il faudrait refaire l'agent IA de génération de postes avec la même approche "programmatische" que celle-ci !

4.4. Génération des conversations d'entrevue

La solution de génération des conversations d'entrevue permet de créer une conversation "fictive" (synthétique dans le jargon IA) entre un recruteur et un candidat pour un poste donné. Le poste est choisi parmi ceux de la base de données des descriptions de postes "fictifs", le recruteur et le candidat incarnent respectivement l'un des profils préalablement créés et leur conversation est le fruit de l'alternance entre une question posée par le recruteur à laquelle le candidat répond. Le but final est d'obtenir un jeu de données de conversations sur lequel nous évaluerons un agent IA EDI chargé de détecter la présence de biais dans ces conversations. Nous devons donc produire des conversations avec des recruteurs possédant un biais et d'autres n'en possédant pas.

4.4.1. Composition de l'équipe et flux de travail

L'équipe se compose des agents IA suivants :

- **Agent recruteur** : cet agent est chargé de poser des questions pertinentes au candidat et de réagir à ses réponses. Il a en permanence accès à l'historique de la conversation. Le profil du recruteur contient les informations suivantes (issues de la base de données des recruteurs) :

- Son rôle, ses responsabilités, ses passions et loisirs.
- Ses convictions personnelles (biais), s’il en a.
- La description du poste pour atteindre son objectif : trouver un bon candidat pour ce poste.
- **Agent candidat** : cet agent est chargé de répondre aux questions du recruteur en mettant en avant ses compétences et son expérience. Il a en permanence accès à l’historique de la conversation. Le profil du candidat contient les informations suivantes (issues de la base de données des candidats) :
 - Son CV incluant ses formations, ses compétences et expériences passées, ses passions et loisirs.
 - Ses atouts : pourquoi il pense être un bon candidat pour le poste.
 - La description du poste pour atteindre son objectif : obtenir ce poste.

Le flux de travail est simple. La discussion est amorcée avec une question fixée au préalable puis on enchaîne alternativement une réponse de l’agent candidat et une question de l’agent recruteur pendant un nombre fixé d’échanges.

4.4.2. Implémentation

L’équipe a été créée avec le framework **CrewAI** [15]³ et utilise les modèles GPT d’**OpenAI**. Le détail de l’implémentation se trouve dans les annexes.

4.4.3. Apprentissages

Voici quelques retours d’expériences lors des premières exécutions du flux de travail :

- **Points positifs** :
 - L’utilisation du framework **AgentOPS** [2] est vraiment bénéfique pour déboguer et effectuer les réglages sur les tâches.
 - L’utilisation du framework **CrewAI** est simple, facile et efficace pour le développeur.
 - * En outre, la documentation est riche et très bien faite.
- **Points de vigilance** :
 - Le réglage des "prompts" (goal, backstory et task) est un processus itératif : beaucoup de variabilité dans la qualité des résultats dépend de cela.
 - Il est très difficile d’évaluer si la conversation est biaisée ou pas lorsque l’on souhaite qu’elle le soit ou pas !

³Instructions et codes sur GitHub [delemarchand2020](https://github.com/delemarchand2020)

4.5. Analyse des conversations d’entrevue

Cette équipe est chargée de fournir un rapport complet pour évaluer les biais chez les recruteurs en analysant leurs conversations d’entrevues avec les candidats.

4.5.1. Composition de l’équipe

L’équipe se compose des agents IA suivants :

- **Agent préparateur des dossiers** : cet agent récupère les informations (conversations, rapports de recrutement), éventuellement fait un pré-traitement (anonymisation, changer les prénoms ...), monte le dossier et le transmet à l’auditeur EDI.
- **Agent auditeur EDI** : cet agent réalise l’audit selon les stratégies demandées (analyse des échanges seuls, des rapports seuls, ou des échanges et des rapports).
- **Agent rédacteur d’audit** : cet agent rédige le rapport d’audit selon les analyses de l’auditeur dans le format spécifié.

4.5.2. Implémentation

L’équipe a été créée avec le framework **CrewAI** [15] ⁴ et utilise les modèles GPT d’**OpenAI**. Le détail de l’implémentation se trouve dans les annexes.

4.5.3. Apprentissages

Voici quelques retours d’expériences lors des premières exécutions :

- **Points positifs** :
 - Les éléments mentionnés dans le rapport sont souvent pertinents et bien écrits.
 - L’essentiel des entrevues semble bien capté. Cela semble bien résumer les échanges et les potentiels "biais".
 - Cela ressemble à un vrai rapport professionnel d’audit !
- **Points de vigilance** :
 - Cependant, il repère parfois des "biais" qui n’en sont pas au sens des stéréotypes visés : il faudrait lui "apprendre" à détecter les biais de type stéréotype (c’est à dire lui fournir des exemples et des indices dans le prompt).
 - Il est assez difficile de comprendre et suivre le fonctionnement du mode hiérarchique de **CrewAI** ⁵. De plus, ce mode est très gourmand en ressources LLM (le

⁴Instructions et codes sur GitHub [delemarchand2020](#)

⁵Mode hiérarchique dans CrewAI

framework introduit la planification et l'orchestration des tâches) : jusqu'à 50 LLM mis en jeu contre 18 en mode séquentiel ⁶.

- Il ne pas oublier de nettoyer la mémoire CrewAI lors des différentes exécutions d'équipes (cela semble mélanger les agents et leurs tâches) : par exemple si nous lançons 2 fois la génération du rapport EDI sur 2 jeux de conversations différentes, la mémoire court terme (permanente tout de même sur une fenêtre de temps courte) utilisée par les agents vient parfois confondre les candidats et leurs conversations pourtant distinctes.
- Le cumul des tâches d'analyse paraît mal adapté à un mode de traitement séquentiel. Une structure où chaque tâche d'analyse est traitée indépendamment semble plus prometteuse : soit analyser une conversation à la fois puis produire un rapport, soit analyser les deux conversations simultanément avant de générer le rapport. Cependant, enchaîner les deux analyses dans le même flux de travail crée des interférences avec la mémoire de l'équipe, ce qui risque de mélanger les informations. Cela semble conduire également à des résumés ou à des suppressions partielles d'informations dans l'historique.
- On a pu noter que selon les prompts, l'analyste EDI loupe des petits détails de conversation (pourtant important pour la détection d'un biais).
- Le choix du modèle de langage (LLM) peut avoir un impact significatif. Par exemple, un test utilisant le modèle d'OpenAI o1-mini comme LLM pour l'auditeur EDI a donné les résultats suivants : l'auditeur indique initialement que le candidat 2 pourrait être favorisé, avec un biais global estimé à 10 %. Cependant, un retournement de situation se produit lorsque le rédacteur de l'audit conclut avec un biais global de 62,5 %, cette fois en faveur du candidat 1. Cela soulève une question importante : pourquoi le rédacteur refait-il l'analyse déjà effectuée dans le flux de travail ? Il est probable que le mode de raisonnement du modèle o1-mini vienne compléter ou être influencé par celui produit par des prompts évolués dans le framework CrewAI. Dans ce cas, il serait judicieux d'envisager d'utiliser o1-mini seul pour éviter toute interférence.

4.6. Orchestration des scripts

Ce module vise à automatiser la génération d'un rapport EDI (Équité, Diversité, Inclusion) basé sur des données simulées. Le script principal orchestre toutes les étapes nécessaires, en respectant un ordre spécifique pour l'exécution des scripts correspondant aux différentes parties présentées précédemment.

⁶Mode séquentiel dans CrewAI

4.6.1. Implémentation

Le script principal, entièrement développé en Python, orchestre l'ensemble du processus de génération et d'analyse pour produire un rapport EDI (Équité, Diversité, Inclusion). Il suffit de lui spécifier le métier à utiliser pour la génération des postes et il automatise les étapes suivantes en appelant les scripts spécialisés :

- **AgentIA_generation_postes** : génère une description de poste basée sur le métier spécifié.
- **CrewAI_equipe_creation_BD_candidats** : crée deux profils de candidats, l'un féminin et l'autre masculin, adaptés au poste généré.
- **AgentAI_creation_BD_recruteurs** : génère un recruteur fictif, caractérisé par un biais négatif envers le genre féminin.
- **Simulation_conversation** : simule deux conversations distinctes entre le recruteur généré et chacun des deux candidats (féminin et masculin) pour le même poste généré.
- **Equipe_agents EDI** : analyse les conversations générées et produit un rapport final mettant en évidence les éventuels biais de genre dans les interactions.

Ce flux de travail garantit une structure cohérente et reproductible. Chaque étape, de la génération des postes et des candidats à l'analyse des conversations, est soigneusement intégrée pour détecter et illustrer les biais éventuels dans ce processus de recrutement fictif. La figure 4.3 illustre ce flux de bout en bout.

4.6.2. Apprentissages

Voici quelques retours d'expériences lors des premières exécutions :

- **Points positifs** :
 - En une seule commande, il est possible de générer un scénario complet de bout en bout.
 - Cette approche a permis de déboguer toutes les autres parties en obligeant à écrire des scripts dédiés pour chacune d'elles et en enregistrant toutes les informations dans un seul projet **agentops** [2], facilitant ainsi le suivi des étapes et des appels aux LLM sous-jacents.
 - La centralisation et l'orchestration ont également conduit à finaliser la documentation du code.
- **Points de vigilance** :




Fig. 4.3. Déroulement du flux d'expérimentation en 8 étapes.

- Le processus complet permet d'évaluer le temps et le coût d'exécution : chaque génération de scénario coûte environ 0,32 \$ et prend environ 9 minutes, ce qui peut devenir onéreux pour une exploration intensive.
- Il est nécessaire d'améliorer l'orchestrateur pour permettre de lancer uniquement quelques étapes du processus (par exemple, éviter de régénérer un poste pour le même métier si l'objectif est de tester uniquement avec d'autres candidats).

- Les expérimentations ont révélé des limites dans les résultats : les rapports montrent que la génération des conversations biaisées et leur détection sont loin d’être parfaites, nécessitant un travail approfondi sur les prompts et les configurations.

4.7. Structure du projet

Le projet complet est disponible sur GitHub à l’adresse :
<https://github.com/delemarchand2020/ProjetMaitrise>.

L’ensemble du code source est publié sous licence Apache 2.0, permettant sa réutilisation libre et sa modification par la communauté scientifique pour favoriser la poursuite de ces recherches.

L’implémentation de notre architecture multi-agents s’appuie sur un écosystème technologique diversifié, combinant des modèles de langage de pointe avec des frameworks spécialisés pour l’orchestration d’agents IA. Le tableau 4.1 présente les principales technologies utilisées, organisées par catégorie fonctionnelle.

Le choix de ces technologies a été guidé par plusieurs critères : la performance des modèles LLM, la facilité d’intégration des frameworks multi-agents, et la robustesse des outils de développement et d’observabilité. L’utilisation de GPT-4o [48] comme moteur principal permet d’optimiser le rapport coût-performance, tandis que les frameworks comme CrewAI [15] facilitent la coordination des équipes d’agents.

Chaque composant de notre architecture utilise une combinaison spécifique de frameworks et de modèles LLM, optimisée pour ses fonctions particulières. Le tableau 4.2 détaille la configuration technique de chaque composant, illustrant comment les différentes technologies s’articulent pour créer un système cohérent.

Cette approche modulaire permet une maintenance facilitée et une évolutivité optimale. Par exemple, l’agent de génération de postes utilise l’interface ChatGPT+ pour sa simplicité d’utilisation, tandis que les équipes d’agents plus complexes s’appuient sur CrewAI [15] pour la coordination et AgentOPS [2] pour l’observabilité. Cette diversité technologique, loin d’être un inconvénient, reflète une adaptation pragmatique aux besoins spécifiques de chaque composant.

Tableau 4.1. Technologies et frameworks utilisés dans le projet

Catégorie	Technologie	Usage
Modèles LLM	OpenAI GPT-4o [48]	Moteur principal des agents IA
	OpenAI GPT-4	Comparaison et validation
	OpenAI o1-mini	Tests expérimentaux
	Mistral Large [4]	Tests alternatifs
Frameworks Multi-Agents	CrewAI [15]	Orchestration des équipes d'agents
	LangChain [12]	Intégration des outils LLM
	AutoGen [41]	Exploration (mentionné)
Plateformes IA	ChatGPT+ (my GPT)	Agent de génération de postes
	Opik [14]	Gestion des prompts et traçabilité
	AgentOPS [2]	Observabilité et débogage
Langages et formats	Python 3.12	Langage principal d'implémentation
	JSON	Format de données
	Markdown	Documentation
Outils de développement	Git/GitHub	Gestion de versions
	PyCharm	Environnement de développement
	Virtual Environment	Isolation des dépendances

L'évaluation quantitative de notre implémentation révèle des performances satisfaisantes tant en termes de coût que de temps d'exécution. Avec un coût moyen de 0,32\$ par scénario complet et un temps d'exécution d'environ 9 minutes, notre système offre un bon compromis entre performance et accessibilité économique.

Cette efficacité résulte notamment de l'optimisation réalisée avec GPT-4o, qui présente un coût 12,5 fois inférieur à GPT-4 tout en maintenant une qualité de génération comparable. L'orchestrateur Python natif, bien que plus basique que les frameworks spécialisés, assure une coordination efficace sans surcoût technologique.

Ces métriques valident la faisabilité économique de notre approche pour une utilisation en contexte de recherche ou de déploiement pilote en entreprise. L'évolutivité du système

Tableau 4.2. Détails techniques par composant

Composant	Framework	Modèle LLM	Fonctionnalités
Agent génération postes	ChatGPT+ (my GPT)	GPT-4o	API externe, format JSON
Équipe candidats	CrewAI	GPT-4o	4 agents spécialisés
	AgentOPS	GPT-4o	Observabilité
Agent recruteurs	Opik [14]	GPT-4o	Gestion prompts versionnée
Conversations	CrewAI	GPT-4o	2 agents interactifs
	AgentOPS	GPT-4o	Traçabilité
Agents EDI	CrewAI	GPT-4o	3 agents d’analyse
	AgentOPS	GPT-4o	Débogage
	(Test o1-mini)	o1-mini	Expérimentation
Orchestrateur	Python natif	Multiple	Coordination complète

permettrait d’optimiser davantage ces performances pour une utilisation intensive en production.

4.8. Conclusion

Ce chapitre a présenté la concrétisation technique de notre approche méthodologique pour la détection de biais dans les entrevues de recrutement. L’architecture multi-agents développée et les expérimentations réalisées offrent des enseignements précieux tant sur les capacités que sur les limites des technologies d’IA générative actuelles.

Réalisations techniques et validation de l’approche

L’implémentation réussie de l’architecture multi-agents démontre la faisabilité de notre approche méthodologique. Les six composants développés - agent de génération de postes, équipe de création de candidats, agent de génération de recruteurs, système de génération de conversations, agents d’analyse EDI, et orchestrateur - fonctionnent de manière cohérente et produisent des résultats exploitables.

L’utilisation de frameworks spécialisés (CrewAI [15] pour les équipes d’agents, Opik [14] pour la gestion des prompts) s’est révélée particulièrement bénéfique pour le développement et le débogage. Les outils d’observabilité comme AgentOPS [2] ont considérablement facilité l’optimisation des performances et la compréhension des comportements des agents.

Les choix technologiques effectués, notamment l'utilisation de GPT-4o d'OpenAI [48], ont permis d'atteindre un bon équilibre entre performance et coût (réduction de 90% du coût par rapport à GPT-4 et amélioration significative de la vitesse d'exécution). Cette optimisation économique est cruciale pour la viabilité pratique de l'approche.

Enseignements sur l'ingénierie des prompts et la gestion des biais

Les expérimentations ont confirmé l'importance critique de l'ingénierie des prompts dans la qualité des résultats obtenus. L'effet papillon observé, où de petites modifications dans les prompts entraînent des changements significatifs dans les sorties, souligne la nécessité d'une approche itérative et rigoureuse dans la conception des instructions.

L'émergence de biais non intentionnels dans les générations automatiques (surreprésentation masculine, préférence pour les profils juniors) illustre la persistance des biais des données d'entraînement dans les LLM. Ces observations renforcent la pertinence de notre travail et justifient la nécessité d'outils de détection automatisée.

L'utilisation de méta-prompts pour générer les prompts définitifs s'est révélée efficace, validant l'hypothèse que les LLM peuvent être de bons "prompt engineers" dans certains contextes spécifiques, malgré les réserves exprimées dans la littérature.

Défis identifiés et solutions adoptées

Les principales difficultés rencontrées concernent la gestion de la mémoire dans les frameworks multi-agents, les interférences entre tâches séquentielles, et la variabilité dans le respect des consignes de formatage. Ces problèmes ont nécessité des ajustements architecturaux et des stratégies de contournement, comme l'ajout d'exemples explicites dans les prompts et la gestion manuelle de la mémoire entre les exécutions.

La difficulté à évaluer subjectivement la qualité des biais générés dans les conversations souligne l'importance d'une validation objective, qui sera développée dans les expérimentations du chapitre suivant.

Optimisation économique et opérationnelle

L’orchestrateur développé permet de générer un scénario complet en une seule commande, avec un coût moyen de 0,32\$ et un temps d’exécution de 9 minutes. Cette performance, bien que satisfaisante pour des expérimentations contrôlées, nécessiterait une optimisation pour une utilisation intensive en production.

L’analyse des coûts par composant révèle des opportunités d’optimisation, notamment l’utilisation sélective de modèles moins coûteux pour les tâches simples, selon les principes du routage intelligent des LLM.

Validation de l’approche méthodologique

L’architecture développée valide notre hypothèse selon laquelle les agents IA peuvent générer des données synthétiques réalistes pour l’étude des biais de recrutement. Les rapports EDI produits par les agents d’analyse présentent une qualité professionnelle et identifient correctement les éléments pertinents dans les conversations.

Cependant, les limites observées dans la détection précise des biais de type stéréotype indiquent la nécessité d’un affinement supplémentaire des prompts et possiblement d’un entraînement spécialisé pour optimiser les performances de détection.

Transition vers l’évaluation empirique

Cette implémentation technique constitue la base expérimentale nécessaire pour évaluer quantitativement l’efficacité de notre approche. Les outils développés, les données générées et les enseignements tirés de cette phase d’implémentation guideront la conception des expériences d’évaluation.

Le chapitre suivant présentera les résultats détaillés de nos expérimentations, en analysant les performances de détection des agents EDI sur le jeu de données synthétiques généré, et en comparant leur efficacité selon différents types de biais et scénarios d’entrevue. Cette évaluation empirique permettra de valider quantitativement l’approche développée et d’identifier les pistes d’amélioration pour une utilisation pratique en contexte réel de recrutement.

Chapitre 5

Expériences et résultats

Ce chapitre présente les résultats expérimentaux de notre approche pour la détection automatisée de biais dans les entrevues de recrutement. Il valide empiriquement l'efficacité de l'architecture multi-agents développée et évalue la qualité des données synthétiques générées ainsi que la performance de notre système de détection EDI.

L'évaluation de notre approche s'articule autour de deux axes complémentaires qui correspondent aux objectifs principaux de ce mémoire. Le premier axe concerne la validation de notre capacité à générer des conversations d'entrevue synthétiques de qualité suffisante pour servir de support à la recherche. Le second axe porte sur l'évaluation de l'efficacité de notre système de détection automatisée des biais de genre dans ces conversations.

La première section détaille les résultats de l'évaluation de la qualité des données synthétiques générées par notre système. Cette évaluation, menée auprès de 28 professionnels répartis entre le Québec et la France, analyse la pertinence et le réalisme de 18 conversations d'entrevue représentant 180 interactions. Cette validation externe nous permet de quantifier la crédibilité de nos données synthétiques et d'identifier les axes d'amélioration pour optimiser la génération de conversations.

La seconde section présente l'évaluation de notre système de détection de biais EDI. Cette évaluation compare les analyses produites par notre équipe d'agents IA avec celles d'expertes en ressources humaines spécialisées en équité, diversité et inclusion. L'analyse porte sur six cas d'étude représentant différents types de manifestations de biais de genre, permettant d'évaluer la précision et la cohérence de notre système de détection.

Ces expérimentations s'appuient sur une méthodologie rigoureuse incluant des phases de calibrage du système, des protocoles d'évaluation standardisés, et des analyses comparatives avec des experts humains. L'objectif est de démontrer que notre approche peut effectivement détecter les manifestations subtiles de stéréotypes de genre dans les processus de recrutement tout en générant des rapports d'audit exploitables en contexte professionnel.

5.1. Création d'un jeu de données pour la recherche

Dans le cadre de cette étude sur la détection des biais de type stéréotype dans les processus de recrutement, il est primordial d'avoir accès à des conversations d'entrevue entre un recruteur et un candidat. Ce type de données n'est pas disponible pour le grand public et probablement pas dans la sphère privée des entreprises. Nous avons donc créé de toutes pièces des conversations synthétiques simulant des entretiens d'embauche via Teams ou Zoom et dont les transcriptions auraient été mises à notre disposition.

Notons que seul le biais de genre a été effectivement expérimenté dans le cadre de ce mémoire. Cette limitation s'explique par plusieurs facteurs pratiques et méthodologiques.

D'une part, les véritables experts EDI disponibles pour valider nos résultats avaient une expertise principalement liée aux stéréotypes de genre, phénomène habituellement rencontré dans le milieu du travail et particulièrement en vogue ces derniers temps. Cette spécialisation nous a permis d'obtenir des évaluations professionnelles de haute qualité, mais a naturellement orienté nos expérimentations vers cette catégorie de biais.

D'autre part, le choix du biais de genre comme cas d'étude principal se justifie par sa prévalence documentée dans les processus de recrutement et sa reconnaissance comme enjeu prioritaire dans les politiques d'équité, diversité et inclusion des organisations contemporaines.

Il est important de souligner que l'environnement de simulation développé permettrait, avec quelques ajustements, de produire et détecter d'autres types de biais tels que l'âgisme, les discriminations liées à la religion, l'ethnie, ou encore le statut socio-économique. L'architecture multi-agents proposée est suffisamment flexible pour intégrer de nouveaux profils de candidats, adapter les scénarios de conversation, changer la langue, et configurer les agents d'analyse EDI selon différents critères de discrimination.

Cette extensibilité constitue l’une des forces de notre approche méthodologique et ouvre la voie à des travaux futurs couvrant un spectre plus large de biais sociaux dans les processus de recrutement automatisés.

5.1.1. Méthodologie pour évaluer les échanges synthétiques générés

Nous avons dans un premier temps généré une base de 18 conversations comportant chacune 5 échanges ou interactions, totalisant au global 180 questions et réponses , portant sur 10 postes à pourvoir (voir la table 5.1 pour la liste des postes) et réparties à parité entre des candidats masculins et féminins. La génération des conversations a été réalisé via l’outil d’orchestration qui met en œuvre toute la panoplie des agents et équipes IA présentés dans la section précédente.

Tableau 5.1. Liste des postes générés pour le sondage.

Poste
Scrum Master SaFe - Senior Coach Agile
Contrôleur de Gestion Senior - Projets Internationaux
Consultant(e) Fiscaliste International(e)
Dentiste Endodontiste
Ingénieur Procédés en Optimisation Chimique
Responsable des Achats Bio et Éthique
Scrum Master Agile Senior
Développeur Java Backend - Services Cloud
Java Backend Developer - Cloud Applications
Contrôleur.se de Gestion Commerciale

Un sondage ¹ a été mené entre le 1er et le 23 février 2025 pour évaluer ces transcriptions simulant des entretiens via Teams ou Zoom. Les participants, constitués exclusivement de professionnels issus du réseau de l’auteur (ce qui explique la langue choisie et les pays de provenance de ces personnes), ont évalué la pertinence des échanges, en notant cet aspect sur une échelle de 1 à 5, et en indiquant par oui ou non si les interactions entre le recruteur et le candidat leur paraissent réalistes.

Évaluation :

¹Lien vers le sondage : <https://delemarchand2020.github.io/ProjetMaitrise/sondages/conversations/>

- Par **pertinence**, nous entendons un lien clair et direct avec le sujet abordé dans l'échange. Autrement dit, la réponse du candidat répond-elle à la question du recruteur : 1 = pas du tout pertinent et 5 = très pertinent.
- Par **réalisme**, nous entendons des échanges naturels et plausibles dans un entretien de recrutement.

Le formulaire pour réaliser le sondage présente une entrevue aléatoirement choisie parmi les 18 conversations. Le participant peut changer d'entrevue si le tirage aléatoire initial ne lui convient pas. Ainsi il peut explorer, aléatoirement, toutes les entrevues générées. L'évaluation est complétée une fois qu'il a exporté ses résultats et les a envoyés par courriel. La figure 5.1 illustre le formulaire Web envoyé aux participants.

Les réponses ne sont pas anonymes car ils doivent transmettre leurs résultats par courriel après avoir exporté le fichier. Ce choix a été fait pour qu'ils sachent exactement quelles données sont transmises.

28 participants (voir la table 5.2), tous des professionnels en entreprise, répartis entre le Québec (53 %) et la France (47 %), ont évalué 47 conversations, soit 235 interactions. Les conversations ont été évaluées au moins une fois chacune. Aucune mention n'a été faite aux participants sur la façon dont ces conversations ont été captées ou générées.

5.1.2. Statistiques générales

Le rapport statistique généré fournit une vue d'ensemble sur les notes de pertinence des questions et réponses, ainsi que le réalisme des interactions.

Les notes globales de pertinence des questions et réponses sont les suivantes :

- **Pertinence des questions** : Moyenne = 4.5, Médiane = 5.0, Écart-type = 0.84.
- **Pertinence des réponses** : Moyenne = 4.1, Médiane = 5.0, Écart-type = 1.09.

Le pourcentage d'interactions jugées réalistes est de 72.17 %, avec 26.96 % jugées non réalistes et 0.87 % non répondues.

La figure 5.2 illustre la distribution des notes de pertinence sur les 5 interactions que comporte une conversation. La première interaction correspond toujours à la question d'introduction du recruteur suivi par la réponse du candidat et la dernière aux salutations habituelles afin de clôturer l'entrevue.

Échange 1

Question (recruteur) : Bonjour Sophie Dupont, vous postulez pour le poste de Consultant(e) Fiscaliste International(e), dites m'en un peu plus sur vous et ce qui vous motive dans ce poste ?

Notez la pertinence de la question (1-5) :

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5

Réponse (candidat.e) : Bonjour, avec plus de 15 ans d'expérience en fiscalité internationale et une expertise avérée en structuration fiscale et conformité transfrontalière, je suis particulièrement motivée par l'opportunité de rejoindre FiscElite Advisory pour conseiller des entreprises multinationales et optimiser leur structure fiscale tout en assurant la conformité avec les réglementations internationales.

Notez la pertinence de la réponse (1-5) :

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5

Cette interaction semble-t-elle réaliste ?

☐ Oui ☐ Non

Échange 2

Question (recruteur) : Merci pour votre réponse. Pourriez-vous partager un exemple où vous avez dû surmonter un défi technique complexe dans le cadre de vos fonctions en fiscalité internationale, et comment vous avez réussi à le résoudre?

Notez la pertinence de la question (1-5) :

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5

Réponse (candidat.e) : Lors d'une mission avec GlobalTax Consultancy, j'ai affronté le défi complexe de restructurer les opérations fiscales d'une multinationale pour assurer la conformité avec des réglementations transfrontalières variées. Grâce à une analyse approfondie et à l'utilisation de logiciels avancés comme SAP Tax Management, j'ai réussi à proposer des solutions innovantes qui ont optimisé leur structure fiscale tout en garantissant une pleine conformité.

Fig. 5.1. Formulaire de sondage envoyé aux participants.

La figure 5.3 représente l'évaluation de la pertinence moyenne des interactions au long de la conversation.

Tableau 5.2. Répartition des répondants (seuls les prénoms sont fictifs).

Prénom	Poste	Pays
Eve	Directeur services conseils	QC
Patricia	Analyste d'affaire	QC
Alex	Ingénieur Cloud	FR
Donna	Responsable de produit	QC
Wilhelmina	Architecte logiciel	QC
Joanna	Directrice performance organisationnelle	QC
Victoria	Analyste performance organisationnelle	QC
Oliver	Consultant cybersécurité	FR
Yann	Ingénieur système transport	QC
Sophie	Acquisition de talent	FR
Florence	Responsable produit	QC
Thomasina	Analyste fonctionnel	QC
Ava	Analyste d'affaire	QC
Matthew	Acquisition de talent	FR
Maria	Acquisition de talent	FR
Robinia	Acquisition de talent	FR
Isabelle	Acquisition de talent	FR
Charlotte	Directeur cloud	FR
Jordana	Développeur IA	QC
Frances	Analyste d'affaire	QC
Henry	Architecte logiciel	FR
Tom	Analyste d'affaires	QC
Bridget	Conseillère stratégique	FR
Paulus	Architecte de solutions TI	QC
Karine	Acquisition de talent	FR
Eliott	Acquisition de talent	QC
Fulbert	Acquisition de talent	FR
Max	Chercheur en chimie médicinale	FR

La conversation la plus mal notée sur la pertinence (moyenne de 3.7 sur les 5 interactions) est la conversation pour le poste de Java Backend Developer - Cloud Applications pour un candidat nommé Antoine Dupont.




Fig. 5.2. Répartition et distributions des notes selon les échanges.




Fig. 5.3. Réalisme des interactions en fonction des échanges.

La conversation la plus mal notée sur le réalisme (moyenne de 40 % sur les 5 interactions) est la conversation pour le poste de Consultant(e) Fiscaliste International(e) pour une

candidate nommée Sophie Dupont.

La conversation la mieux notée sur la pertinence (moyenne de 4.8 sur les 5 interactions) est la conversation pour le poste de Consultant(e) Fiscaliste International(e) pour un candidat nommé Alexandre Dupont.

La conversation la mieux notée sur le réalisme (moyenne de 100 % sur les 5 interactions) est la conversation pour le poste de Contrôleur de Gestion Senior - Projets Internationaux pour un candidat nommé Pierre Martin.

5.1.3. Constats

Les questions sont globalement plus pertinentes que les réponses. Les premiers échanges sont également plus pertinents que les derniers (voir 5.2). On note une corrélation entre la perte de pertinence et la baisse du réalisme au fil de la conversation (à comparer avec 5.3).

Le réalisme des interactions semble plutôt bien noté au global (72.17 % des interactions sont jugées réalistes). Cette portion monte à 79.41 % quand on exclut les répondants qui sont des recruteurs (ceux dont le poste est identifié par acquisition de talents). Par contre, lorsque l'on porte un regard uniquement avec les lunettes des répondants spécialisés en acquisition de talents, donc des personnes dont le travail est de mener des entrevues, le réalisme tombe à 51.67 %.

Ce sont les 2 grands blocs de constats quantitatifs que nous observons. En outre, quelques répondants ont retourné avec leurs évaluations des commentaires qualitatifs sur leur expérience. Ce n'était pas demandé dans le sondage afin de le garder suffisamment léger mais nous pouvons rapporter les principaux retours :

- Toutes les conversations ont la même structure, ce qui les rend moins réalistes.
- Le ton est tellement courtois, notamment de la part du recruteur, que cela ne fait pas naturel.
- Les termes élogieux n'ont pas leur place dans une entrevue de recrutement, par exemple : votre expérience est impressionnante. Cela suggère une relation inversée.
- Certaines interactions sont trop généralistes alors qu'il s'agit d'entrevues pour des postes spécifiques. Cela donne l'impression que le candidat ne maîtrise pas son sujet.

5.1.4. Conclusion

Le résultat de ce sondage fournit des informations importantes sur la perception de la pertinence et du réalisme des simulations d'entrevue, ce qui peut être utilisé pour améliorer la génération des conversations d'entrevue afin d'en faire un jeu de données de qualité pour la recherche.

Les questions posées par les recruteurs ont été jugées globalement plus pertinentes que les réponses des candidats. Cela suggère que les questions étaient bien adaptées aux postes proposés, mais que les réponses pourraient être améliorées pour mieux refléter les compétences et l'expérience des candidats. Il existe des pistes d'amélioration pour rendre les conversations plus authentiques, comme varier les structures des conversations et éviter les échanges trop généralistes. Cela pourrait être fait en affinant le prompt de l'agent IA candidat pour augmenter la pertinence des réponses en intégrant des éléments plus spécifiques au poste visé. L'affinage du prompt de l'agent IA recruteur serait bénéfique pour varier le schéma de questions et ajuster le ton afin de le rendre plus naturel. D'autre part, dans le paramétrage de l'agent recruteur, il serait peut-être utile qu'il "prenne connaissance" du profil du candidat au préalable (ce n'est pas le cas dans la configuration utilisée pour produire les conversations évaluées par ce sondage).

Une majorité des interactions ont été perçues comme réalistes, ce qui est encourageant. Cependant, ce pourcentage chute significativement lorsque l'on considère uniquement les évaluations des professionnels de l'acquisition de talents, indiquant que les standards de réalisme varient selon l'expertise des évaluateurs. Une piste serait d'impliquer davantage les professionnels de l'acquisition de talents dans le processus de création des simulations car cela pourrait aider à aligner les attentes de réalisme.

Il y a une tendance observée où la pertinence et le réalisme des échanges diminuent au fil de la conversation. Cela pourrait être dû à une fatigue ou à une perte d'intérêt des participants au cours de la lecture des conversations.

Bien que les analyses ne font pas état des différences entre les évaluateurs du Québec et de France, il pourrait être intéressant d'explorer davantage les nuances culturelles ou professionnelles qui pourraient influencer la perception de la pertinence et du réalisme des entretiens.

Le premier objectif de ce mémoire consistait à générer des conversations simulées contrôlées, variées, pertinentes et réalistes, dans un format exploitable à la fois par des humains et des systèmes informatiques. Les résultats du sondage montrent que cet objectif a été largement atteint, tout en identifiant des pistes concrètes d'amélioration.

Tout d'abord, la capacité à générer des conversations contrôlées, avec ou sans biais injecté, a été démontrée. Le système permet de configurer différents paramètres tels que le poste à pourvoir, le profil des recruteurs et des candidats, et d'orchestrer un échange structuré entre ces deux acteurs. Cela valide la maîtrise du cadre narratif et la génération intentionnelle de scénarios ciblés.

Ensuite, les conversations présentent une variété suffisante sur les plans des postes, des profils et des styles d'échange dans le cadre de l'expérimentation. Toutefois cette diversité devra être améliorée pour constituer un corpus représentatif et riche, conforme aux attentes d'un jeu de données pour la recherche en EDI et en recrutement.

Concernant la pertinence et le réalisme, le sondage révèle que la majorité des interactions ont été jugées naturelles et adaptées, notamment les questions posées par les recruteurs. Si les réponses des candidats peuvent encore gagner en précision et spécificité, cela n'enlève rien au fait que le lien question-réponse est maintenu et cohérent, remplissant l'un des critères fondamentaux de pertinence. Le réalisme perçu, bien que variable selon le niveau d'expertise des évaluateurs, reste globalement satisfaisant, et peut être renforcé par des ajustements ciblés dans les prompts.

Enfin, le format technique des conversations est conforme aux attentes : chaque interlocuteur est clairement identifié, les échanges sont chronologiques et structurés, ce qui facilite autant la lecture humaine que l'exploitation automatique des données.

En résumé, le système répond aux cinq critères définis : contrôle, variété, pertinence, réalisme et format lisible. Le cadre mis en place est fonctionnel et améliorable, et constitue une base solide pour des recherches futures sur la simulation d'entretiens avec ou sans biais.

Poursuivons avec l'expérimentation consacrée à la détection de biais, qui constitue la pierre angulaire de ce travail de recherche. Elle vise à évaluer la capacité d'une solution IA EDI à assister l'humain en identifiant automatiquement les biais présents dans les échanges entre recruteurs et candidats.

5.2. Détection des biais avec une équipe d’agents EDI

Le cœur de ce projet de mémoire est de concevoir une solution IA EDI capable d’assister l’humain en détectant automatiquement des biais chez les recruteurs lors des entrevues. Pour restreindre la portée des biais à détecter, nous avons ciblé l’analyse sur la recherche du biais (stéréotype) de genre. Nous allons dans ce chapitre comparer les résultats entre ce que détecte l’agent IA et ce que détecte un expert humain du domaine. Le support de ces analyses sont les conversations d’entrevue synthétiques générées par notre système préalablement mis en place.

5.2.1. Calibrage

Cette phase est nécessaire pour établir une sorte d’étalonnage de notre solution IA EDI sur un cas typique. Le calibrage nécessite une connaissance en entrevue de recrutement et une expertise dans la solution d’agents IA utilisée.

Fort des premiers apprentissages vus lors de l’implémentation de l’équipe d’agents EDI, nous avons précisé la description des tâches d’analyse des biais, établi un barème de notation et précisé le format attendu pour le rapport. Tous ces détails sont disponibles dans le code source de l’équipe EDI ².

Pour calibrer notre équipe EDI, nous commençons par générer via l’orchestrateur 2 conversations d’entrevue entre un recruteur doté d’un stéréotype de genre et 2 candidats : 1 femme et 1 homme. Nous choisissons un métier très technique où les femmes semblent moins représentées : Java Backend Developer - Cloud Applications. Le hasard de la génération, fait que la manifestation du biais de genre prend la forme d’une question sur l’équilibre travail-vie personnelle uniquement pour la candidate. Nous lançons ensuite la génération du rapport EDI avec un paramétrage de LLM le plus déterministe possible pour les agents IA de l’équipe EDI (opérée par CrewAI [15]). Voir les annexes pour le détail du paramétrage.

Après une vingtaine de génération du rapport EDI sur les mêmes 2 conversations, nous obtenons des rapports relativement homogènes et constants : les scores sont cohérents avec les explications fournies et sont constants en ordre de grandeur (50 % de suspicions de biais de genre pour la candidate contre 10 % pour le candidat). Toutefois, il existe de temps en temps des rapports avec des interprétations atypiques (le biais n’est pas interprété comme un biais de genre mais comme une attention particulière à l’égard du genre féminin).

²gen_rapport_EDI.py

Il existe encore de la variabilité ! rappelons que la variation d'un mot dans un prompt initial (le premier agent qui fait l'acquisition des entrevues via un outil pour le formater et le transmettre à l'analyste) peut générer une cascade de petits changements dans les différentes tâches subséquentes des 2 autres agents impliqués et donc produire au final une variabilité dans la production du rapport final.

Après un raffinement de la description de la tâche d'analyse (ciblage sur le biais de genre et simplification des instructions), nous obtenons une meilleure reproductibilité dans les résultats d'analyse.

Suite à ce premier calibrage, nous vérifions que l'ordre des conversations n'a pas d'impact dans l'analyse : par construction, l'orchestrateur génère la conversation 1 avec la candidate et la conversation 2 avec le candidat. Une inversion des 2 fichiers a permis de vérifier cet aspect. Enfin, nous vérifions que la détection de la présence ou non du biais reste possible sans nécessiter une comparaison avec une entrevue différente. La fourniture d'une seule des 2 conversations a permis de contrôler cet aspect (quoique la comparaison semble renforcer le score).

Le second calibrage consiste à modifier légèrement le profil du recruteur afin de générer 2 nouvelles conversations avec une manifestation du biais différente. Cette fois-ci, c'est une question sur la difficulté à se faire entendre en réunion. Nous avons généré 2 rapports qui sont parfaitement homogènes et constants : les scores sont cohérents avec les explications fournies et sont constants en ordre de grandeur (40 % de suspicions de biais de genre pour la candidate contre 10 % pour le candidat). Le second calibrage est un succès.

Le jeu de données de calibrage (le poste à pouvoir, le profil de la candidate, le profil du candidat, le profil du recruteur et son biais de genre, les 2 conversations d'entrevue) ainsi que les rapports EDI générées sont disponibles sur le répertoire GIT du projet ³.

5.2.1.1. Automatisation du calibrage. Le calibrage, c'est à dire l'optimisation des "prompts" des tâches des agents IA de l'équipe EDI, auraient pu être auto généré. En effet, il existe un framework ⁴ qui permettrait de réaliser ce travail automatiquement. L'article de Yuksekgonul & Al. (2024) [77] présente TextGrad, un framework pour l'optimisation des systèmes d'IA complexes en utilisant des rétroactions textuelles fournies par des LLM. Inspiré

³Calibrage de l'équipe EDI

⁴TextGrad

par la rétropropagation et la différentiation automatique ⁵ qui ont transformé l’entraînement des réseaux de neurones, TextGrad applique ces concepts aux systèmes d’IA avancées.

5.2.2. Méthodologie

Nous avons sollicité deux expertes RH spécialisées dans le domaine EDI auxquelles nous avons soumis 6 cas générés avec l’orchestrateur ⁶. Chaque cas comprend 1 poste, 1 profil de recruteur avec le biais de genre, 1 profil de candidate, 1 profil de candidat, 1 transcription de l’entrevue de recrutement avec la candidate, 1 transcription de l’entrevue de recrutement avec le candidat et finalement le rapport EDI généré par l’équipe d’agents IA.

Nous avons demandé aux 2 expertes EDI de choisir 3 cas chacune et pour chaque cas de lire dans l’ordre les 2 entrevues, de noter sur un papier leurs observations en ce qui concerne la présence ou non de la manifestation d’un biais de type stéréotype pour chaque conversation anonymisée, de donner un score de présence de biais (même barème que celui utilisé par notre agent IA EDI), puis de lire le rapport EDI, de comparer avec leurs résultats et de noter qualitativement le rapport EDI.

Les expertes EDI n’ont pas à évaluer le réalisme ou la pertinence des conversations. Elles n’ont pas accès aux profils des protagonistes, ni à la description du poste. En fait nous ne leur demandons pas une opinion sur ces aspects mais uniquement si elles étaient face à ces transcriptions d’entrevues, fussent-elles réelles ou non, feraient-elles les mêmes observations ? Un exemple de transcription d’entrevue de recrutement soumis aux expertes EDI est illustré par la figure 5.4 (on peut y déceler la manifestation potentielle d’un biais dans la dernière question du recruteur).

Nous avons également sollicité une experte RH en développement des compétences à laquelle nous avons soumis l’ensemble des 6 cas avec le même protocole d’évaluation. Ce second avis, moins spécialisé en EDI mais orienté sur un autre domaine des RH, permet de contrebalancer les biais professionnelles des deux premières et sert de point de comparaison externe : son regard moins spécialisé en EDI peut apporter des convergences ou divergences intéressantes qui enrichissent l’évaluation globale des rapports générés par notre agent EDI.

⁵Techniques utilisées dans l’entraînement des réseaux de neurones

⁶Lien vers le détails des 6 cas d’expertise proposés :

https://github.com/delemarchand2020/ProjetMaitrise/tree/master/Equipe_agents_EDI/Cas_Expertise_Externe

```

    "role": "Recruteur",
    "message": "Bonjour XXX, vous postulez pour le poste de Senior Java
Backend Developer - Cloud Solutions Architect, pouvez vous m'en dire un peu plus
sur vous et ce qui vous motive dans ce poste ?"
  },
  {
    "role": "Candidat",
    "message": "Bonjour, je suis passionné.e par le développement de
solutions cloud innovantes et j'ai une solide expérience en Java, Spring Boot,
et AWS, ce qui me motive à contribuer efficacement au sein de CloudSynapse
Innovations. Mon expertise en architecture de microservices me permettra
d'apporter des solutions robustes et scalables adaptées à vos besoins."
  },
  {
    "role": "Recruteur",
    "message": "Merci pour votre réponse. Pouvez-vous me parler d'une
situation où vous avez collaboré avec une équipe DevOps pour automatiser le
déploiement d'une application sur AWS ? Quels défis avez-vous rencontrés et
comment les avez-vous surmontés ?"
  },
  {
    "role": "Candidat",
    "message": "Lors de ma collaboration avec l'équipe DevOps chez TechCloud
Developments, nous avons automatisé le déploiement d'applications backend sur
AWS. Nous avons dû relever le défi d'intégrer des outils CI/CD efficaces et
avons réussi en optimisant nos scripts pour assurer une transition fluide et
sans erreur vers l'environnement cloud."
  },
  {
    "role": "Recruteur",
    "message": "Je comprends que vous avez une expérience significative dans
l'automatisation des déploiements avec AWS. Dans ce contexte, avez-vous déjà eu
des difficultés à vous faire entendre dans des réunions techniques au sein de
votre équipe actuelle ?"
  },
  {
    "role": "Candidat",
    "message": "Lors de ma collaboration avec l'équipe DevOps chez TechCloud
Developments, j'ai effectivement rencontré des difficultés pour faire valoir
certaines de mes propositions techniques. Cependant, en mettant en avant des
solutions innovantes et des résultats tangibles obtenus grâce à notre
automatisation sur AWS, j'ai pu démontrer l'impact positif de mes idées et
gagner en influence lors des réunions techniques."
  }
]

```

Fig. 5.4. Exemple de conversation soumise aux expertes EDI.

5.2.3. Analyses des expertes RH

Nous avons rassemblé dans le tableau 5.3 les analyses des expertes RH en face de celles de notre agent IA EDI (scores/range de scores des biais pour chaque entrevue, raison de la détection du biais sur l’entrevue de la candidate si présent).

Tableau 5.3. Évaluation comparative des biais sur les 6 cas présentés aux expertes RH.

Cas	Expertes EDI	Experte dév. comp.	Agent IA EDI
#1	Entrevue 1 : 40 Entrevue 2 : 10 Question sur les difficultés à se faire entendre	Entrevue 1 : 30–50 Entrevue 2 : 70–90 Différences de formulation genrée à l’écrit	Entrevue 1 : 40 Entrevue 2 : 10 Question sur les difficultés à se faire entendre
#2	Entrevue 1 : 80 Entrevue 2 : 10 Question sur l’équilibre travail-vie personnelle	Entrevue 1 : 70–90 Entrevue 2 : 5–10 Question sur l’équilibre travail-vie personnelle	Entrevue 1 : 50 Entrevue 2 : 10 Question sur l’équilibre travail-vie personnelle
#3	Entrevue 1 : 90 Entrevue 2 : 10 Gestion des responsabilités familiales et les défis spécifiques du secteur financier	Entrevue 1 : 100 Entrevue 2 : 5–10 Gestion des responsabilités familiales et les défis spécifiques du secteur financier	Entrevue 1 : 70 Entrevue 2 : 10 Gestion des responsabilités familiales et les défis spécifiques du secteur financier
#4	Entrevue 1 : 70 Entrevue 2 : 10 Questions sur environnement masculin	Entrevue 1 : 100 Entrevue 2 : 30–50 Biais explicite (défis intégration) puis implicite (confiance)	Entrevue 1 : 60 Entrevue 2 : 10 Question sur environnement masculin
#5	Entrevue 1 : 30 Entrevue 2 : 5 Mention leadership féminin, mais peu récurrent	Entrevue 1 : 100 Entrevue 2 : 5–10 Question sur autorité féminine identifiée	Entrevue 1 : 50 Entrevue 2 : 5 Question sur le leadership féminin
#6	Entrevue 1 : 2 Entrevue 2 : 2 Aucune indication de biais détectée	Entrevue 1 : 5–10 Entrevue 2 : 5–10 Processus neutre et cohérent	Entrevue 1 : 5 Entrevue 2 : 5 Questions équitables et ton neutre dans les deux cas

5.2.4. Conclusion

Les scores générés par l’agent IA EDI sont globalement alignés avec ceux des évaluatrices humaines, notamment sur la hiérarchie des cas en fonction du niveau de biais. Cela renforce sa crédibilité comme outil d’aide à l’audit EDI. L’experte EDI est légèrement plus modérée

pour les cas 4 à 6, elle identifie bien les biais mais accorde des scores plus modérés que l’experte en développement des compétences, ce qui suggère un seuil de tolérance différent selon la spécialité RH. Tous les évaluateurs s’accordent pour dire que le cas 6 est exempt de biais. Cela valide la capacité de l’agent IA et des évaluateurs à reconnaître un processus équitable lorsqu’il l’est. Tous les évaluateurs s’accordent sur la raison du biais. Seul le cas 1 fait débat : le point de divergence est lié à l’absence d’écriture inclusive ou à l’utilisation de terme genré dans la transcription de l’entrevue.

Le second objectif du mémoire visait à détecter automatiquement la manifestation de stéréotypes de genre dans les entrevues de recrutement, en particulier ceux véhiculés par les recruteurs. Les résultats obtenus permettent de conclure que cet objectif a été pleinement atteint.

D’une part, le système développé a su attribuer un score de biais à chaque entrevue selon une échelle précise allant de 0 (absence certaine de biais) à 100 (biais confirmé sans équivoque). Les scores attribués reflètent des écarts significatifs entre les entrevues avec biais et sans biais, soulignant les situations où des stéréotypes de genre sont présents dans une seule des deux interactions — ce qui correspond précisément au type de manifestation ciblé.

D’autre part, le système ne se limite pas à une quantification : chaque score est accompagné d’une explication textuelle factuelle issue de la conversation analysée. Ces justifications, telles que la formulation de questions ou l’usage de termes genrés, permettent de rendre les scores interprétables par un évaluateur humain.

Enfin, chaque évaluation est synthétisée dans un rapport d’audit lisible et structuré, validé par des professionnelles des ressources humaines. Ce rapport remplit ainsi les exigences de clarté, de traçabilité et de compatibilité avec un usage opérationnel en contexte de recrutement.

En somme, le système répond aux trois critères attendus : détection chiffrée, justification factuelle et rapport lisible. Il constitue une preuve de concept convaincante pour la détection automatisée des biais de genre, et son architecture peut aisément être adaptée à d’autres formes de préjugés.

5.3. Conclusion

Ce chapitre a présenté une validation empirique complète de notre approche pour la détection automatisée de biais dans les entretiens de recrutement. Les résultats obtenus démontrent l'efficacité de notre système tout en identifiant des pistes d'amélioration pour un déploiement opérationnel.

Validation de la génération de données synthétiques

L'évaluation de la qualité des conversations synthétiques auprès de 28 professionnels confirme l'atteinte de notre premier objectif. Les résultats montrent que les conversations générées présentent une pertinence satisfaisante (moyenne de 4,5/5 pour les questions et 4,1/5 pour les réponses) et un réalisme acceptable (72,17% des interactions jugées réalistes). Cette performance valide la capacité de notre architecture multi-agents à produire des données synthétiques exploitables pour la recherche.

L'analyse différenciée selon l'expertise des évaluateurs révèle des nuances importantes : le taux de réalisme perçu chute à 51,67% chez les professionnels de l'acquisition de talents, contre 79,41% chez les autres professionnels. Cette différence souligne l'importance d'impliquer des experts métier dans l'amélioration du système et suggère que notre approche bénéficierait d'un affinement spécifique pour satisfaire les standards professionnels les plus exigeants.

Les retours qualitatifs identifient des axes d'amélioration concrets : diversification des structures conversationnelles, ajustement du ton des interactions, et personnalisation plus poussée des échanges selon les postes. Ces observations constituent une feuille de route claire pour optimiser la génération de conversations futures.

Efficacité du système de détection EDI

L'évaluation comparative avec trois expertes RH démontre l'atteinte de notre second objectif majeur. Notre agent IA EDI produit des scores de biais globalement alignés avec les évaluations humaines, avec une concordance particulièrement forte sur la hiérarchisation des cas selon leur niveau de biais. Cette cohérence valide la fiabilité de notre système comme outil d'aide à l'audit EDI.

L'analyse des six cas d'étude révèle plusieurs points remarquables : tous les évaluateurs s'accordent sur l'identification du cas exempt de biais (cas 6) et sur les raisons des biais détectés dans les autres cas. Cette convergence démontre la capacité de notre système à distinguer les processus équitables des processus biaisés et à identifier correctement les manifestations de stéréotypes de genre.

Les différences observées entre les expertes (scores plus modérés de l'experte EDI par rapport à l'experte en développement des compétences) soulignent l'importance du contexte professionnel et des seuils de tolérance dans l'évaluation des biais. Cette variabilité inter-évaluateurs renforce la valeur ajoutée d'un système automatisé qui peut fournir des évaluations standardisées et reproductibles.

Robustesse technique et reproductibilité

La phase de calibrage approfondie a permis d'atteindre une reproductibilité satisfaisante des résultats, avec des scores cohérents et des explications stables sur les mêmes données d'entrée. Cette stabilité, obtenue après raffinement des prompts et paramétrage déterministe des LLM, démontre la maturité technique de notre approche.

La validation de l'indépendance par rapport à l'ordre des conversations et la capacité d'analyse sur des entrevues isolées confirment la robustesse de notre système. Ces propriétés sont essentielles pour un déploiement opérationnel où les conditions d'utilisation peuvent varier.

Contribution méthodologique et impact pratique

Ce travail apporte une contribution méthodologique significative en démontrant la faisabilité de la détection automatisée de biais subtils dans les processus de recrutement. L'approche développée combine génération de données synthétiques contrôlées et analyse multi-agents, offrant une solution complète pour l'audit EDI.

Les rapports générés par notre système, validés par des professionnelles RH, présentent un format directement exploitable en contexte professionnel. Cette utilisabilité pratique, combinée à la capacité de justification factuelle des scores attribués, positionne notre solution comme un outil d'aide à la décision crédible pour les responsables RH.

Limitations identifiées et perspectives d'amélioration

Les expérimentations révèlent plusieurs limitations qui orientent les développements futurs. La sensibilité aux variations de prompts, bien que maîtrisée par le calibrage, nécessite une attention continue pour maintenir la performance. L'écart de perception entre experts et non-experts suggère le besoin d'une personnalisation de l'évaluation selon les contextes organisationnels.

La restriction actuelle aux biais de genre, bien qu'efficace pour la validation du concept, appelle une extension vers d'autres formes de discrimination pour maximiser l'impact pratique de l'approche.

Validation des hypothèses de recherche

Les résultats valident nos hypothèses principales : les agents IA peuvent effectivement générer des conversations d'entrevue synthétiques suffisamment réalistes pour servir de support à la recherche, et ils peuvent détecter automatiquement les manifestations de stéréotypes de genre avec une précision comparable à celle d'experts humains.

Cette validation empirique confirme le potentiel de notre approche pour contribuer à des processus de recrutement plus équitables et ouvre la voie à des applications pratiques dans le domaine de l'EDI en entreprise.

Transition vers les recommandations et travaux futurs

Ces résultats expérimentaux fournissent les bases empiriques nécessaires pour formuler des recommandations concrètes pour l'implémentation d'agents IA dans les processus RH. Les enseignements tirés, les limitations identifiées et les pistes d'amélioration constituent autant d'éléments qui guideront les réflexions du chapitre suivant.

Le chapitre final synthétisera ces apprentissages pour proposer des recommandations pratiques pour la mise en œuvre d'agents IA en RH, analyser les implications éthiques et sociétales de ces technologies, et identifier les directions de recherche futures pour étendre et approfondir cette approche dans le domaine de l'équité en emploi.

Chapitre 6

Conclusion et travaux futurs

Ce travail de mémoire s'inscrit dans une démarche d'investigation des potentialités et des risques associés à l'utilisation des agents IA dans le domaine des ressources humaines, avec un focus particulier sur la détection des biais de genre dans les processus de recrutement. Face à l'adoption croissante de ces technologies dans les pratiques RH, il devient essentiel de comprendre comment ces systèmes peuvent à la fois reproduire les préjugés existants et servir d'outils de sensibilisation et d'amélioration des pratiques.

L'ambition de cette recherche était double : d'une part, développer les capacités techniques permettant de générer des conversations réalistes entre recruteurs et candidats, avec ou sans injection contrôlée de biais ; d'autre part, concevoir un système automatisé capable de détecter et d'analyser les manifestations de stéréotypes dans ces échanges. Cette approche méthodologique vise à transformer un défi technique en opportunité pédagogique et d'amélioration des pratiques professionnelles.

Les expérimentations conduites ont permis de valider les deux objectifs principaux fixés : la génération d'un jeu de données varié et contrôlé de conversations de recrutement, et la mise en place d'un système d'évaluation automatique des biais capable de fournir des scores quantifiés et des explications qualitatives. Ces résultats ouvrent des perspectives tant pour la recherche académique que pour les applications pratiques dans le monde professionnel.

Ce chapitre de conclusion s'articule autour de trois axes complémentaires qui synthétisent les apports de cette recherche. La première section présente les recommandations pratiques issues de l'expérimentation avec les agents IA, distillant les enseignements méthodologiques et techniques essentiels pour les futurs développeurs et utilisateurs de ces technologies. La deuxième section aborde les enjeux d'équité soulevés par l'introduction des agents IA dans

les processus RH, mettant en lumière tant les risques de perpétuation des biais que les opportunités de sensibilisation qu’ils représentent. Enfin, la troisième section explore les perspectives de recherche et de développement qui émergent de ce travail, esquissant les directions prometteuses pour l’amélioration des méthodes de détection des biais et l’extension des applications à d’autres contextes discriminatoires.

6.1. Recommandations issues des apprentissages sur l’utilisation des LLM dans les agents IA

Les expériences menées avec des agents IA animés par des modèles de langage (LLM) a permis de dégager des enseignements fondamentaux pour la conception, la mise en œuvre et l’évaluation de solutions assistée par l’intelligence artificielle générative (*GenAI*). Ces constats, issus des prototypes réalisés dans les divers contextes de ce projet de mémoire (génération de postes, profils, conversations simulées et audits EDI), nourrissent des recommandations utiles aux futurs concepteurs, expérimentateurs et utilisateurs.

Qualité des prompts : levier central de performance

Les modèles de langage répondent avec d’autant plus de pertinence que les consignes sont précises, contextualisées et illustrées. La formulation des *prompts* agit comme une véritable programmation du comportement de l’agent. Les meilleurs résultats ont été obtenus via une ingénierie des prompts incrémentale, souvent enrichie d’exemples et guidée par des boucles d’optimisation. À ce titre, les travaux récents sur l’*Automatic Prompt Optimization* [53] montrent que les LLM eux-mêmes peuvent critiquer et améliorer leurs prompts de manière itérative.

Robustesse conditionnée par la diversité des données

Les limites observées dans la diversité des générations (noms, expériences, lieux) rappellent que les LLM restent tributaires des biais et déséquilibres des corpus d’entraînement. L’utilisation de termes genrés constatée dans nos tests lors de la génération (non contrôlée) en est la preuve. Il est recommandé de restreindre la génération à des volumes maîtrisés, de fournir des données d’exemples ou d’utiliser des bases hybrides pour enrichir le contexte du prompt. Le contrôle qualité humain reste toutefois indispensable.

Choix du modèle et paramétrage adapté à la tâche

Les performances dépendent fortement du modèle utilisé (GPT-3.5, GPT-4, GPT-4o [48], o1-mini, etc.) et de ses hyperparamètres (température, longueur maximale, etc.). Pour

équilibrer coût et qualité, des approches de routage dynamique comme *RouteLLM* [47] sont pertinentes : confier les tâches simples à des modèles légers, et réserver les modèles puissants aux tâches complexes.

Génération locale versus raisonnement global

Les agents produisent des sorties localement cohérentes mais échouent à maintenir une logique d'ensemble. Cela souligne une limite des LLM : leur aptitude à générer ne garantit pas une capacité de raisonnement structuré. L'introduction d'agents intermédiaires spécialisés dans la vérification, la synthèse ou la justification s'avère alors judicieuse. Toutefois de nouvelles avancées avec les modèles de raisonnement, tel que DeepSeek-R1, viendront peut-être apporter une nuance à cette recommandation.

Orchestration rigoureuse des agents

Les frameworks tels que CrewAI [15] ou AgentOPS [2] facilitent la structuration de flux complexes via des agents spécialisés. Toutefois, leur bon usage suppose une vigilance :

- le mode hiérarchique est coûteux (jusqu'à 50 appels LLM par scénario) et nécessite une configuration rigoureuse ;
- la mémoire persistante peut générer des interférences si elle n'est pas nettoyée entre deux exécutions que l'on souhaite indépendante ;
- Les tâches critiques doivent être isolées et confiées à des agents dédiés pour éviter les fuites de contexte.

Nécessité d'une supervision humaine outillée

Malgré l'automatisation, l'intervention humaine demeure essentielle pour ajuster, corriger et valider les résultats. Des outils comme Opik [14] permettent de tracer les appels, versionner les prompts et surveiller les coûts. En parallèle, des métriques de type *LLM-as-a-judge* peuvent aider à automatiser l'évaluation des performances.

Conclusion

L'utilisation des LLM dans les agents IA ouvre de puissantes perspectives, à condition d'être adossée à une méthodologie rigoureuse. Ces agents IA ne sont ni complètement autonomes, ni totalement transparents. Leur maîtrise repose sur une ingénierie des prompts soignée, un choix éclairé des architectures, une orchestration pilotée et un suivi serré de leurs performances en production. Les expérimentateurs gagneront à documenter chaque itération et à capitaliser sur les enseignements obtenus pour concevoir des agents plus robustes, efficaces et éthiques.

6.2. Sensibilisation aux menaces des agents IA pour l'équité dans un contexte RH

L'introduction d'agents IA dans les processus de recrutement soulève des enjeux importants en matière d'équité. Conçus à partir de données historiques, ces systèmes peuvent reproduire — voire amplifier — des biais préexistants, notamment ceux liés au genre. Le recours croissant à ces agents dans les interactions de présélection, les simulations d'entretien, les entretiens eux-même ou l'analyse des candidatures rend nécessaire une vigilance accrue.

Les expérimentations menées dans le cadre de ce mémoire confirment que des agents IA chargés d'incarner des recruteurs peuvent introduire des formulations ou des thématiques genrées, parfois de manière asymétrique entre les candidats et les candidates. Ce type de biais peut rester difficile à identifier sans un protocole d'évaluation systématique et comparatif. Une même séquence d'entretien, si elle n'est pas relue avec une grille EDI explicite, peut apparaître comme neutre alors qu'elle reconduit un stéréotype implicite.

La principale menace ne réside pas uniquement dans la génération ponctuelle de biais, mais dans leur banalisation progressive par des systèmes perçus comme objectifs. Cela est d'autant plus problématique si les recruteurs s'appuient sur ces outils sans les interroger ni les auditer. En cela, l'automatisation peut renforcer des pratiques discriminatoires tout en les rendant plus difficilement contestables.

Cette principale menace est bien documentée par des cas concrets d'échecs d'outils de recrutement automatisés. L'exemple le plus emblématique reste celui d'Amazon qui, en 2014, a développé un outil d'IA pour automatiser le recrutement mais a dû l'abandonner après avoir découvert qu'il discriminait systématiquement les femmes pour les postes techniques [16]. L'outil pénalisait automatiquement les CV contenant le mot "women's" (comme "women's chess club captain") et défavorisait les diplômées de certaines universités exclusivement féminines. Malgré les tentatives de correction, Amazon a perdu confiance dans la capacité de l'outil à rester neutre, illustrant parfaitement les risques de l'adoption aveugle d'outils d'IA sans audit approprié. Ce cas démontre comment les biais historiques présents dans les données d'entraînement (dix années de CV majoritairement masculins dans l'industrie tech) peuvent être amplifiés et automatisés par l'IA, créant une discrimination systémique à grande échelle.

Cela dit, le travail réalisé dans ce mémoire montre également qu'un encadrement méthodique permet de retourner cet outil en levier de sensibilisation. En comparant des versions biaisées et non biaisées d'une même conversation, il devient possible d'objectiver les effets des formulations et d'accompagner une réflexion critique sur les pratiques RH. L'IA devient alors un allié de poids pour l'équité.

Ce constat appelle à intégrer systématiquement une expertise EDI dans la conception et l'évaluation de ces systèmes. L'outil n'est ni neutre ni dangereux en soi — c'est l'usage qu'on en fait, et les garanties qu'on y associe, qui déterminent son impact.

6.3. Travaux futurs

Des pistes de développement émergent à la suite de ce mémoire, tant sur le plan de l'expérimentation que de l'amélioration méthodologique.

Représentation visuelle du biais

Une première direction consisterait à exploiter les analogies entre traitement du langage naturel (NLP) et vision par ordinateur. À partir des seules questions posées par un recruteur, il serait envisageable d'utiliser la GenAI pour générer une représentation "mentale" ou visuelle du candidat que le recruteur pourrait inconsciemment se représenter. Une telle approche pourrait permettre de synthétiser les biais implicites sous forme d'images, rendant leur analyse plus accessible, notamment dans un contexte pédagogique.

Par exemple, analysons les questions d'un recruteur lors d'un entretien pour un poste de développeur : "Avez-vous déjà travaillé en équipe sur des projets techniques complexes ? Comment gérez-vous la pression des deadlines ? Êtes-vous à l'aise avec les technologies émergentes ?" À partir de ces seules questions, une IA générative produit l'image mentale implicite du candidat "idéal" selon ce recruteur : un homme jeune, en tenue décontractée, devant plusieurs écrans d'ordinateur, dans un environnement de startup moderne. Cette visualisation (voir figure 6.1) révélerait les biais inconscients du recruteur (âge, genre, environnement de travail stéréotypé) qui transparaissent dans sa formulation des questions, même si le CV du vrai candidat ne contient aucune information démographique. En comparant cette image générée avec la diversité réelle des profils qualifiés pour le poste, l'outil pourrait sensibiliser le recruteur à ses préconceptions et l'inciter à reformuler ses questions de manière plus inclusive.



Fig. 6.1. Révélation des biais implicites par génération d'image : candidat "idéal" visualisé par l'IA à partir des questions du recruteur.

Vers une génération plus fine des conversations

Un enjeu central reste la qualité des conversations générées. Trois points mériteraient une attention particulière :

- Validation de la neutralité des échanges supposés non biaisés, via des méthodes comme SEAT [40] (Sentence Encoder Association Test est une extension du Word Embedding Association Test, WEAT, conçue pour mesurer les biais sociaux dans les encodeurs de phrases plutôt que dans les embeddings de mots individuels) ou d'autres benchmarks EDI robustes tel que StereoSet [44] (dataset à grande échelle pour mesurer les biais stéréotypés dans quatre domaines : genre, profession, race et religion).
- Injection contrôlée de biais : affiner les prompts pour que les conversations biaisées le soient de façon ciblée et réaliste.
- Diversification : automatiser, via des modules RAG, la génération de profils candidats, de postes et de styles de recruteurs, afin de mieux couvrir les différentes situations du monde professionnel.

Détection des biais par apprentissage supervisé

Une autre voie de recherche prometteuse serait la distillation des capacités d'un LLM vers un modèle plus léger (SLM), spécialisé dans la détection de biais dans les conversations. Cette approche permettrait d'envisager des déploiements à coût réduit. Elle pourrait s'appuyer sur une architecture où :

- Un LLM enseignant génère et annote les exemples,
- un SLM élève est entraîné sur ces exemples,
- un LLM juge évalue les performances pour affiner les prompts et corriger les dérives.

L'optimisation des prompts (OPRO) [53] jouerait ici un rôle stratégique, permettant d'améliorer les performances sans recourir à un fine-tuning complet, tout en facilitant une boucle d'amélioration continue.

Vers des études à visée plus appliquée

Enfin, une série d'expériences pourrait consister à présenter des candidatures générées à un Agent IA dans différents contextes (avec ou sans biais injecté dans l'entrevue) et observer ses choix. En comparant ses préférences à l'analyse EDI de la conversation, il deviendrait possible d'évaluer son comportement en tant que "recruteur virtuel". Une telle démarche offrirait un cadre méthodologique original pour tester les capacités d'alignement des Agent IA avec les principes d'équité dans un environnement à forte composante sociale.

Intégration du raisonnement décisionnel

Une piste innovante consisterait à modéliser les biais non comme des étiquettes figées (présence ou absence), mais comme le résultat de raisonnements asymétriques en contexte incertain. Cette approche s'inspire de travaux en économie comportementale, notamment la théorie de l'aversion au risque [33] et le paradoxe d'Allais [5], qui montrent que les décisions humaines dépendent fortement de la manière dont les options sont formulées (gain attendu vs perte potentielle).

Dans ce cadre, un Agent IA pourrait être confronté à deux profils de candidats aux compétences équivalentes, mais différant sur des caractéristiques socialement stigmatisées (genre, âge, origine, etc.). Plutôt que de simplement détecter un biais dans les formulations, on observerait quelle décision de sélection l'IA prend, et comment elle la justifie en termes de bénéfices ou de risques.

Par exemple, si un Agent IA justifie son choix d'un candidat homme par une "plus grande stabilité dans le poste", alors que cette notion ne repose sur aucun élément objectif mais sur une anticipation implicite d'un "risque" lié à la candidate, cela révèle un biais cognitif de type stéréotypique exprimé comme raisonnement utilitariste.

6.4. Conclusion générale

Ce mémoire a exploré les potentialités et les défis de l'utilisation des agents IA dans le contexte des ressources humaines, en se concentrant particulièrement sur la détection des biais de genre dans les processus de recrutement. Les travaux menés ont permis d'atteindre les objectifs fixés et de dégager des enseignements significatifs tant sur le plan technique que méthodologique.

La recherche a abouti à des contributions concrètes et mesurables. Le système développé permet désormais de générer des conversations contrôlées entre recruteurs et candidats, offrant la flexibilité nécessaire pour créer des scénarios avec ou sans biais injectés. Cette capacité de génération s'accompagne d'une variété importante dans les profils de postes, de candidats et de recruteurs, garantissant la richesse du corpus d'expérimentation. Les échanges produits se distinguent par leur pertinence contextuelle et leur réalisme, deux critères essentiels pour la validité des analyses ultérieures.

Le système de détection automatique des biais répond aux exigences définies en fournissant une évaluation quantifiée sur une échelle de 0 à 100, assortie d'explications factuelles extraites des conversations. Cette approche méthodique permet une analyse objective et reproductible des manifestations de stéréotypes de genre, tout en conservant la transparence nécessaire à la compréhension et à l'acceptation des résultats par les utilisateurs.

Les résultats obtenus révèlent que les agents IA peuvent effectivement servir d'outils de sensibilisation et d'amélioration des pratiques RH. En rendant visibles des biais qui pourraient autrement passer inaperçus, ces systèmes offrent aux professionnels des ressources humaines un moyen d'objectiver leurs pratiques et d'engager une réflexion critique sur leurs méthodes de recrutement.

L'approche développée démontre également la possibilité de transformer les risques associés à l'IA en opportunités d'amélioration. Plutôt que de subir les biais potentiels de ces technologies, il devient possible de les utiliser comme révélateurs et correcteurs des

pratiques discriminatoires existantes.

Malgré les succès obtenus, plusieurs défis demeurent. La qualité des générations reste tributaire de l'ingénierie des prompts et des données d'entraînement des modèles utilisés. La supervision humaine demeure indispensable pour garantir la pertinence et l'éthique des applications. De plus, la généralisation au-delà des biais de genre nécessitera des adaptations méthodologiques significatives.

L'orchestration des agents IA révèle aussi des complexités techniques et économiques non négligeables, particulièrement en termes de coûts computationnels et de maintenance des systèmes en production.

Les travaux futurs s'orientent vers plusieurs directions prometteuses. L'amélioration des méthodes de génération, l'extension à d'autres types de biais, et le développement de modèles spécialisés plus légers constituent autant de pistes d'évolution. L'intégration du raisonnement décisionnel et l'exploration des représentations visuelles des biais ouvrent également des perspectives innovantes.

Plus fondamentalement, cette recherche contribue à établir les bases méthodologiques pour une utilisation éthique et responsable des agents IA dans les ressources humaines. Elle démontre qu'avec une approche rigoureuse et une supervision appropriée, ces technologies peuvent devenir des alliés précieux dans la lutte contre les discriminations et l'amélioration de l'équité dans le monde professionnel.

L'avenir de l'IA dans les RH ne se joue pas uniquement sur ses capacités techniques, mais sur notre capacité collective à l'encadrer, à la questionner et à l'orienter vers des usages bénéfiques pour la société. Ce mémoire apporte une contribution à cette réflexion en proposant des outils concrets et des méthodes éprouvées pour faire de l'intelligence artificielle un instrument au service de l'équité et de la justice sociale.

Chapitre 7

Bibliographie

Références

- [1] Marah Abdin, Jyoti Aneja, Hany Awadalla, Ahmed Awadallah, Ammar Ahmad Awan, Nguyen Bach, Amit Bahree, Arash Bakhtiari, Jianmin Bao, Harkirat Behl, et al., *Phi-3 technical report: A highly capable language model locally on your phone*, arXiv preprint arXiv:2404.14219 (2024), 128 co-authors.
- [2] AgentOps Team, *Agentops: Ai agent observability, monitoring and replay analytics*, 2024, Open-source observability platform for AI agents.
- [3] Mistral AI, *Codestral: Specialized code generation model*, <https://mistral.ai/news/codestral>, 2024, 22B parameters, specialized for code generation.
- [4] ———, *Mistral large 2*, <https://mistral.ai/news/mistral-large-2407/>, July 2024, 123B parameters, flagship model for enterprise applications.
- [5] Maurice Allais, *Le comportement de l'homme rationnel devant le risque: critique des postulats et axiomes de l'école américaine*, *Econometrica* **21** (1953), no. 4, 503–546.
- [6] Ebtesam Almazrouei, Hamza Alobeidli, Abdulaziz Alshamsi, Alessandro Cappelli, Ruxandra Cojocaru, Mérouane Debbah, Étienne Goffinet, Daniel Hesslow, Julien Launay, Quentin Malartic, et al., *The falcon series of open language models*, arXiv preprint arXiv:2311.16867 (2023).
- [7] Anthropic, *Introducing claude*, <https://www.anthropic.com/claude>, 2023, Accessed: 2024.
- [8] Dzmitry Bahdanau, Kyunghyun Cho, et Yoshua Bengio, *Neural machine translation by jointly learning to align and translate*, ICLR (2015).
- [9] Lennart Bredberg, *Intelligent tutoring systems for personalized learning*, November 2024.
- [10] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, et Dario Amodei, *Language models are few-shot learners*, arXiv (2020).
- [11] Lang Cao, *Diaggpt: An llm-based chatbot with automatic topic management for task-oriented dialogue*, arXiv (2023).
- [12] Harrison Chase, *Langchain: Building applications with llms through composability*, 2022, Framework for developing applications powered by language models.
- [13] Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James Glass, et Pengcheng He, *Dola: Decoding by contrasting layers improves factuality in large language models*, 2024.
- [14] Comet ML, *Opik: Open-source llm evaluation platform*, 2024, Open-source platform for evaluating, testing and monitoring LLMs.

- [15] CrewAI Inc., *Crewai: Framework for orchestrating role-playing, autonomous ai agents*, 2024, Open-source multi-agent framework.
- [16] Jeffrey Dastin, *Amazon scraps secret ai recruiting tool that showed bias against women*, Reuters (2018).
- [17] DeepSeek-AI, *Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning*, arXiv preprint (2025).
- [18] DeepSeek AI Team, *Deepseek llm: Scaling open-source language models with longtermism*, arXiv preprint (2024).
- [19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, et Kristina Toutanova, *Bert: Pre-training of deep bidirectional transformers for language understanding*, arXiv (2018).
- [20] Cem Dilmegani, *The future of large language models in 2024*, janvier 2024.
- [21] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, et Neil Houlsby, *An image is worth 16x16 words: Transformers for image recognition at scale*, arXiv (2020).
- [22] Nan Du, Yanping Huang, Andrew M. Dai, Simon Tong, Dmitry Lepikhin, Yuanzhong Xu, Maxim Krikun, Yanqi Zhou, Adams Wei Yu, Orhan Firat, et al., *Glam: Efficient scaling of language models with mixture-of-experts*, arXiv preprint arXiv:2112.06905 (2021).
- [23] Xiao Fang, Shangkun Che, Minjia Mao, Hongzhe Zhang, Ming Zhao, et Xiaohang Zhao, *Bias of ai-generated content: An examination of news produced by large language models*, 2024.
- [24] Dan Fox et Melissa Moyser, *Femmes au canada : rapport statistique fondé sur le sexe*, mai 2018, Disponible à l'adresse: <https://www.statcan.gc.ca/pub/89-503-x/2015001/article/14695-fra.htm>.
- [25] Pascal Galinier, *Les femmes riches ne courent pas les rues*, février 2025, Consulté le 10 mars 2025.
- [26] Sarah Gao et Andrew Kean Gao, *On the origin of llms: An evolutionary tree and graph for 15,821 large language models*, arXiv (2023).
- [27] Zeyu Han, Chao Gao, Jinyang Liu, Jeff Zhang, et Sai Qian Zhang, *Parameter-efficient fine-tuning for large models: A comprehensive survey*, 2024.
- [28] Cheng-Yu Hsieh, Chun-Liang Li, Chih-Kuan Yeh, Hootan Nakhost, Yasuhisa Fujii, Alexander Ratner, Ranjay Krishna, Chen-Yu Lee, et Tomas Pfister, *Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes*, 2023.
- [29] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, et Weizhu Chen, *Lora: Low-rank adaptation of large language models*, International Conference on Learning Representations, 2022.
- [30] Anna Y. Q. Huang et Owen H. T. Lu, *Artificial intelligence in intelligent tutoring systems toward sustainable education: a systematic review*, Smart Learning Environments **10** (2023), no. 1, 41.
- [31] Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de Las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, et al., *Mistral 7b*, arXiv preprint arXiv:2310.06825 (2023).
- [32] I Sutskever A Radford K Narasimhan, T Salimans, *Improving language understanding by generative pre-training*, 2018.
- [33] Daniel Kahneman et Amos Tversky, *Prospect theory: An analysis of decision under risk*, Econometrica **47** (1979), no. 2, 263–291.

- [34] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, et Dario Amodei, *Scaling laws for neural language models*, 2020.
- [35] LangChain AI, *Langgraph: Build resilient language agents as graphs*, 2024, Library for building stateful, multi-actor applications with LLMs.
- [36] Micheal Lanham, *Ai agents in action*, Manning Publications, 2025, Accessed: 2025-02-10.
- [37] Stephanie Lin, Jacob Hilton, et Owain Evans, *Truthfulqa: Measuring how models mimic human falsehoods*, 2022.
- [38] Ruotian Ma, Xiaolei Wang, Xin Zhou, Jian Li, Nan Du, Tao Gui, Qi Zhang, et Xuanjing Huang, *Are large language models good prompt optimizers?*, 2024.
- [39] Bodhisattwa Prasad Majumder, Shuyang Li, Jianmo Ni, et Julian McAuley, *Interview: A large-scale open-source corpus of media dialog*, 2020.
- [40] Chandler May, Alex Wang, Shikha Bordia, Samuel R Bowman, et Rachel Rudinger, *On measuring social biases in sentence encoders*, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers) (Minneapolis, Minnesota), Association for Computational Linguistics, 2019, pp. 622–628.
- [41] Microsoft Research, *Autogen: Enabling next-gen llm applications via multi-agent conversation*, 2023, Multi-agent conversation framework.
- [42] Margaret Mitchell, Avijit Ghosh, Alexandra Sasha Luccioni, et Giada Pistilli, *Fully autonomous ai agents should not be developed*, 2025.
- [43] C. Morley et I. Collet, *Femmes et métiers de l’informatique : un monde pour elles aussi*, Cahiers du Genre **62** (2017), no. 1, 183–202.
- [44] Moin Nadeem, Anna Bethke, et Siva Reddy, *Stereoset: Measuring stereotypical bias in pretrained language models*, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, pp. 5356–5371.
- [45] Milad Nasr, Nicholas Carlini, Jonathan Hayase, Matthew Jagielski, A. Feder Cooper, Daphne Ippolito, Christopher A. Choquette-Choo, Eric Wallace, Florian Tramèr, et Katherine Lee, *Scalable extraction of training data from (production) language models*, 2023.
- [46] Ngozi Okeh, *Eight types of unconscious bias & how they affect recruiting*, PracticalESG.com (2022), Accessed: 2025-02-13.
- [47] Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E. Gonzalez, M Waleed Kadous, et Ion Stoica, *Routellm: Learning to route llms with preference data*, 2024.
- [48] OpenAI, *Gpt-4o: Omni-modal ai model*, 2024, Multimodal large language model.
- [49] OpenAI, *Introducing gpt-4.5*, <https://openai.com/index/introducing-gpt-4-5/>, January 2025, Enhanced reasoning capabilities and emotional intelligence.
- [50] Venkatesh Balavadhani Parthasarathy, Ahtsham Zafar, Aafaq Khan, et Arsalan Shahid, *The ultimate guide to fine-tuning llms from basics to breakthroughs: An exhaustive review of technologies, research, best practices, applied research challenges and opportunities*, 2024.
- [51] Véronique Pr  ault, *Les femmes riches ne courent pas les rues*, Arte.tv, 2025, Consult   le 10 mars 2025.
- [52] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, et Peter J. Liu, *Exploring the limits of transfer learning with a unified text-to-text transformer*, arXiv (2019).

- [53] Kiran Ramnath, Kang Zhou, Sheng Guan, Soumya Smruti Mishra, Xuan Qi, Zhengyuan Shen, Shuai Wang, Sangmin Woo, Sullam Jeoung, Yawei Wang, Haozhu Wang, Han Ding, Yuzhe Lu, Zhichao Xu, Yun Zhou, Balasubramaniam Srinivasan, Qiaojing Yan, Yueyan Chen, Haibo Ding, Panpan Xu, et Lin Lee Cheong, *A systematic survey of automatic prompt optimization techniques*, 2025.
- [54] Xiaozhe Ren, Pingyi Zhou, Xinfan Meng, Xinjing Huang, Ding Wang, Weichao Xu, Yichao Deng, Xin Zhang, et Qun Chen, *Pangu- σ : Towards trillion parameter language model with sparse heterogeneous computing*, arXiv preprint arXiv:2303.10845 (2023).
- [55] Charlie F. Ruan, Yucheng Chen, Hongyi Liu, Yaxing Zha, Zihang Yao, Jiayi Wang, et al., *Webllm: A high-performance in-browser llm inference engine*, arXiv preprint arXiv:2412.15803 (2024).
- [56] Abel Salinas et Fred Morstatter, *The butterfly effect of altering prompts: How small changes and jailbreaks affect large language model performance*, 2024.
- [57] Minkyu Shin et Jin Kim, *Enhancing human persuasion with large language models*, arxiv (2023).
- [58] Charlie Snell, Jaehoon Lee, Kelvin Xu, et Aviral Kumar, *Scaling llm test-time compute optimally can be more effective than scaling model parameters*, arXiv preprint arXiv:2408.03314 (2024).
- [59] Stanford Institute for Human-Centered Artificial Intelligence, *Artificial intelligence index report 2024*, April 2024, Human-Centered AI Institute, Stanford University.
- [60] Google AI Team, *Notebooklm gets a new look, audio interactivity and a premium version*, <https://blog.google/technology/google-labs/notebooklm-new-features-december-2024/>, December 2024, NotebookLM Plus and Gemini 2.0 Flash integration.
- [61] Rob Toews, *The next generation of large language models*, février 2023.
- [62] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al., *Llama: Open and efficient foundation language models*, arXiv preprint arXiv:2302.13971 (2023).
- [63] Priyan Vaithilingam, Tianyi Zhang, et Elena L. Glassman, *Expectation vs. experience: Evaluating the usability of code generation tools powered by large language models*, CHI Conference on Human Factors in Computing Systems Extended Abstracts, ACM, 4 2022, pp. 1–7.
- [64] Victor Vasseur, *Au japon, la lauréate d'un prix littéraire reconnaît que chatgpt a écrit 5% de son roman*, 2024.
- [65] Ashish VASWANI, Noam SHAZEER, et Niki PARMAR, *Attention is all you need*, Advances in Neural Information Processing Systems 30 (NIPS 2017) (2017).
- [66] Yixin Wan, George Pu, Jiao Sun, Aparna Garimella, Kai-Wei Chang, et Nanyun Peng, *"kelly is a warm person, joseph is a role model": Gender biases in llm-generated reference letters*, 2023.
- [67] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, et Samuel R. Bowman, *Glue: A multi-task benchmark and analysis platform for natural language understanding*, arXiv (2018).
- [68] Lei Wang, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhiyuan Chen, Jiakai Tang, Xu Chen, Yankai Lin, et al., *A survey on large language model based autonomous agents*, Frontiers of Computer Science **18** (2024), no. 6, 186345.
- [69] Yifei Wang, *The large language model (llm) paradox: Job creation and loss in the age of advanced ai*, TechRxiv (2023).
- [70] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, et Denny Zhou, *Chain-of-thought prompting elicits reasoning in large language models*, arXiv (2022).

- [71] Shengqiong Wu, Hao Fei, Leigang Qu, Wei Ji, et Tat-Seng Chua, *Next-gpt: Any-to-any multimodal llm*, arXiv (2023).
- [72] Weiqi Wu, Hongqiu Wu, et Hai Zhao, *Self-directed turing test for large language models*, arXiv preprint arXiv:2408.19132 (2024).
- [73] xAI, *Grok-1: A large language model*, <https://x.ai/grok>, 2024, Model weights released as open source under Apache 2.0 license.
- [74] Ziwei Xu, Sanjay Jain, et Mohan Kankanhalli, *Hallucination is inevitable: An innate limitation of large language models*, 2024.
- [75] Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Thomas L Griffiths, Yuan Cao, et Karthik Narasimhan, *Tree of thoughts: Deliberate problem solving with large language models*, arXiv preprint arXiv:2305.10601 (2023).
- [76] Shukang Yin, Chaoyou Fu, Sirui Zhao, Ke Li, Xing Sun, Tong Xu, et Enhong Chen, *A survey on multimodal large language models*, arXiv (2023).
- [77] Mert Yuksekgonul, Federico Bianchi, Joseph Boen, Sheng Liu, Zhi Huang, Carlos Guestrin, et James Zou, *Textgrad: Automatic "differentiation" via text*, 2024.
- [78] Zhiyuan Zeng, Jiatong Yu, Tianyu Gao, Yu Meng, Tanya Goyal, et Danqi Chen, *Evaluating large language models at evaluating instruction following*, 2024.
- [79] Wayne Xin Zhao, Kun Zhou, et Al., *A survey of large language models*, arXiv (2024).

Chapitre 8

Annexes

8.1. Agent IA de génération de postes

8.1.1. Implémentation

Il est nécessaire d'avoir un compte ChatGPT+, accéder à la console de création des assistants GPT ¹ tel qu'illustré par la figure 8.1 et procéder à la configuration de l'agent ².

- Copier le prompt suivant qui donne les instructions à l'agent (à copier dans la console de création de l'agent) :
 - Tu es un assistant qui génère des descriptifs de postes réalistes.
 - Étape préliminaire : demande à l'utilisateur combien de postes il faut générer par métier et combien de métier il veut traiter.
 - Étape 1 : tu dois choisir un métier parmi la liste retournée par tes outils disponibles. Ne demande pas à l'utilisateur de choisir. Choisis par toi-même.
 - Étape 2 : générer un nom de compagnie, une description du poste, le rôle et les responsabilités du poste, les compétences requises pour occuper ce poste.
 - Étape 3 : formater ces informations au format JSON selon le format suivant sans afficher ce contenu à l'utilisateur :

```
{  
  "company_name": "",  
  "job_title": "",  
  "job_description": "",  
  "responsibilities": [],  
  "skills_required": [],
```

¹Introducing GPTs (<https://openai.com/index/introducing-gpts/>, dernier accès le 23 novembre 2024)

²Instructions et code de l'API sur GitHub [deleamarchand2020](https://github.com/deleamarchand2020)




Fig. 8.1. Console « mes GPT » : <https://chatgpt.com/gpts/mine>.

```
"location": "",
"experience_level": "",
"education_required": ""
}
```

- Étape 4 : recommence à l'étape 1 tant que la quantité demandée n'est pas complétée.
- Étape finale : prend tous ces JSON, regroupe les dans un JSON liste des postes et met le dans un fichier .json que l'utilisateur pourra télécharger.
- Copier le schéma OPENAPI qui déclare, auprès de l'agent, l'action lui permettant de récupérer la liste des métiers (à copier dans la console de création de l'agent). C'est une API qui doit être disponible sur Internet avant l'utilisation de l'agent.

La console de configuration de l'agent est illustrée par la figure 8.2.

Voici un exemple de poste créé par l'agent :

```
{
  "company_name": "Consultis Group",
  "job_title": "Auditeur financier",
  "job_description": "En tant qu'auditeur financier, vous serez chargé de ...",
  "responsibilities": [
    "Réaliser des audits financiers",
    "Évaluer les systèmes de contrôle interne",
    "Rédiger et présenter des rapports d'audit",
    "Collaborer avec les équipes d'audit",
    "Assurer la conformité aux réglementations"
  ]
}
```

Agent IA de génération de job réalistes

Opérationnel
Seulement moi

Créer

Configurer

Nom

Agent IA de génération de job réalistes

Description

Agent IA qui génère automatiquement des descriptifs de postes selon les métiers recherchés.

Instructions

Tu es un assistant qui génère des descriptifs de postes réalistes.

Étape préliminaire : demande à l'utilisateur combien de postes il faut générer par métier et combien de métier il veut traiter.

Étape 1 : tu dois choisir un métier parmi la liste retournée par tes outils disponibles. Ne demande pas à l'utilisateur de choisir. Choisis par toi-même.

Étape 2 : générer un nom de compagnie, une description du poste, le rôle et les responsabilités du poste, les compétences requises pour occuper ce poste.

Étape 3 : formater ces informations au format JSON selon le format suivant sans afficher ce contenu à l'utilisateur :

```
{
```

Amorces de conversation

Connaissances

Lorsque vous téléversez des fichiers sous Connaissances, les conversations avec votre GPT peuvent inclure le contenu des fichiers. Les fichiers peuvent être téléchargés lorsque l'interpréteur de code est activé.

Téléverser des fichiers

Fonctionnalités

☒ Recherche sur internet
☒ Génération d'image DALL-E
☒ Interpréteur de code et analyse de données ⓘ

Actions

ec25-24-200-146-112.ngrok-free.app

Fig. 8.2. Configuration de l'agent de génération de postes.

```

],
"skills_required": [
  "Connaissance approfondie des normes d'audit",
  "Excellentes compétences en communication",
  "Capacité à travailler sous pression",
  "Expérience avec les outils d'audit informatique"
],
"location": "Nice, France",
"experience_level": "Senior",
"education_required": "Master en comptabilité ou audit"
}

```

NB : l'API décrite dans cette implémentation a pour vocation de montrer l'utilisation des fonctions/actions/outils par les agents IA (voir le chapitre 2.5.1). Une évolution de cet agent pourrait consister à lui faire rechercher de vrais postes trouvés sur Internet afin d'augmenter le réalisme et la diversité des postes générés. Ce serait, encore une fois, via une API de recherche que l'agent exécuterait cette action.

8.1.2. Optimisation du prompt pour la génération de postes

En utilisant les capacités de LLM plus grands et plus puissants tel que GPT4-o1, il est possible d'avoir une version optimisée du prompt pour l'agent IA de génération de poste.

8.1.2.1. Prompt pour l'optimiseur de prompt - GPT-4o1.

```
## Objectif
Je voudrais que tu optimises ce prompt suivant :

## Prompt existant

### [PROMPT]
Tu es un assistant qui génère des descriptifs de postes réalistes.

1. **Étape préliminaire :**
    Demande à l'utilisateur combien de postes il faut générer par métier
    et combien de métiers il veut traiter.

2. **Étape 1 :**
    Tu dois choisir un métier parmi la liste retournée par tes outils
    disponibles. Ne demande pas à l'utilisateur de choisir.
    Choisis par toi-même.

3. **Étape 2 :**
    Génère :
    - Un nom de compagnie.
    - Une description du poste.
    - Le rôle et les responsabilités du poste.
    - Les compétences requises pour occuper ce poste.
```


4. ****Étape 3 : ****

Formate ces informations au format JSON selon le modèle suivant sans afficher ce contenu à l'utilisateur :

```
```json
{
 "company_name": "",
 "job_title": "",
 "job_description": "",
 "responsibilities": [],
 "skills_required": [],
 "location": "",
 "experience_level": "",
 "education_required": ""
}
```

#### 5. **\*\*Étape 4 : \*\***

Recommence à l'étape 1 tant que la quantité demandée n'est pas complétée.

#### 6. **\*\*Étape finale : \*\***

Prends tous ces JSON, regroupe-les dans un JSON liste des postes, et mets-les dans un fichier '.json' que l'utilisateur pourra télécharger.

---

### **## Types de demandes**

#### **### [DURANT LA CONVERSATION DEMANDE DE L'UTILISATEUR]**

- Lance le processus.
- 1 poste par métier, 5 métiers.
- 5 postes par métier, 1 métier.
- Relance une autre session.
- 5 postes par métier et 5 métiers (de préférence des métiers non scientifiques ou techniques).
- 5 postes par métier, 30 métiers, donc 150 postes distincts, avec

des noms d'entreprise distincts et originaux (pas de noms tels que "école 1", "école 2", ...).

Assure un contrôle qualité de ce que tu produis.

- 2 postes par métier (1 junior et 1 senior), 10 métiers, 5 plutôt scientifiques ou techniques et 5 non scientifiques ou techniques,

des noms originaux d'entreprises prises dans l'univers de Harry Potter, aucun item générique dans les descriptions, localisation en Europe, le nom du fichier doit contenir le nombre de postes et de métiers.

---

## Problèmes rencontrés avec le prompt actuel

### [DURANT LA CONVERSATION FEEDBACK DE L'UTILISATEUR]

- On devrait avoir 25 entrées, je n'en vois que 5.
- Tu as juste copié 5 fois le même poste par métier. Je veux à chaque fois un poste différent (une entreprise différente, des compétences différentes, des expériences différentes...).
- Il ne contient que 3 postes pour 1 seul métier.
- Cela manque de réalisme ! Les tâches, compétences, expériences ne peuvent pas être génériques !

---

## Demande finale

Écris-moi un prompt plus efficace.

#### 8.1.2.2. Résultat de l'optimiseur de prompt.

# Génération de Descriptifs de Postes Réalistes et Détaillés

## Étape Préliminaire

Demande à l'utilisateur :

- Combien de postes il souhaite générer par métier.
- Combien de métiers il veut traiter.

- S'il a des préférences spécifiques (types de métiers, niveaux d'expérience, localisation, thèmes particuliers pour les noms d'entreprises, etc.).

## ## Étape 1

Pour chaque métier à traiter :

- Sélectionne un métier distinct, en respectant les préférences de l'utilisateur (par exemple, métiers scientifiques, techniques, non scientifiques).
- Assure-toi que les métiers choisis sont variés et correspondent aux critères donnés.

## ## Étape 2

Pour chaque poste à générer pour chaque métier :

- **\*\*Nom de l'entreprise\*\*** : Génère un nom d'entreprise original et unique, en respectant les thèmes éventuels demandés (par exemple, univers de Harry Potter).
- **\*\*Titre du poste\*\*** : Crée un titre de poste spécifique et pertinent pour le métier.
- **\*\*Description du poste\*\*** : Rédige une description détaillée et réaliste, en évitant les généralités.
- **\*\*Responsabilités\*\*** : Liste des responsabilités spécifiques au poste, en étant précis et exhaustif.
- **\*\*Compétences requises\*\*** : Énumère les compétences nécessaires, en détaillant chaque compétence.
- **\*\*Localisation\*\*** : Indique la localisation du poste, en respectant les préférences géographiques de l'utilisateur (par exemple, Europe).
- **\*\*Niveau d'expérience\*\*** : Spécifie le niveau d'expérience requis (par exemple, Junior, Senior), en alignement avec les demandes de l'utilisateur.
- **\*\*Éducation requise\*\*** : Précise les qualifications éducatives nécessaires pour le poste.

## ## Étape 3

Formate toutes ces informations dans le format JSON suivant, sans les afficher à l'utilisateur à ce stade :

```
```json
{
  "company_name": "",
  "job_title": "",
  "job_description": "",
  "responsibilities": [],
  "skills_required": [],
  "location": "",
  "experience_level": "",
  "education_required": ""
}
```

Étape 4

Répète les étapes 1 à 3 jusqu'à atteindre le nombre total de postes demandés par l'utilisateur.

Étape 5

Contrôle Qualité

- Vérifie que chaque poste est unique et qu'il n'y a pas de duplicatas.
- Assure-toi que les descriptions, responsabilités et compétences sont spécifiques et non génériques.
- Confirme que tous les critères et préférences de l'utilisateur ont été respectés.

Étape Finale

Rassemble tous les JSON des postes dans une liste sous la clé "postes", par exemple :

```
'''json
{
  "postes": [/* liste des postes */]
}
```

Nomme le fichier '.json' en incluant le nombre de postes et de métiers si l'utilisateur l'a spécifié (par exemple, '10_postes_5_metiers.json').

Propose le fichier '.json' à l'utilisateur pour qu'il puisse le télécharger.

Notes Additionnelles

- Si l'utilisateur demande de relancer une session ou de modifier les critères, retourne à l'étape préliminaire en prenant en compte les nouvelles informations.
- Sois attentif aux demandes spécifiques, comme éviter les métiers scientifiques ou utiliser des noms d'entreprises issus d'un certain univers.
- Maintiens une communication claire avec l'utilisateur si des clarifications sont nécessaires, mais évite de le surcharger de questions inutiles.
- Ton objectif principal est de fournir un ensemble de descriptifs de postes qui répondent précisément aux attentes de l'utilisateur, en étant réalistes et détaillés.

8.2. Équipe d'agents IA de création des profils candidats

8.2.1. Implémentation

Il vous faut un compte payant sur OpenAI pour utiliser les LLM nécessaires à CrewAI. Vous payez ce que vous consommez.

Il vous faut également un compte gratuit sur AgentOPS pour suivre le flux de travail des agents sur leurs tâches dans l'équipe CrewAI. C'est optionnel mais néanmoins très utile pour le débogage.

L'ensemble du code de l'équipe tient dans un seul fichier Python et consiste principalement à décrire les 4 agents et les 4 tâches au travers des classes (au sens de la programmation orientée objet) fournies par le framework **CrewAI**.

Les agents sont définis avec un modèle de LLM choisi parmi 3 configurés avec des variations sur paramètres suivants :

- **temperature** : ce paramètre contrôle le niveau de créativité des réponses générées. Une valeur proche de 0 rend les réponses plus déterministes et précises, tandis qu'une valeur proche de 1 produit des réponses plus variées et créatives.
- **top_p** : ce paramètre applique un échantillonnage qui permet de ne considérer que les tokens ayant une probabilité cumulative dans un certain pourcentage (p). Par exemple, une valeur de 0.8 inclut les tokens ayant un cumul de probabilité totalisant 80
- **frequency_penalty** : ce paramètre ajuste la probabilité d'inclure des tokens fréquemment utilisés. Une valeur positive réduit la probabilité que des mots répétés soient utilisés, favorisant ainsi une plus grande diversité.
- **presence_penalty** : ce paramètre favorise l'inclusion de nouveaux tokens non encore présents dans le contexte. Une valeur positive encourage l'originalité en rendant moins probable la réutilisation des mêmes mots ou idées.

Cela permet donc de jouer sur le niveau de créativité attendu pour les tâches que doit réaliser l'agent. Par exemple, l'agent de création de profil du candidat idéal aura besoin d'une plus grande créativité que l'agent préparateur qui se cantonne à lire un fichier et y extraire des informations.

Les agents sont définis également par un court texte décrivant leur rôle, un court texte précisant leur but à atteindre, un texte relatant leurs antécédents et les outils dont ils disposent pour faire leur travail. Les tâches sont décrites par un texte où figure les instructions à suivre, un texte décrivant le livrable attendu à la fin et une association avec l'agent qui doit la réaliser. Un agent peut réaliser plusieurs tâches et une tâche est réalisée par un seul agent. Enfin, les agents et leurs tâches sont mises dans une équipe, qui est une classe également fournie par le framework, et en charge d'orchestrer l'exécution des tâches. Voici un exemple complet pour décrire l'**agent de rédaction de persona** et sa tâche :

```

llm_middle_creative = LLM(
    model="gpt-4o",
    temperature=0.8,
    top_p=0.9,
    frequency_penalty=0.1,
    presence_penalty=0.1,
)

file_writer_tool = FileWriterTool()

redacteur_personna_candidat = Agent(
    role="Rédacteur de personna",
    goal="Créer un personna selon un profil de candidat",
    backstory=dedent(
        """
        Tu es un rédacteur expérimenté pour produire un personna réaliste
        pour compléter un profil de candidat.
        """
    ),
    allow_delegation=False,
    verbose=True,
    llm=llm_middle_creative,
    tools=[file_writer_tool],
)

completer_profil_candidat = Task(
    description="""Tu dois rédiger un texte structuré en {langue_de_travail},
    voici les instructions:
    Instructions
    -----
    Tu dois compléter le profil du candidat anonyme qui répond
    au poste à pourvoir.
    Tu dois générer et ajouter au profil les informations suivantes :
        * Nom et prénom [prénom et nom variés selon le genre {genre}]
        * Passions et loisirs [plusieurs item]
        * pourquoi il est le bon candidat pour le poste [plusieurs item]

```

```

"""
expected_output="""Le profil complet du candidat idéal complété selon
les instructions.
Formatter toutes les informations selon le format suivant :
{{
    "poste_num": "{poste_num}",
    "company_name": "",
    "job_title": "",
    "candidate_full_name": "",
    "passions_hobbies": [],
    "why_is_a_good_fit": [],
    "academic_background_certifications": [],
    "technical_professional_skills": [],
    "interpersonal_soft_skills": [],
    "professional_experiences": [],
}}
Points de vigilance :
1- company_name et job_title proviennent des informations transmises
par le rédacteur du poste.
2- professional_experiences est une liste de dictionnaires python
mentionnant le titre et les responsabilités occupées.
3- l'outil File Writer nécessite un contenu en format string.
4- ajoute des retours à la ligne pour que la structure du profil
soit lisible.

Écrit le profil complet dans le fichier {fichier_candidats}
dans le répertoire {output_path}.
"""

agent=redacteur_personna_candidat,
)

```

Finalement la programmation d'agents IA se fait principalement en langage naturel sous forme de descriptions textuelles de ce qui est attendu. Le reste est pris en charge par le framework qui traduit les agents et leurs tâches en prompts et appels de fonctions. Tout

cela semble magique mais il faut recourir à une analyse des logs pour bien comprendre ce qui se joue en arrière scène et ajuster les descriptions en conséquences.

Voici un exemple de candidat créé par une itération complète de l'équipe :

```
{
  "poste_num": "6",
  "company_name": "Consultis Group",
  "job_title": "Auditeur financier",
  "candidate_full_name": "Camille Dupont",
  "passions_hobbies": ["Randonnée en montagne", "Lecture de romans policiers",...],
  "why_is_a_good_fit": ["Solide expérience en audit financier ...",
  "Aptitude à former et encadrer des équipes,..."],
  "academic_background_certifications":
    ["Master en Comptabilité, Université de Paris-Dauphine, obtenu en 2008",
    "Certification CPA (Certified Public Accountant), obtenue en 2010"],
  "technical_professional_skills":
    ["Maîtrise des normes internationales d'audit (ISA)...",
    "Expertise en analyse financière et évaluation ...", ...],
  "interpersonal_soft_skills":
    ["Excellentes compétences en communication orale et écrite",
    "Capacité à travailler ..."],
  "professional_experiences": [
    {"title": "Auditeur Senior, Deloitte France, Paris, 2015 - Présent",
      "responsibilities":
        ["Conduite d'audits financiers complexes pour des entreprises ...",
        ...]},
    {"title": "Auditeur, PwC, Paris, 2010 - 2015", "
      responsibilities":
        ["Réalisation d'audits financiers pour diverses industries, ...]}
  ]
}
```

L'outil AgentOPS est une plateforme permettant de suivre l'exécution et l'utilisation des agents d'intelligence artificielle (IA).

Objectifs de l'outil :

- Fournir un aperçu détaillé de l'utilisation des agents, y compris leur coût, leur durée et leur efficacité (*suivi des performances*).




Fig. 8.3. Suivi d'une session de travail de l'équipe d'agent avec l'outil AgentOPS.

- Permettre de comprendre comment les agents interagissent entre eux et avec les outils à leur disposition (*analyse des interactions*).
- Identifier les goulots d'étranglement et optimiser l'utilisation des ressources pour des tâches spécifiques (*optimisation des processus*).

Suivi d'une session de travail (figure 8.3) :

- **Session Drill-Down** : cette section détaille des informations sur une session d'exécution d'agent, y compris son coût, sa durée et son état (succès ou échec). Elle fournit aussi des détails techniques comme les versions des bibliothèques utilisées (par exemple, `openai`, `crewai.tools`, `langchain`), la configuration matérielle (nombre de cœurs CPU, RAM), et le système d'exploitation (ici, Windows).
- **Agents disponibles** : les agents listés (*Préparateur*, *Rédacteur de poste*, etc.) correspondent à la constitution de l'équipe.

Détail des coulisses (figure 8.4) :

- **Analyse de session** : le graphique à droite montre une visualisation des actions entreprises par un agent (temps d'activation des outils, durée d'exécution). Cela permet de comprendre comment les agents collaborent pour accomplir une tâche donnée.
- **Analyse des prompts** : on observe que l'agent *rédacteur de persona* utilise des consignes explicites pour produire un "persona réaliste" en fonction des informations fournies.




Fig. 8.4. Détail des coulisses pour un agent avec l'outil AgentOPS.

8.3. Agent IA de génération de profils de recruteur

8.3.1. Implémentation

Il vous faut un compte payant sur OpenAI pour utiliser les LLM nécessaires. Vous payez ce que vous consommez.

Il vous faut également un compte gratuit sur Comet/Opik pour déboguer et effectuer des réglages sur les prompts. Le suivi des traces des appels LLM et la gestion des versions de prompts se fait directement en ligne.

L'ensemble du code ³ pour générer les profils de recruteur tient dans un seul fichier Python et consiste principalement à créer un prompt pour l'agent à partir d'un méta prompt, puis d'exécuter l'agent avec le prompt ainsi généré. La génération des traces et l'utilisation des prompts sont facilités par le framework Opik.

Les LLM sont initialisés avec 2 configurations de paramètres de temperature, top_p, frequency_penalty, et presence_penalty. Le LLM chargé de créer le prompt aura une configuration déterministe et l'agent de génération du profil recruteur aura une configuration lui permettant d'être plus créatif.

paramètres pour le LLM déterministe

³Instructions et codes sur GitHub delemarchand2020

```
model_llm_prompt_gen = "gpt-4o"  
temperature_llm_prompt_gen = 0.0  
top_p_llm_prompt_gen = 1.0  
frequency_penalty_llm_prompt_gen = 0.0  
presence_penalty_llm_prompt_gen = 0.0
```

```
# paramètres pour le LLM plus créatif  
model_llm_profil_gen = "gpt-4o"  
temperature_llm_profil_gen = 0.8  
top_p_llm_profil_gen = 0.9  
frequency_penalty_llm_profil_gen = 0.2  
presence_penalty_llm_profil_gen = 0.2
```

8.3.2. Génération du prompt pour l'agent

8.3.2.1. Méta prompt.

```
Tu es un expert en génération de prompt.  
# contexte  
Tu dois créer un prompt permettant à un agent de créer un profil  
de recruteur.  
Utilise la langue {{langue_de_travail}} pour écrire ton prompt.  
Ce profil de recruteur servira plus tard à implémenter un  
recruteur virtuel impliqué dans une simulation de recrutement  
d'un candidat pour un poste.  
# ce que doit accomplir l'agent avec le prompt que tu dois créer  
- générer un prénom et nom pour le recruteur dont le genre est  
{{genre}}  
- générer une description sommaire de son rôle et de ses  
responsabilités en tant que recruteur du secteur {{secteur}}  
- générer ses passions et loisirs  
- générer une description précise du biais dont il est affublé :  
{{biais}}  
- générer des exemples sur comment la manifestation de son biais  
peut influencer son recrutement (posture dans la conversation,  
type de questions, ...) : la manifestation du biais doit être  
tangibile dans la communication (pas utile de donner des exemples
```

```

sur le langage corporel)
- fournir le profil en JSON avec les informations suivantes:
  "recruiter_full_name": "",
  "role_description": "",
  "responsibilities": [],
  "passions_hobbies": [],
  "bias": "",
  "bias_hints": []
# consignes complémentaires
- génère uniquement le prompt
- ne donne pas de commentaire ou d'introduction sur ton travail

```

8.3.2.2. Exemple de prompt généré pour l'agent.

Créez un profil de recruteur virtuel en suivant les instructions ci-dessous. Le profil doit être rédigé en français et structuré en format JSON. Assurez-vous que chaque élément requis est bien rempli.

1. ****Générer un prénom et nom masculin pour le recruteur.****
2. ****Décrire sommairement son rôle et ses responsabilités en tant que recruteur dans le secteur informatique.****
3. ****Lister ses passions et loisirs.****
4. ****Décrire précisément le biais dont il est affublé : un stéréotype sur le genre féminin.****
5. ****Fournir des exemples concrets sur comment ce biais peut influencer son processus de recrutement, notamment dans sa communication verbale (posture dans la conversation, type de questions, etc.).****

Présentez le profil sous le format JSON suivant :

```

'''json
{
  "recruiter_full_name": "Prénom Nom",
  "role_description": "Description sommaire du rôle et des
responsabilités en tant que recruteur dans le secteur
informatique.",

```

```

"responsibilities": [
  "Responsabilité 1",
  "Responsabilité 2",
  "Responsabilité 3"
],
"passions_hobbies": [
  "Passion ou loisir 1",
  "Passion ou loisir 2",
  "Passion ou loisir 3"
],
"bias": "Description précise du biais lié au stéréotype sur le
genre féminin.",
"bias_hints": [
  "Exemple 1 de manifestation du biais dans la communication",
  "Exemple 2 de manifestation du biais dans la communication",
  "Exemple 3 de manifestation du biais dans la communication"
]
}
'''

```

Assurez-vous que chaque champ est rempli de manière cohérente et réaliste pour créer un profil de recruteur virtuel crédible.

Voici un exemple de profil créé par l'agent :

```

{
  "recruiter_full_name": "Marc Dupont",
  "role_description": "En tant que recruteur dans le secteur
informatique, Marc est chargé d'identifier, d'évaluer et de
sélectionner les meilleurs talents pour répondre aux besoins
en personnel technique de son entreprise.",
  "responsibilities": [
    "Analyser les besoins en recrutement et rédiger des
descriptions de poste.",
    "Sourcer et présélectionner des candidats potentiels à
travers différents canaux.",
    "Conduire des entretiens pour évaluer les compétences
techniques et culturelles des candidats."
  ],

```

```

"passions_hobbies": [
    "Lecture de science-fiction",
    "Randonnée en montagne",
    "Programmation de jeux vidéo"
],
"bias": "Marc a tendance à sous-estimer les compétences
techniques des candidates féminines, croyant inconsciemment
qu'elles ont moins d'expérience ou d'intérêt pour la
technologie que leurs homologues masculins.",
"bias_hints": [
    "Lors des entretiens, Marc pose systématiquement plus de
questions techniques détaillées aux candidates féminines
pour 'vérifier' leurs connaissances.",
    "Il exprime souvent une surprise positive lorsqu'une
candidate démontre un haut niveau de compétence
technique, ce qui peut être perçu comme condescendant.",
    "Dans ses conversations avec les collègues, il utilise
parfois des tournures de phrases qui minimisent
involontairement les réalisations des femmes dans le
domaine technologique."
]
}

```

8.4. Génération des conversations d'entrevue

8.4.1. Implémentation

Il vous faut un compte payant sur OpenAI pour utiliser les LLM nécessaires à **CrewAI**. Vous payez ce que vous consommez.

Il vous faut également un compte gratuit sur **AgentOPS** pour suivre le flux de travail des agents sur leurs tâches dans l'équipe **CrewAI**. C'est optionnel mais néanmoins très utile pour le débogage.

L'ensemble du code de l'équipe tient dans un seul fichier Python et consiste à définir les 2 agents avec leurs profils respectifs, décrire leurs tâches (consignes au recruteur pour poser les questions, consignes au candidat pour lui répondre) au travers des classes (au sens de la

programmation orientée objet) fournies par le framework **CrewAI** puis de programmer le flux de travail de ces 2 agents en mémorisant les questions/réponses afin de constituer l'historique.

Les agents sont définis avec un modèle de LLM configuré avec des paramètres favorisant la créativité :

- **temperature** : 0.9
- **top_p** : 0.9
- **frequency_penalty** : 0.2
- **presence_penalty** : 0.2

Cela permet donc de jouer sur le niveau de créativité attendu pour générer une conversation "plausible".

Les agents sont définis par un court texte décrivant leur rôle, leur but à atteindre et leurs antécédents. Les tâches sont décrites par un texte où figure les instructions à suivre et un texte décrivant le livrable attendu à la fin.

Voici un exemple complet pour décrire l'**agent recruteur** et sa tâche :

```
biais = False if RecruiterDataUtils.get_bias(profil_recruteur) == "" else True

recruteur = Agent(
    role=f"{RecruiterDataUtils.get_recruiter_full_name(profil_recruteur)},
        un recruteur",
    goal=dedent(
        f"""
        Tu recherches un candidat pour le poste suivant :
        Titre du poste : {JobDataUtils.get_job_title(profil_poste)}
        Nom de l'entreprise : {JobDataUtils.get_company_name(profil_poste)}
        Description du poste : {JobDataUtils.get_job_description(profil_poste)}
        Responsabilités : {JobDataUtils.get_responsibilities(profil_poste)}
        Compétences requises : {JobDataUtils.get_skills_required(profil_poste)}
        Localisation : {JobDataUtils.get_location(profil_poste)}
        Niveau d'expérience : {JobDataUtils.get_experience_level(profil_poste)}
        Éducation requise : {JobDataUtils.get_education_required(profil_poste)}
        """
    )
)
```



```

    ),
    backstory=dedent(
        f"""
        {RecruiterDataUtils.get_role_description(profil_recruteur)}.
        ses passions/loisirs:
        {RecruiterDataUtils.get_passions_hobbies(profil_recruteur)}.
        ses responsabilités:
        {RecruiterDataUtils.get_responsibilities(profil_recruteur)}.
        {"Ses convictions personnelles : " if biais else ""}
        {RecruiterDataUtils.get_bias(profil_recruteur) if biais else ""}
        {RecruiterDataUtils.get_bias_hints(profil_recruteur) if biais else ""}
        """
    ),
    verbose=True,
    llm=llm_creative
)

task_recruteur = Task(
    description=dedent(
        """
        HISTORIQUE de l'entrevue :
        {historique}
        -----
        CONSIGNES :
        1) Prend connaissance de l'historique de l'entrevue ci-dessus.
        2) Réagis brièvement à la dernière réponse du/de la candidat(e) puis
           pose une nouvelle question selon tes convictions personnelles
           (subtilement) et en rapport avec les responsabilités du poste à
           combler.
        """
    ),
    expected_output=dedent(
        """
        Une ou deux phrases.
        """
    ),

```

```

    agent=recruteur
)

```

Voici un exemple complet pour décrire l'**agent candidat** et sa tâche :

```

candidat = Agent(
    role=f"{CandidateDataUtils.get_candidate_full_name(profil_candidat)},
        un(e) candidat(e)",
    goal=dedent(
        f"""
        Tu postules au poste suivant :
        Titre du poste : {JobDataUtils.get_job_title(profil_poste)}
        Nom de l'entreprise : {JobDataUtils.get_company_name(profil_poste)}
        Description du poste : {JobDataUtils.get_job_description(profil_poste)}
        Responsabilités : {JobDataUtils.get_responsibilities(profil_poste)}
        Compétences requises : {JobDataUtils.get_skills_required(profil_poste)}
        Localisation : {JobDataUtils.get_location(profil_poste)}
        Niveau d'expérience : {JobDataUtils.get_experience_level(profil_poste)}
        Éducation requise : {JobDataUtils.get_education_required(profil_poste)}
        Tu penses que tu es un bon candidat car tu possèdes :
        {CandidateDataUtils.get_why_is_a_good_fit(profil_candidat)}.
        Ta motivation est grande pour obtenir ce job !
        """
    ),
    backstory=dedent(
        f"""
        Tes passions et loisirs :
        {CandidateDataUtils.get_passions_hobbies(profil_candidat)}.
        Tes Formation et certifications :
        {CandidateDataUtils.get_academic_background_certifications(profil_candidat)}.
        Tes compétences techniques et professionnelles :
        {CandidateDataUtils.get_technical_professional_skills(profil_candidat)}.
        Tes compétences interpersonnelles :
        {CandidateDataUtils.get_interpersonal_soft_skills(profil_candidat)}.
        Tes expériences professionnelles :
        {CandidateDataUtils.get_professional_experiences(profil_candidat)}.
        """
    )
)

```

```

        """
    ),
    verbose=True,
    llm=llm_creative
)

task_candidat = Task(
    description=dedent(
        """
        HISTORIQUE de l'entrevue :
        {historique}
        -----

        CONSIGNES :
        1) Prend connaissance de l'historique de l'entrevue ci-dessus.
        2) Répond brièvement à la dernière question du recruteur mettant en
           avant tes compétences et ton expérience en rapport avec les
           responsabilités du poste auquel tu postules.
        """
    ),
    expected_output="Une ou deux phrases.",
    agent=candidat
)

```

Finalement la programmation d'agents IA se fait principalement en langage naturel sous forme de descriptions textuelles de ce qui est attendu. Le reste est pris en charge par le framework qui traduit les agents et leurs tâches en prompts. Tout cela semble magique mais il faut recourir à une analyse des logs pour bien comprendre ce qui se joue en arrière scène et ajuster les prompts en conséquences.

Voici un extrait d'une conversation créé :

```

[
  {
    "role": "Recruteur",
    "message": "Bonjour Émilie Durand, vous postulez pour le poste de Ingénieur
Logiciel Full Stack, dites m'en un peu plus sur vous et ce qui vous motive dans
ce poste ?"
  }
]

```

```

},
{
  "role": "Candidat",
  "message": "Je suis passionnée par la technologie et possède une solide
formation en ingénierie informatique avec une expertise en développement full
stack, notamment en React et Node.js, ce qui me motive à contribuer à des
applications web innovantes chez TechNova Solutions. Mon expérience en
collaboration avec des équipes UX/UI et en intégration d'API me permettra
d'apporter une valeur ajoutée significative à ce poste."
},
{
  "role": "Recruteur",
  "message": "Votre parcours est intéressant, Émilie. Pourriez-vous détailler
une expérience passée où vous avez dû résoudre un problème technique complexe et
comment vous l'avez abordé ?"
},
{
  "role": "Candidat",
  "message": "Lors de mon expérience chez StartTech Innovations, j'ai résolu
un problème complexe en optimisant l'intégration d'une API tierce, ce qui a
amélioré la performance de l'application web. J'ai utilisé mes compétences en
Node.js et mes connaissances des bases de données NoSQL pour élaborer une
solution innovante, tout en collaborant étroitement avec l'équipe pour assurer
une implémentation fluide."
},
...
]

```

8.4.2. Évaluation de la qualité des conversations

Pour évaluer la qualité d'une conversation, au sens de l'objectif du projet, il faut passer la conversation à un agent IA avec le prompt suivant :

Évaluation EDI d'une entrevue de recrutement

****Contexte :****

Vous êtes un agent EDI (Équité, Diversité, Inclusion) chargé d'analyser

les conversations d'entrevue. L'objectif est d'identifier les biais potentiels dans la façon dont cette entrevue a été menée, afin de garantir un processus équitable et inclusif.

****Objectif de la mission :****

- Comparer et analyser l'entrevue pour mettre en évidence toute forme de parti pris (biais conscient ou inconscient).
- Identifier les questions, attitudes et comportements pouvant indiquer un traitement inéquitable ou discriminatoire.
- Faire des recommandations concrètes pour améliorer le processus de recrutement.

Instructions pour l'Agent EDI

1. **Analyse du contenu de l'échange :**

- Analyser la structure de l'entrevue, les types de questions posées, la tonalité.
- Relevez les indices dans les thèmes abordés, le langage utilisé, la quantité et la qualité des informations demandées.

2. **Identification des biais potentiels :**

- Surveillez tout stéréotype ou présomption basée sur le genre, l'origine ethnique, l'âge, l'orientation sexuelle, la religion, le statut social, un handicap, etc.
- Vérifiez si certains sujets de conversation ou questions sont posés de manière inappropriée.

3. **Évaluation de la neutralité du recruteur :**

- Notez le ton, le langage corporel (si observé) ou l'empressement à renseigner ou aider les candidat·e·s.
- Repérez toute insistance particulière ou tout favoritisme implicite dans la façon de conclure l'entrevue ou de donner des informations sur l'étape suivante du processus.

4. **Conclusion et recommandations :**

- Déterminez si des biais ont été détectés et précisez leur nature.
- Fournissez des pistes d'amélioration (formation aux biais inconscients, grille d'évaluation standardisée, etc.) pour que le recruteur puisse mener des entrevues plus équitables et inclusives à l'avenir.

****Format de rendu attendu****

1. ****Résumé de l'analyse :** Présentez en quelques phrases les principales observations sur l'entrevue.
2. ****Observations détaillées :** Fournissez des exemples précis (avec extraits ou références aux minutes/phrases-clés) pour étayer vos constats.
3. ****Diagnostic de biais :** Mettez en évidence les éventuels points de discrimination ou de partialité.
4. ****Recommandations :** Proposez des actions concrètes pour corriger les biais constatés et renforcer l'équité du processus de recrutement.

****Votre mission :** Passez au crible l'entrevue et répondez ensuite en suivant la structure demandée (Résumé, Observations détaillées, Diagnostic, Recommandations). Vous devez fournir une évaluation objective et constructive, à l'appui de la promotion de l'équité, de la diversité et de l'inclusion dans le processus de recrutement. Enfin, donnez un score sur 100 de la présence de biais potentiels chez ce recruteur.

Les premiers résultats n'ont pas été probants lorsque nous avons comparé séparément l'analyse de 2 conversations, l'une avec un candidat cible pour le biais de genre du recruteur et l'autre avec un candidat hors cible. Nous avons réussi à mettre en évidence le biais en faisant comparer les 2 conversations par l'agent IA avec ce nouveau prompt :

Évaluation EDI de deux entrevues de recrutement pour le même poste

****Contexte :****

Vous êtes un agent EDI (Équité, Diversité, Inclusion) chargé d'analyser deux conversations d'entrevue distinctes. Celles-ci ont été menées par le même recruteur et concernent le même poste. L'objectif est d'identifier les biais potentiels dans la façon dont ces entrevues ont été menées, afin de garantir un processus équitable et inclusif.

****Objectif de la mission :****

- Comparer et analyser les deux entrevues pour mettre en évidence toute forme de parti pris (biais conscient ou inconscient).
- Identifier les questions, attitudes et comportements pouvant indiquer un

traitement inéquitable ou discriminatoire.

- Faire des recommandations concrètes pour améliorer le processus de recrutement.

Instructions pour l'Agent EDI

1. **Analyse du contenu des échanges :**

- Comparez la structure de l'entrevue, les types de questions posées, la tonalité et la durée de chaque entretien.
- Relevez toutes différences notables dans les thèmes abordés, le langage utilisé, la quantité et la qualité des informations demandées.

2. **Identification des biais potentiels :**

- Surveillez tout stéréotype ou présomption basée sur le genre, l'origine ethnique, l'âge, l'orientation sexuelle, la religion, le statut social, un handicap, etc.
- Vérifiez si certains sujets de conversation ou questions sont posés de manière inappropriée, ou ciblent l'un des candidats de façon injuste (p. ex. questions plus dures ou plus personnelles pour l'un que pour l'autre).

3. **Évaluation de la neutralité du recruteur :**

- Notez les différences de ton, de langage corporel (si observé) ou d'empressement à renseigner ou aider les candidat·e·s.
- Repérez toute insistance particulière ou tout favoritisme implicite dans la façon de conclure l'entrevue ou de donner des informations sur l'étape suivante du processus.

4. **Conclusion et recommandations :**

- Déterminez si des biais ont été détectés et précisez leur nature.
- Fournissez des pistes d'amélioration (formation aux biais inconscients, grille d'évaluation standardisée, etc.) pour que le recruteur puisse mener des entrevues plus équitables et inclusives à l'avenir.

Format de rendu attendu

1. **Résumé de l'analyse : Présentez en quelques phrases les principales

```
observations sur les deux entrevues.
2. **Observations détaillées : Fournissez des exemples précis (extraits
   ou références aux minutes/phrases-clés) pour étayer vos constats.
3. **Diagnostic de biais : Mettez en évidence les éventuels points de
   discrimination ou de partialité.
4. **Recommandations : Proposez des actions concrètes pour corriger les
   biais constatés et renforcer l'équité du processus de recrutement.

**Votre mission : Passez au crible chacune des deux entrevues et répondez
ensuite en suivant la structure demandée (Résumé, Observations détaillées,
Diagnostic, Recommandations). Vous devez fournir une évaluation objective
et constructive, à l'appui de la promotion de l'équité, de la diversité
et de l'inclusion dans le processus de recrutement.
Enfin, donnez un score sur 100 de la présence de biais potentiels
chez ce recruteur. Quel candidat a été selon vous favorisé ?
```

Ceci est une première piste pour implémenter notre agent EDI mais avant toute chose, il faut encore faire une optimisation des prompts recruteur et candidat pour parfaire les conversations : les rendre plus réalistes quant à la manifestation (subtile) du biais.

8.5. Analyse des conversations d'entrevue

8.5.1. Implémentation

Il vous faut un compte payant sur OpenAI pour utiliser les LLM nécessaires à **CrewAI**. Vous payez ce que vous consommez.

Il vous faut également un compte gratuit sur **AgentOPS** pour suivre le flux de travail des agents sur leurs tâches dans l'équipe **CrewAI**. C'est optionnel mais néanmoins très utile pour le débogage.

L'ensemble du code de l'équipe tient dans un seul fichier Python et consiste principalement à décrire les 3 agents et les 3 tâches au travers des classes (au sens de la programmation orientée objet) fournies par le framework **CrewAI**.

Les agents sont définis par un court texte décrivant leur rôle, leur but à atteindre et leurs antécédents. Les tâches sont décrites par un texte où figure les instructions à suivre et un texte décrivant le livrable attendu à la fin.

Voici un exemple complet pour décrire l'**agent rédacteur d'audit** et sa tâche :

```
redacteur_audit = Agent(
    role="Rédacteur d'audit EDI",
    goal="Rédiger le rapport d'audit selon l'analyse EDI.",
    backstory=dedent(
        """
        Tu es un rédacteur expérimenté chargé de produire un rapport EDI
        (Équité, Diversité, Inclusion).
        """
    ),
    allow_delegation=False,
    verbose=False,
    cache=False,
    llm=llm_middle_creative,
    tools=[file_writer_tool],
)

rediger_rapport_audit = Task(
    description=dedent("""
    Reprendre l'analyse EDI et rédiger un rapport d'audit pour un public
    de gestionnaires.
    Présente la méthodologie et l'analyse effectuée.
    Présente les observations et les conclusions de l'analyse.
    Conclue avec le score de biais (stéréotypes) attribué lors de l'analyse.
    """),
    expected_output=dedent("""
    Écrit le rapport complet au format MD dans le fichier {output_file}
    dans le répertoire {output_dir}.
    """),
    agent=redacteur_audit,
)
```

Voici un exemple de rapport généré :

Rapport d'Audit EDI

Méthodologie

L'analyse EDI a été réalisée à partir des transcriptions des entrevues menées avec deux candidats postulant pour le poste de Senior Java Backend Developer - Cloud Solutions Architect. L'objectif était d'identifier les biais potentiels dans le processus de recrutement, en se concentrant sur les questions posées par le recruteur et les réponses des candidats.

Analyse

Entrevue 1

Le recruteur a posé des questions sur l'expérience technique d'Élise, sa collaboration avec les équipes DevOps, et son équilibre travail-vie personnelle. Par exemple, "Comment assurez-vous l'équilibre entre votre vie professionnelle et personnelle, surtout dans un domaine aussi exigeant que le développement backend cloud?"

Entrevue 2

Le recruteur s'est concentré sur les compétences techniques de Marc et sa collaboration avec les équipes DevOps, sans aborder l'équilibre travail-vie personnelle. Par exemple, "Pourriez-vous nous parler d'une situation où vous avez collaboré avec une équipe DevOps pour automatiser le déploiement d'applications sur AWS et des défis que vous avez rencontrés?"

Observations

- **Entrevue 1 :** Le recruteur a posé une question sur l'équilibre travail-vie personnelle uniquement à Élise, ce qui pourrait indiquer un biais de genre, en supposant que les femmes doivent justifier leur capacité à gérer cet équilibre.
- **Entrevue 2 :** L'absence de question sur l'équilibre travail-vie personnelle pour Marc pourrait indiquer un biais implicite, où l'on suppose que cela n'est pas un sujet de préoccupation pour les hommes.

Conclusions

- **Diagnostic de biais :**
 - **Entrevue 1 :** La présence de biais est probable en raison de la question sur l'équilibre travail-vie personnelle posée uniquement à Élise.
 - **Entrevue 2 :** La présence de biais est probable en raison de l'absence de

question sur l'équilibre travail-vie personnelle pour Marc.

- **Recommandations :**

- Former les recruteurs sur les biais inconscients, notamment ceux liés au genre, pour éviter de poser des questions stéréotypées.
- Utiliser une grille d'évaluation standardisée pour s'assurer que les mêmes questions sont posées à tous les candidats, indépendamment de leur genre ou d'autres caractéristiques personnelles.
- Inclure des questions sur l'équilibre travail-vie personnelle pour tous les candidats, afin de garantir une évaluation équitable et complète.

Score de Biais

- **Entrevue 1 :** 50/100 - La présence de biais est probable.
- **Entrevue 2 :** 40/100 - La présence de biais est probable.
- **Score biais global :** 50/100 - En prenant le maximum des deux scores, la présence de biais est probable.

Candidat Favorisé

Marc semble avoir été favorisé, car le recruteur n'a pas abordé l'équilibre travail-vie personnelle, ce qui pourrait indiquer une présomption que cela n'est pas un problème pour lui, contrairement à Élise.

8.6. Calibrage des agents IA EDI

Ces paramètres devraient aider à minimiser la variabilité dans les réponses générées par un modèle de référence stable :

```
model="gpt-4o-2024-08-06",
temperature=0.0,
top_p=1.0,
frequency_penalty=0.0,
presence_penalty=0.0
```

Entre chaque lancement de la génération du rapport EDI, il faut nettoyer les différentes mémoires courte et long termes de l'équipe CrewAI afin de ne pas hériter des précédentes

analyses (CrewAI utilise ces mémoires lors de l'exécution des tâches pour nourrir le contexte)
et donc générer de la variabilité :

```
crewai reset-memories --all
```